Regressão Linear

PNV-3421 – Processos Estocásticos

Prof. Dr. André Bergsten Mendes

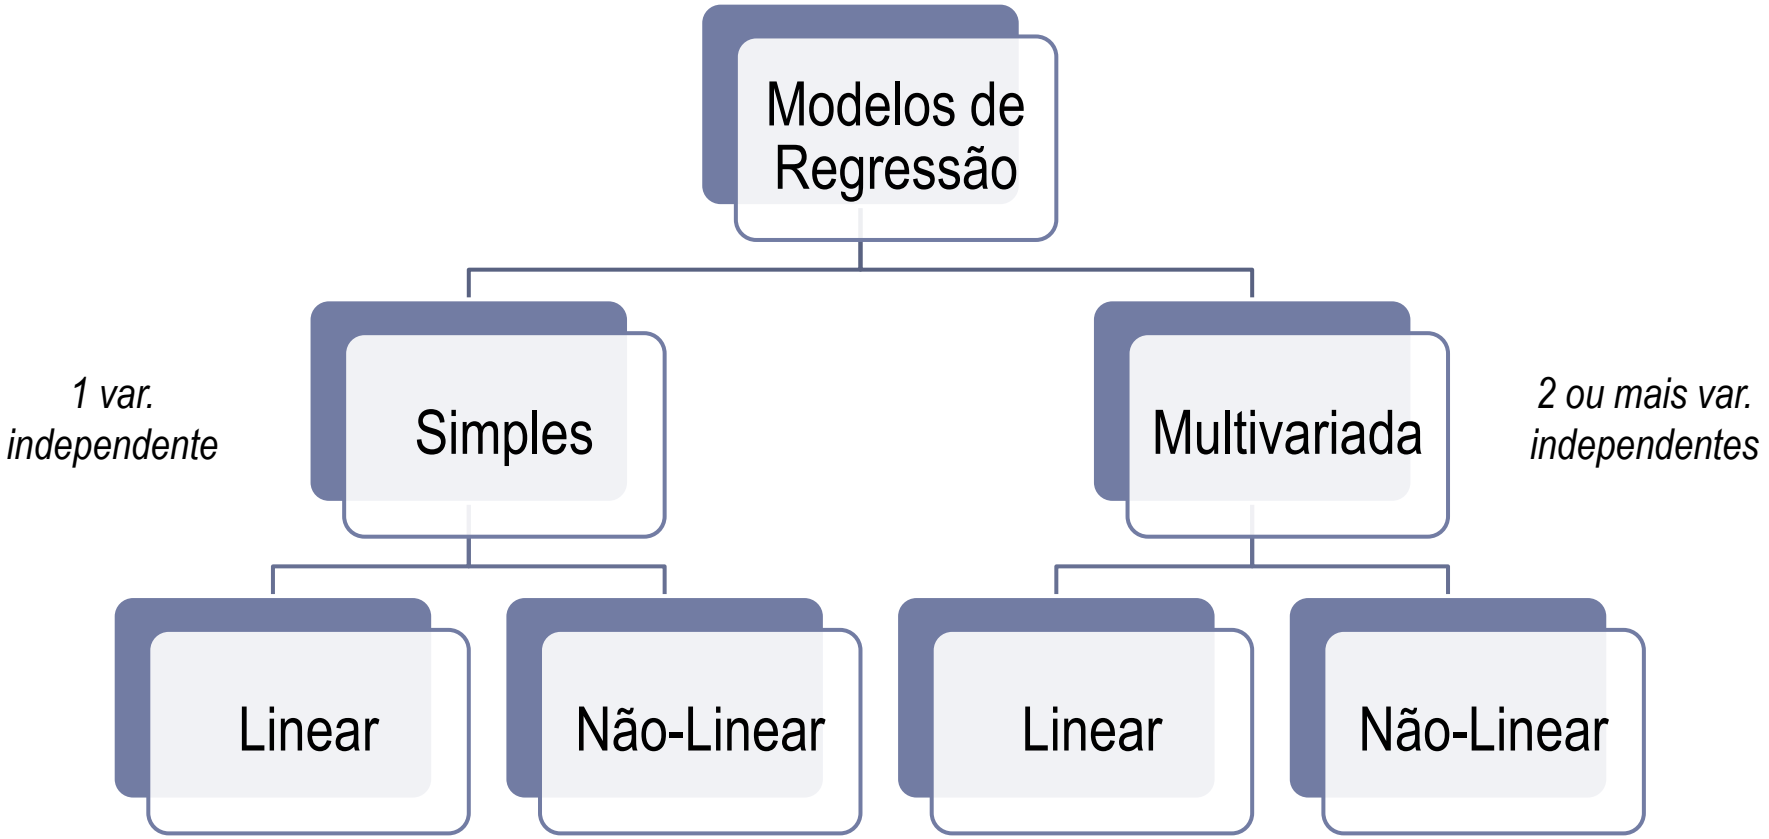
Bibliografia Principal

- Hanke, J.E & Reitsch A.G. (1998) Business Forecasting. 6th Edition, Prentice Hall, Upper Sadle River, NJ.

Modelos de Regressão

- Expressar a relação entre uma variável dependente e variáveis explanatórias (independentes), por meio de uma equação, com o objetivo de previsão.
- As variáveis podem ser numéricas ou indicativas de uma categoria.

Modelos de Regressão



Variáveis Correlacionadas

- Covariância entre duas variáveis aleatórias é uma medida da variabilidade conjunta.

$$\operatorname{cov}(x, y) = \frac{\sum_{i=1}^{n} (x_i - \overline{X})(y_i - \overline{Y})}{n-1}$$

- cov(*x*,*y*) > 0 ⟶ *x* e *y* são correlacionadas positivamente
- cov(*x*,*y*) < 0 ⟶ *x* e *y* são correlacionadas negativamente
- cov(*x*,*y*) = 0 ⟶ *x* e *y* são independentes

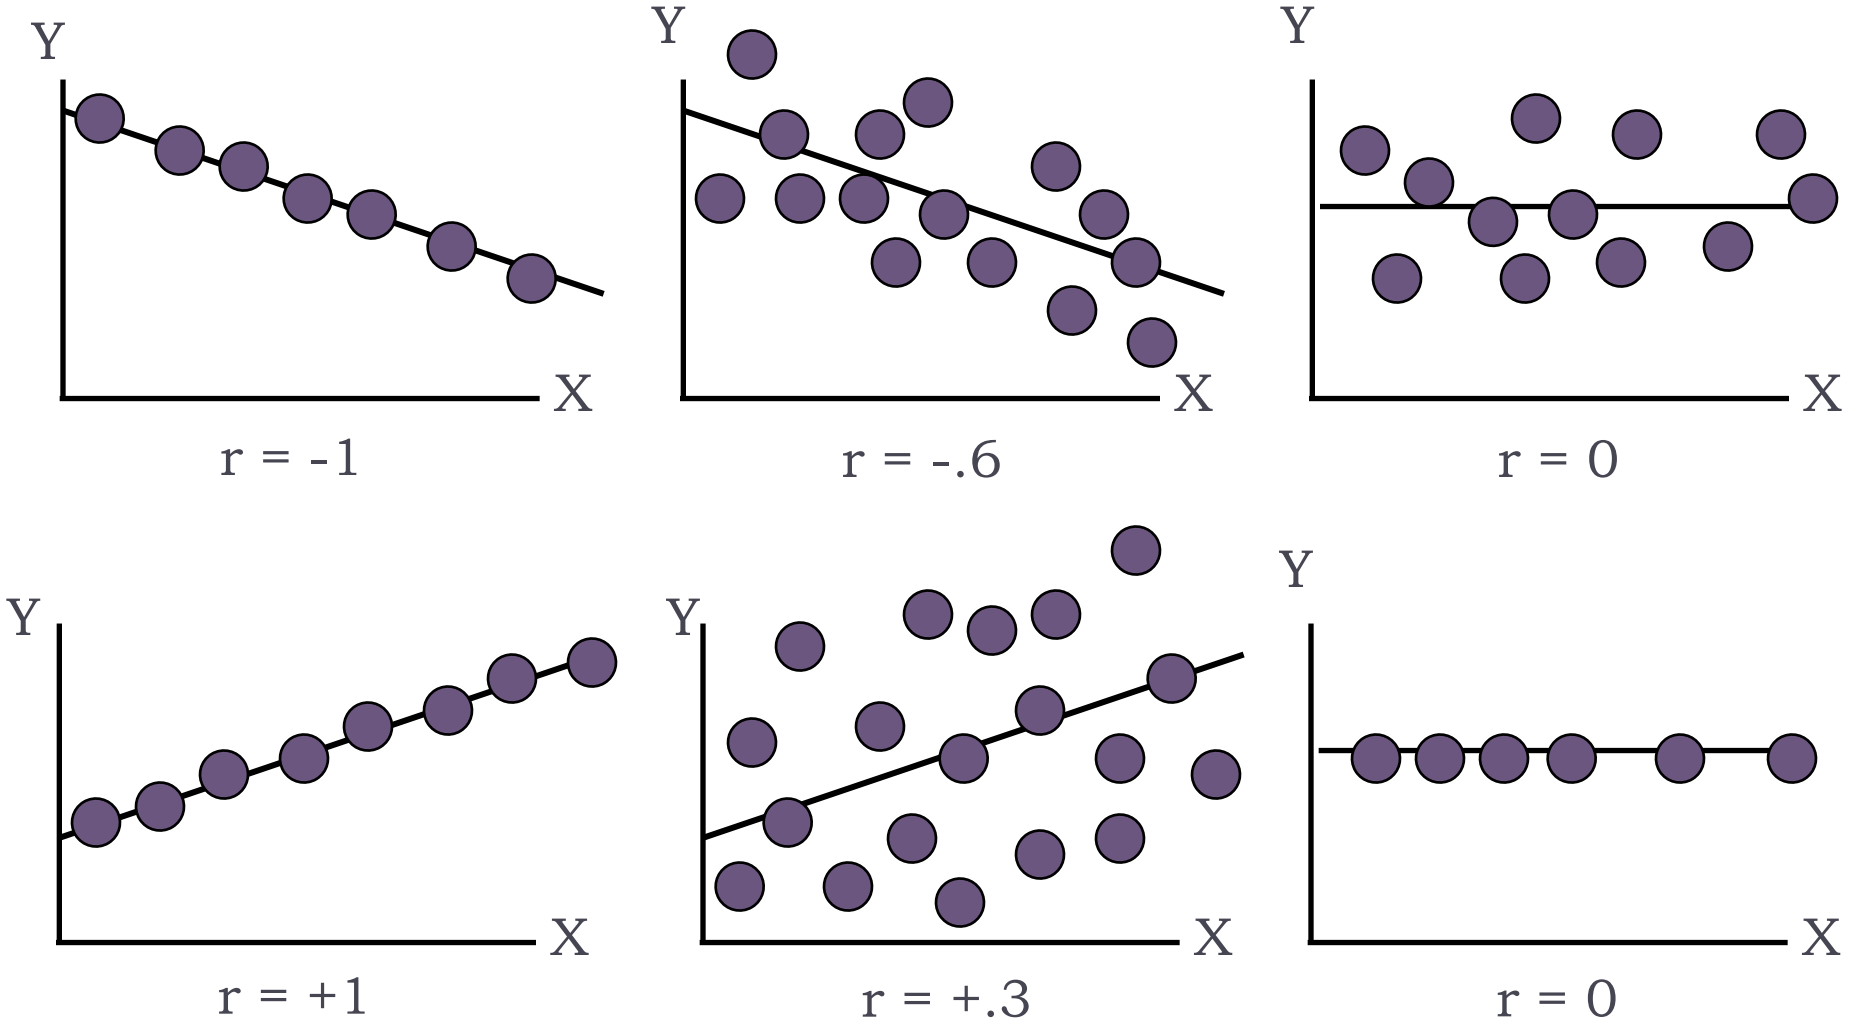
Variáveis Correlacionadas

- O índice de correlação de Pearson é uma medida normalizada de covariância.

$$r = \frac{\operatorname{cov}(x, y)}{\sqrt{\operatorname{var} x}\sqrt{\operatorname{var} y}}$$

- Varia entre -1 e +1.
- Quanto mais próximo de -1, maior a relação linear negativa.
- Quanto mais próximo de +1, maior a relação linear positiva.
- Quanto mais próximo de 0, maior a ausência de relação linear.

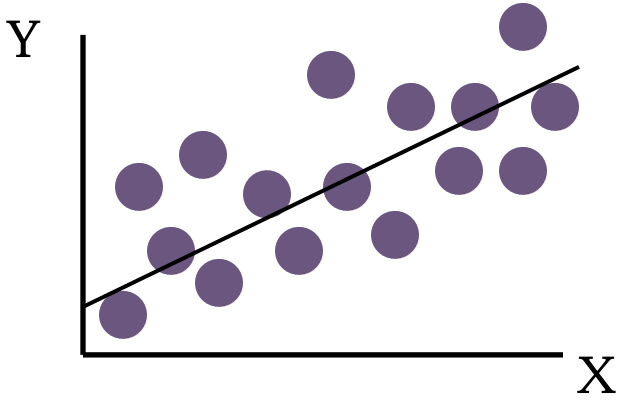
Variáveis Correlacionadas

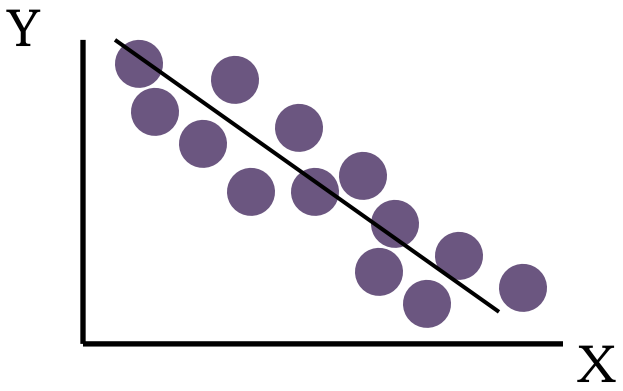


Fonte: Statistics for Managers Using Microsoft® Excel 4th Edition, 2004 Prentice-Hall

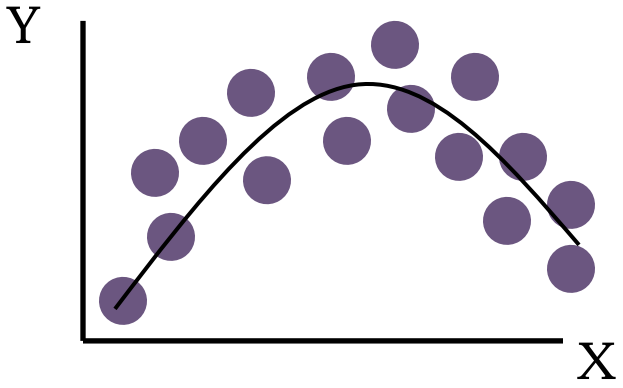
Variáveis Correlacionadas

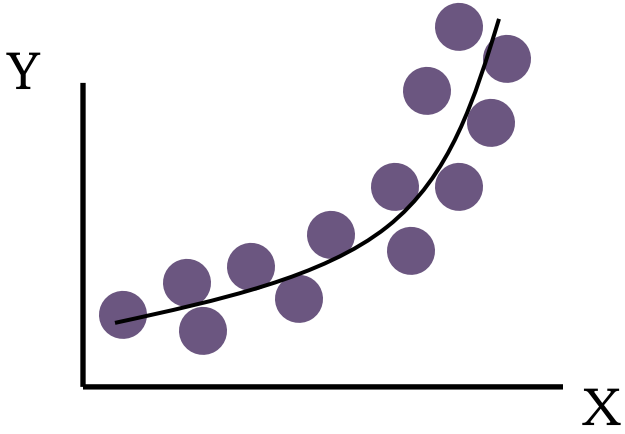
Relação Linear





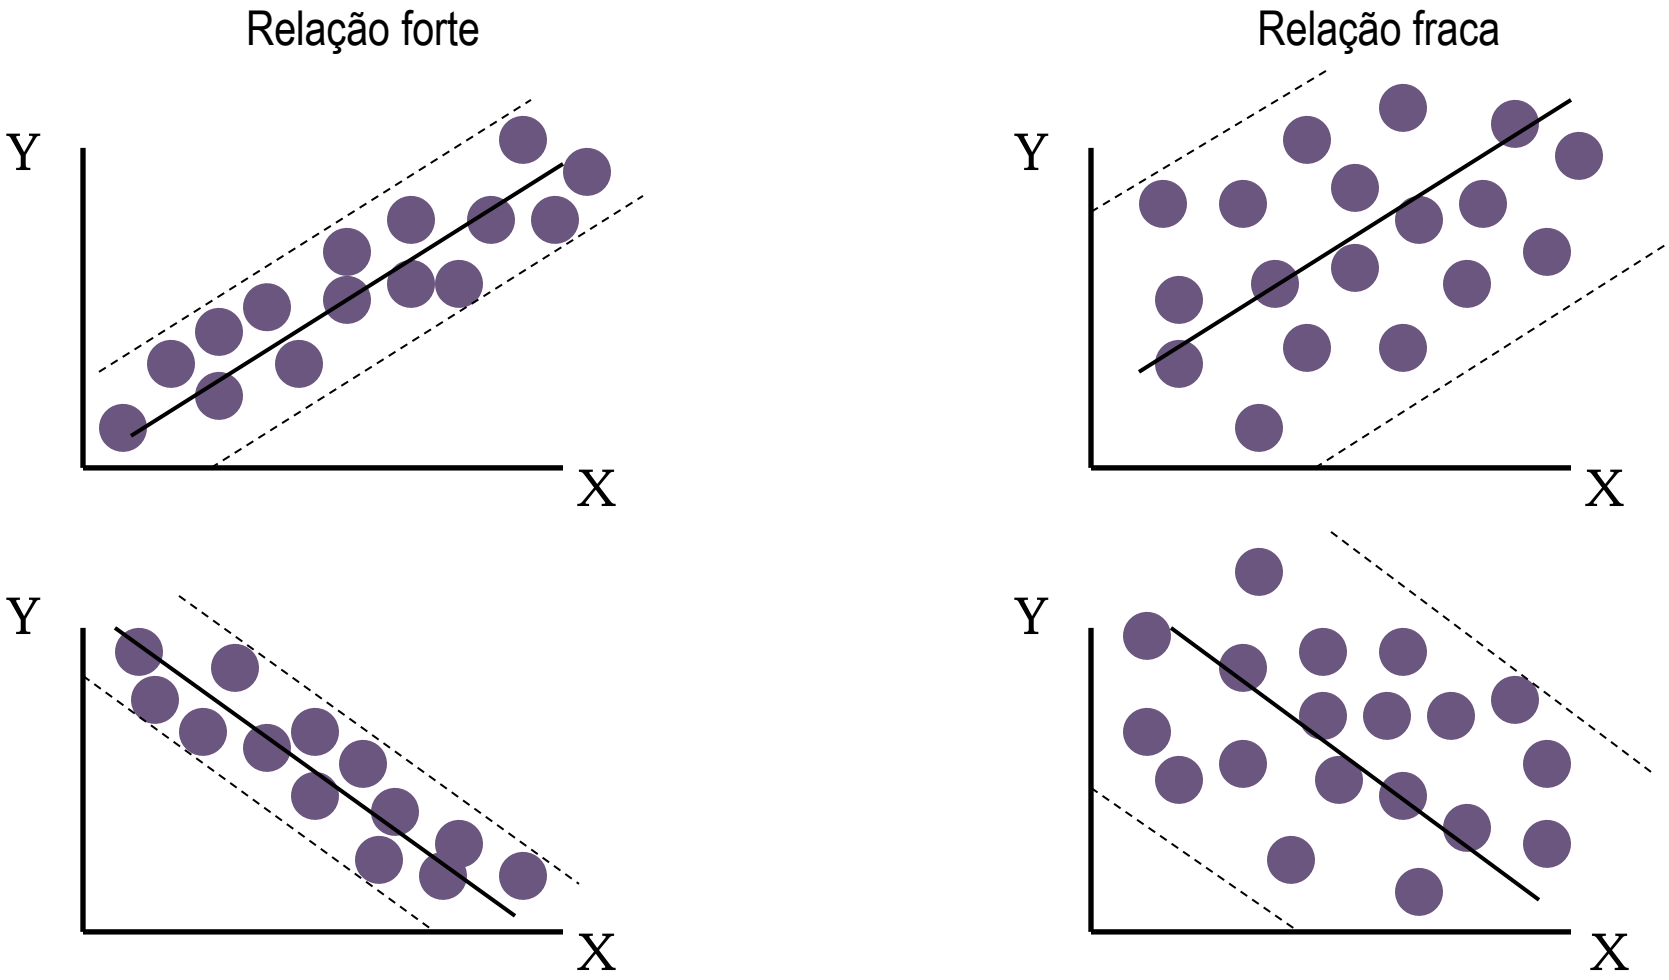
Relação não-linear





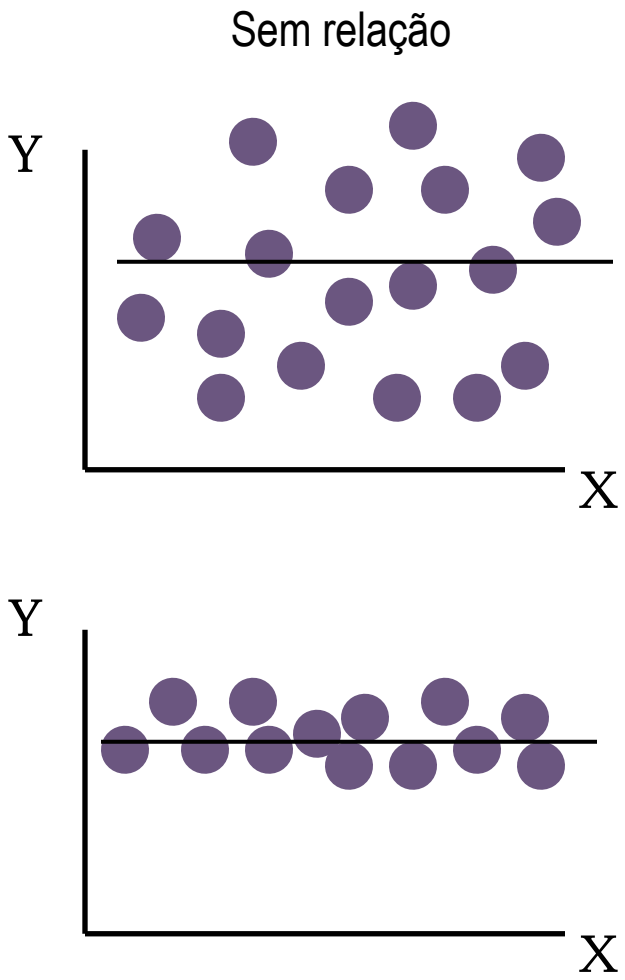
Fonte: Statistics for Managers Using Microsoft® Excel 4th Edition, 2004 Prentice-Hall

Variáveis Correlacionadas



Fonte: Statistics for Managers Using Microsoft® Excel 4th Edition, 2004 Prentice-Hall

Variáveis Correlacionadas



Fonte: Statistics for Managers Using Microsoft® Excel 4th Edition, 2004 Prentice-Hall

Regressão Linear Simples

Regressão Linear Simples
Exemplo

- Uma rede vende peças para manutenção de motores. Foram registrados os níveis de venda (“Y”) para 10 semanas (em centenas de itens), para diferentes níveis de preços (“X”), já que os preço variam segundo o valor do câmbio.

#	X	Y
1	1,3	10
2	2,0	6
3	1,7	5
4	1,5	12
5	1,6	10
6	1,2	15
7	1,6	5
8	1,4	12
9	1,0	17
10	1,1	20

Regressão Linear Simples
Exemplo

```
# Importa bibliotecas
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
```

```
Preço = [1.3, 2.0, 1.7, 1.5, 1.6, 1.2, 1.6, 1.4, 1.0, 1.1]
Vendas =[10, 6, 5, 12, 10, 15, 5, 12, 17, 20]
df = pd.DataFrame(list(zip(Preço, Vendas)), columns =['Preço','Vendas'])
print(df)
```

```
   Preço  Vendas
0    1.3      10
1    2.0       6
2    1.7       5
3    1.5      12
4    1.6      10
5    1.2      15
6    1.6       5
7    1.4      12
8    1.0      17
9    1.1      20
```

Regressão Linear Simples
Coeficiente de Correlação

#	X	Y	XY	X^2	Y^2
1	1,30	10,00	13,00	1,69	100,00
2	2,00	6,00	12,00	4,00	36,00
3	1,70	5,00	8,50	2,89	25,00
4	1,50	12,00	18,00	2,25	144,00
5	1,60	10,00	16,00	2,56	100,00
6	1,20	15,00	18,00	1,44	225,00
7	1,60	5,00	8,00	2,56	25,00
8	1,40	12,00	16,80	1,96	144,00
9	1,00	17,00	17,00	1,00	289,00
10	1,10	20,00	22,00	1,21	400,00
Soma	**14,40**	**112,00**	**149,30**	**21,56**	**1.488,00**

Regressão Linear Simples
Coeficiente de Correlação

$$r = \frac{n\sum XY - (\sum X)(\sum Y)}{\sqrt{n\sum X^2 - (\sum X)^2}\sqrt{n\sum Y^2 - (\sum Y)^2}}$$

$$= \frac{10(149{,}3) - (14{,}4)(112{,}0)}{\sqrt{10(21{,}56) - (14{,}4)^2}\sqrt{10(1.488) - (112)^2}} = -0{,}8635$$

Há correlação linear negativa

```
corr = df.corr()
print(corr)
```

```
           Preço    Vendas
Preço    1.000000 -0.863489
Vendas  -0.863489  1.000000
```

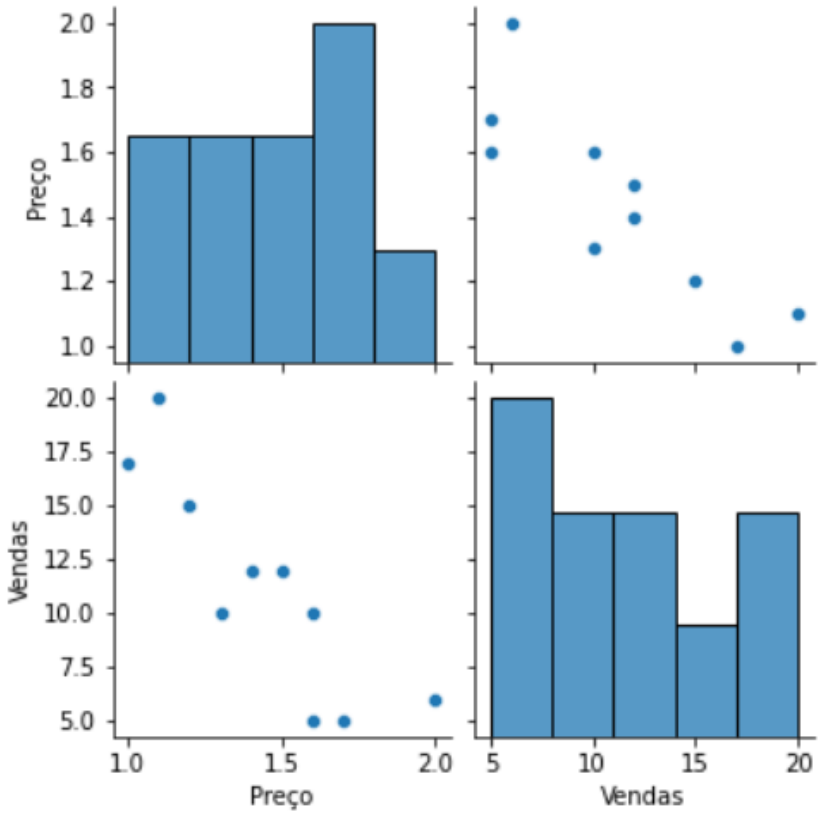
```
corr_Preço_Vendas = np.corrcoef(df.Preço, df.Vendas)[0,1]
print("Correlação entre Preço e Vendas: {:.3f}".format(corr_Preço_Vendas))
```

```
Correlação entre Preço e Vendas: -0.863
```

Regressão Linear Simples
Correlação

```
# Mostra a correção entre as variáveis
sns.pairplot(df)
```

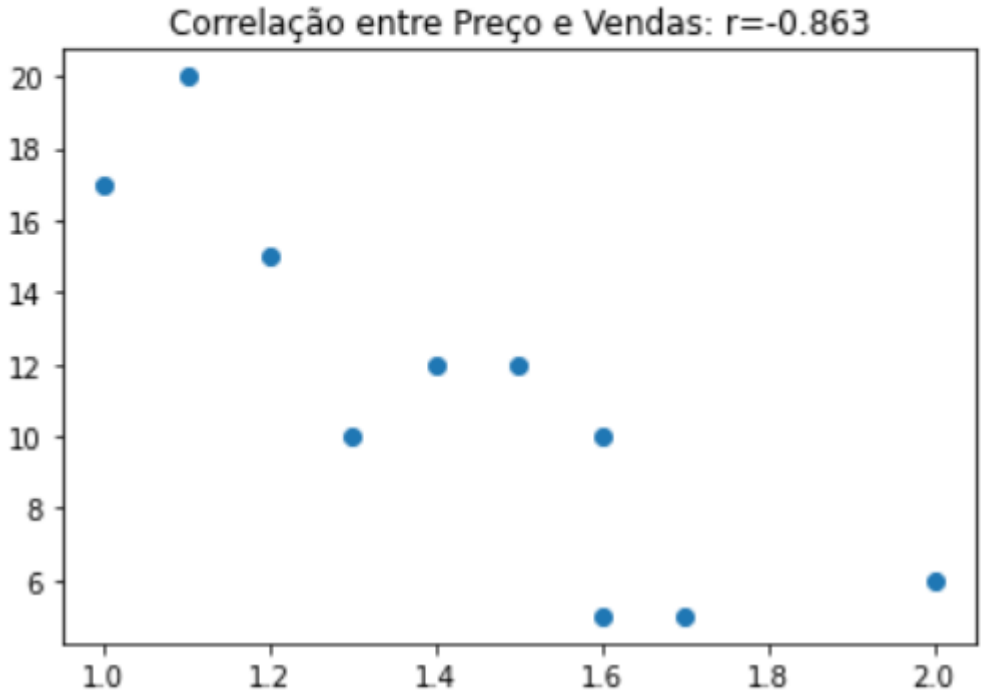
```
<seaborn.axisgrid.PairGrid at 0x2a798442100>
```



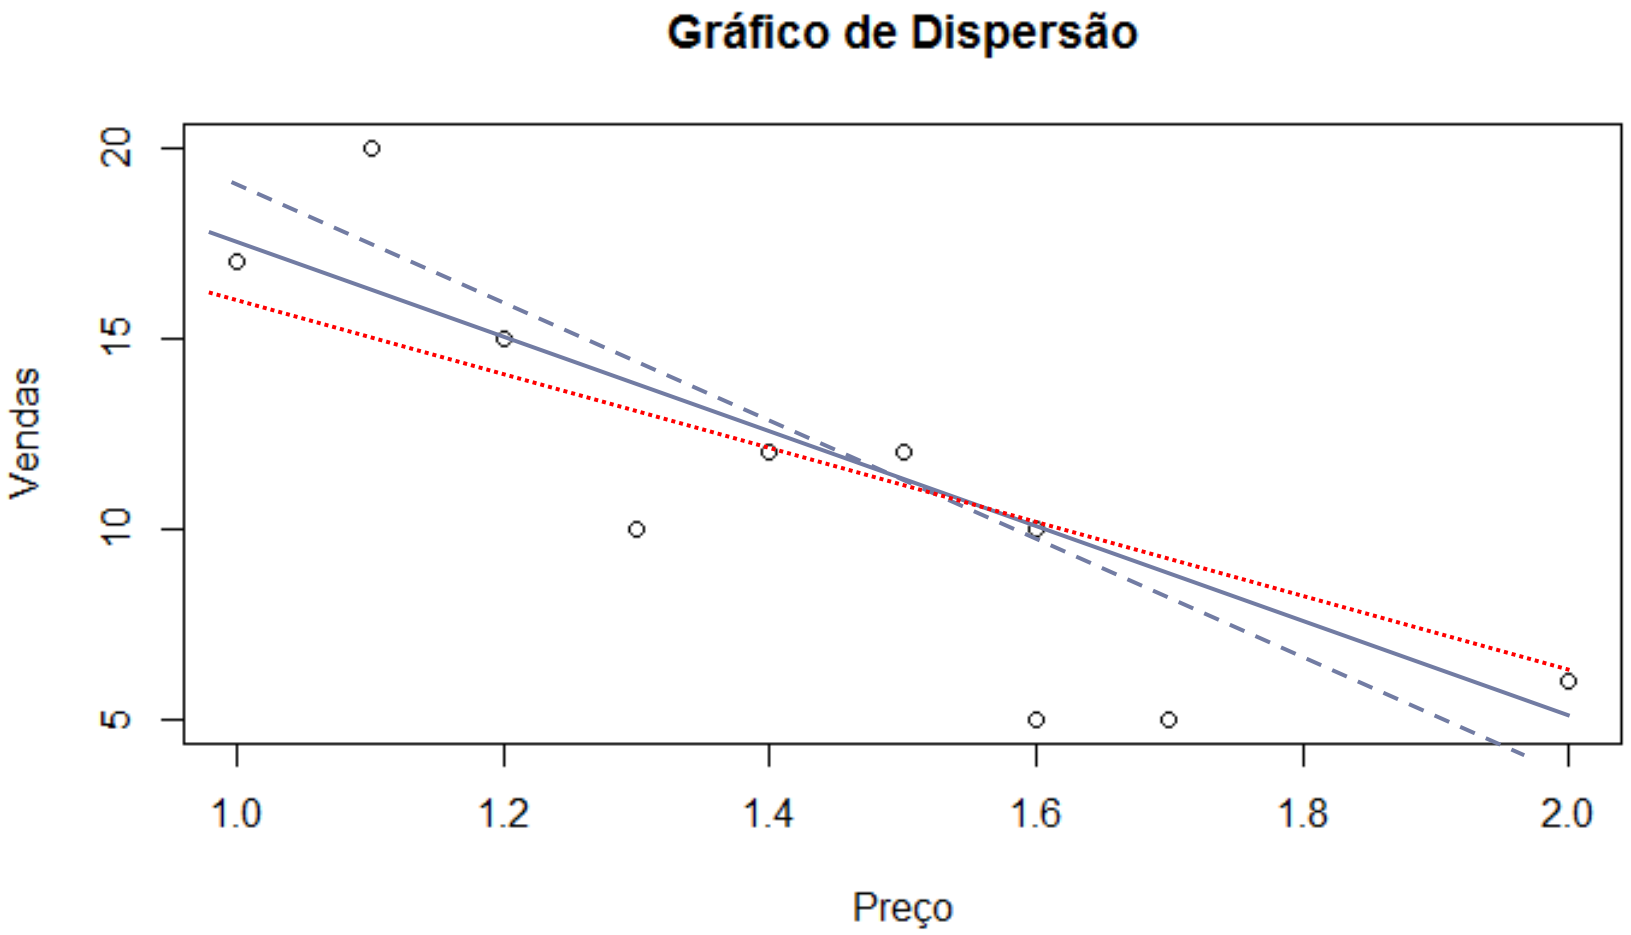
Regressão Linear Simples
Gráfico de Dispersão

```
# Visualizar a correlação entre Preço e Vendas
plt.scatter(df['Preço'], df['Vendas'])
plt.title("Correlação entre Preço e Vendas: r={:.3f}".format(corr_Preço_Vendas))
```

```
Text(0.5, 1.0, 'Correlação entre Preço e Vendas: r=-0.863')
```



Regressão Linear Simples
Determinando uma reta (curva) de regressão



Qual é a melhor reta de regressão?

Regressão Linear Simples

- Reta (curva) de Regressão: $\hat{Y} = b_0 + bX$
- A melhor reta de regressão é aquela que minimiza a soma das diferenças quadráticas (distância) entre os pontos e a reta – *método dos mínimos quadrados:*

$$b = \frac{n\sum XY - \sum X \sum Y}{n\sum X^2 - (\sum X)^2} \qquad b_0 = \frac{\sum Y}{n} - \frac{b\sum X}{n}$$

Regressão Linear Simples

- Reta (curva) de Regressão: $\hat{Y} = b_0 + bX$
- A melhor reta de regressão é aquela que minimiza a soma das diferenças quadráticas (distância) entre os pontos e a reta – *método dos mínimos quadrados:*

$$\min \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \min \sum_{i=1}^{n} (y_i - (b_0 + bx_i))^2$$

- A minimização desta função resulta em:

$$b = \frac{n \sum XY - \sum X \sum Y}{n \sum X^2 - (\sum X)^2}$$

$$b_0 = \frac{\sum Y}{n} - \frac{b \sum X}{n}$$

Regressão Linear Simples

```
# Importa biblioteca
from sklearn.linear_model import LinearRegression

# Variáveis do problema (arrays)
# reshape(-1,1) para transformar em uma matriz n x 1 (em caso contrário, será uma matriz 1 x n).
pre = df['Preço'].values.reshape(-1,1)
ven = df['Vendas'].values.reshape(-1,1)

# Inicializa a realiza a regressão
model_lr = LinearRegression()
model_lr.fit(pre, ven)

# Mostra o modelo de regressão
print('Coeficiente de regressão: %.3f' %model_lr.coef_)
print('Intercepta: %.3f' %model_lr.intercept_)
print('Equação de regressão: y= %.3fx + %.3f' % (model_lr.coef_ , model_lr.intercept_))

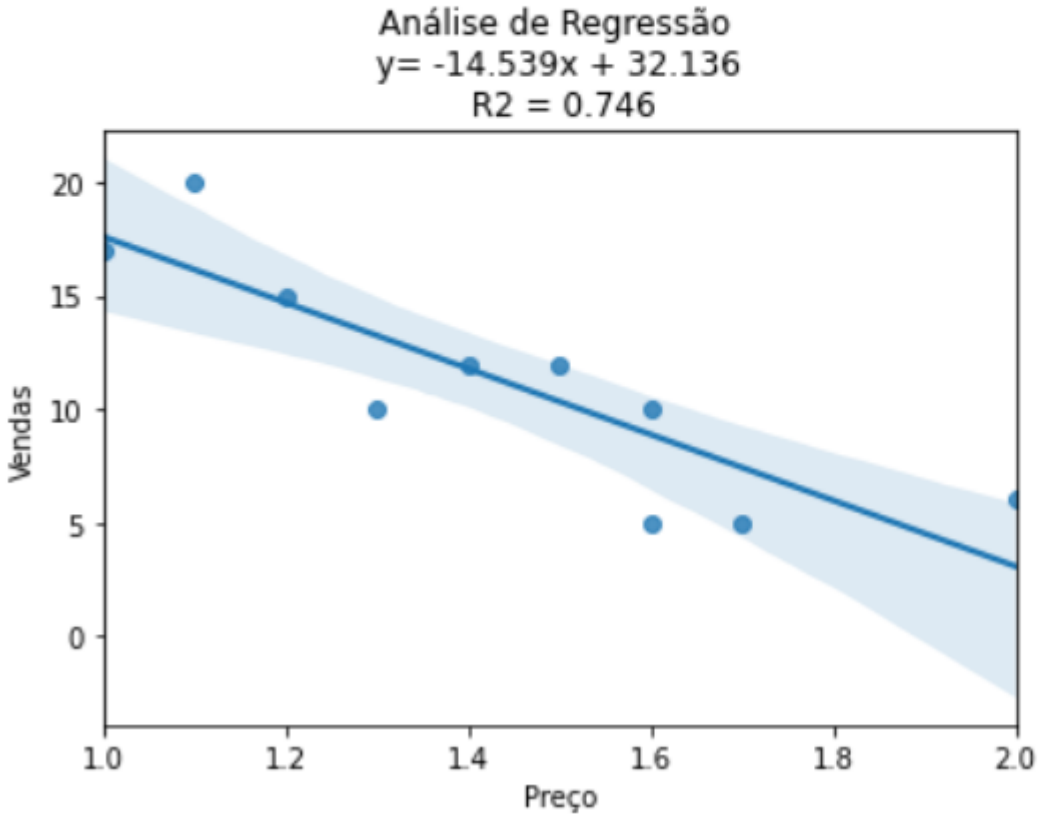
# Imprime R^2
print("R^2 = {:.3f}".format(model_lr.score(pre, ven)))
```

```
Coeficiente de regressão: -14.539
Intercepta: 32.136
Equação de regressão: y= -14.539x + 32.136
R^2 = 0.746
```

Regressão Linear Simples
Plotando a Curva de Regressão

```
# Visualiza a Regressão Linear Simpels
sns.regplot(x="Preço", y="Vendas", data=df, ci=95)
plt.title("Análise de Regressão \n y= %.3fx + %.3f \n R2 = %.3f" %
          (model_lr.coef_ , model_lr.intercept_, model_lr.score(pre, ven)))
```

```
Text(0.5, 1.0, 'Análise de Regressão \n y= -14.539x + 32.136 \n R2 = 0.746')
```



Regressão Linear Simples

```
# Importa as Bibliotecas
import statsmodels.api as sm
from statsmodels.formula.api import ols
```

```
# Regressão - Variável Independente Preço
model_1 = ols('Vendas ~ Preço', df).fit()
print(model_1.summary())
```

Regressão Linear Simples

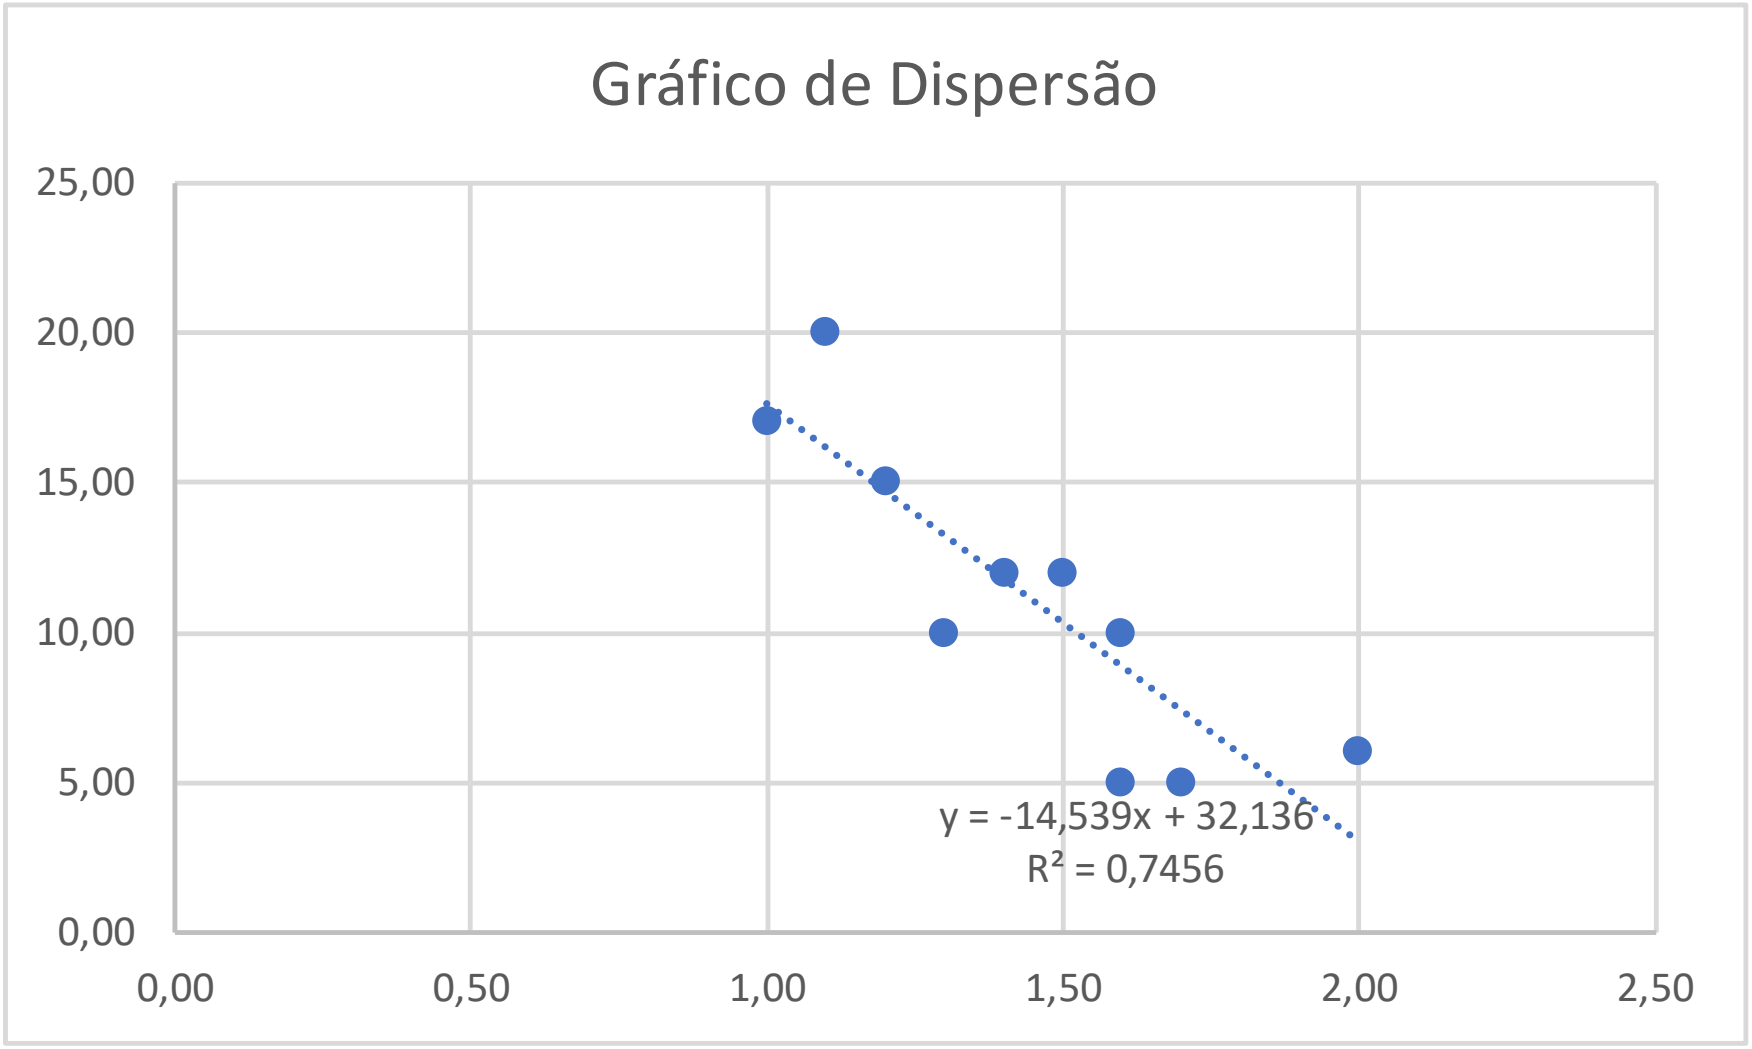
OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.746
Model:	OLS	Adj. R-squared:	0.714
Method:	Least Squares	F-statistic:	23.45
Date:	Wed, 12 Oct 2022	Prob (F-statistic):	0.00128
Time:	17:14:39	Log-Likelihood:	-23.100
No. Observations:	10	AIC:	50.20
Df Residuals:	8	BIC:	50.81
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	32.1359	4.409	7.289	0.000	21.970	42.302
Preço	-14.5388	3.002	-4.842	0.001	-21.462	-7.615

Omnibus:	0.546	Durbin-Watson:	2.345
Prob(Omnibus):	0.761	Jarque-Bera (JB):	0.518
Skew:	-0.120	Prob(JB):	0.772
Kurtosis:	1.911	Cond. No.	10.9

Regressão Linear Simples
Plotando a Curva de Regressão (Excel)

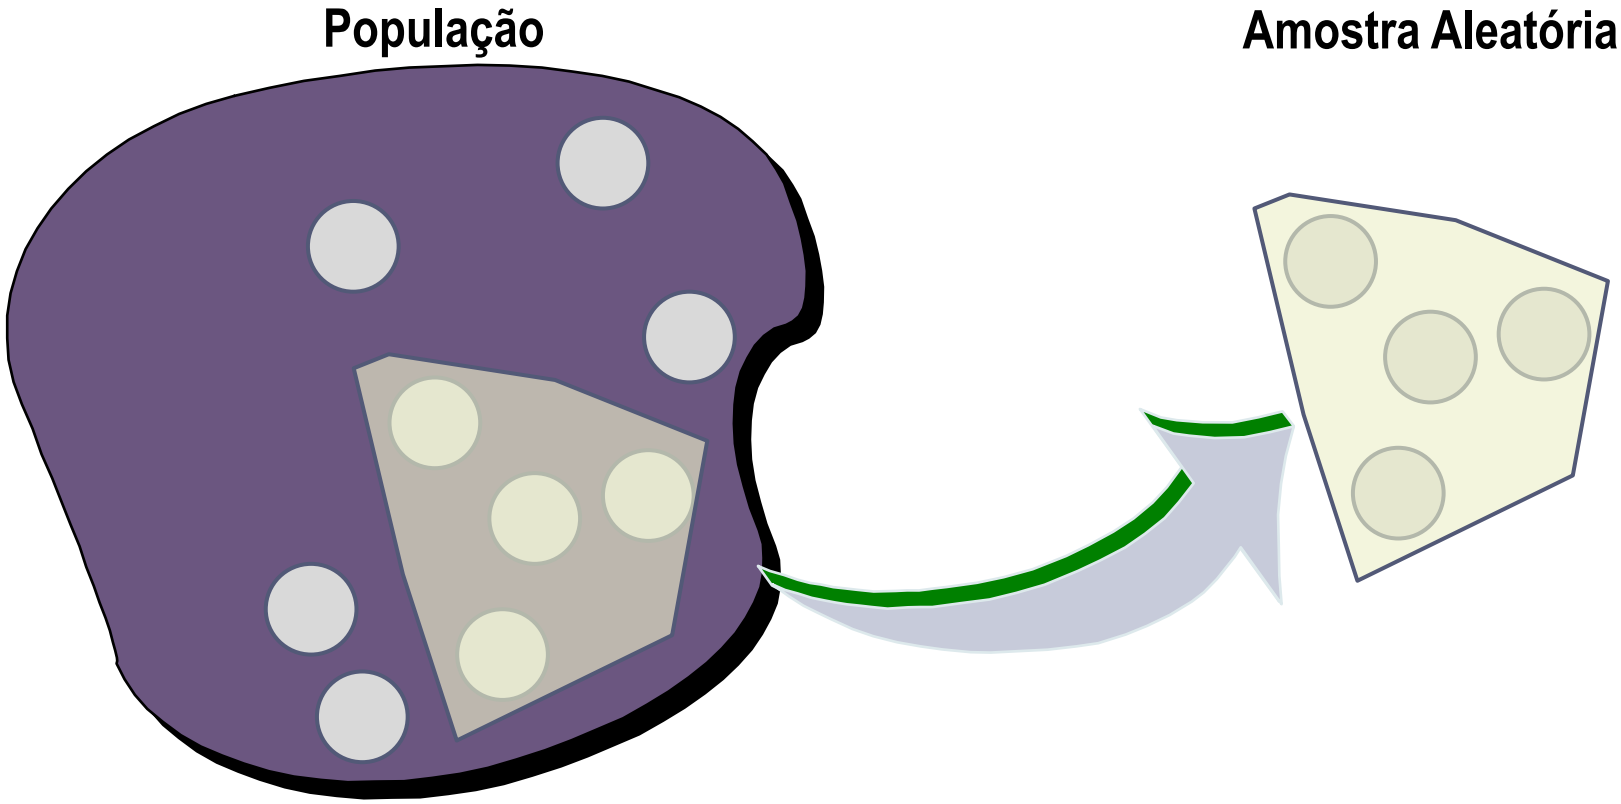


Avaliação do Modelo

Regressão Linear Simples

- É importante observar que a regressão linear elaborada baseia-se em **dados amostrais**.
- Se a amostra for diferente (ou maior), a equação de regressão poderá ser diferente.
- Assim, para a regressão realizada existe um erro associado, que passará ser analisado.

Regressão Linear Simples

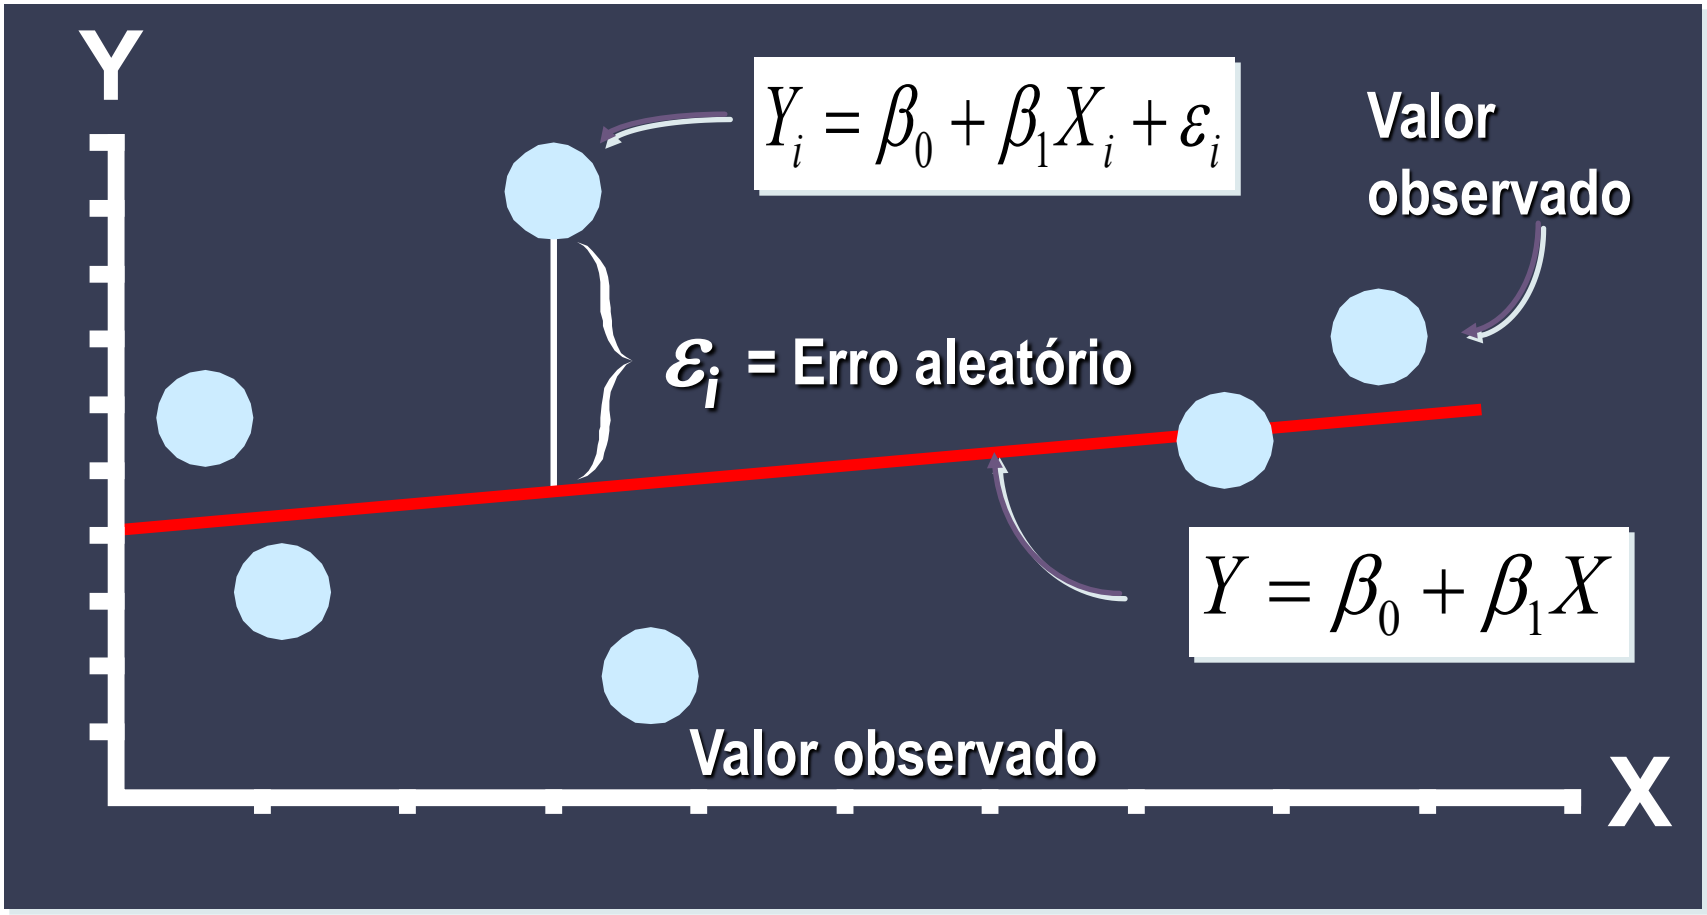


$$Y = \beta_0 + \beta X \qquad \hat{Y} = b_0 + bX$$

$$Y_i = \beta_0 + \beta X_i + \varepsilon_i \qquad Y_i = b_0 + bX_i + e_i$$

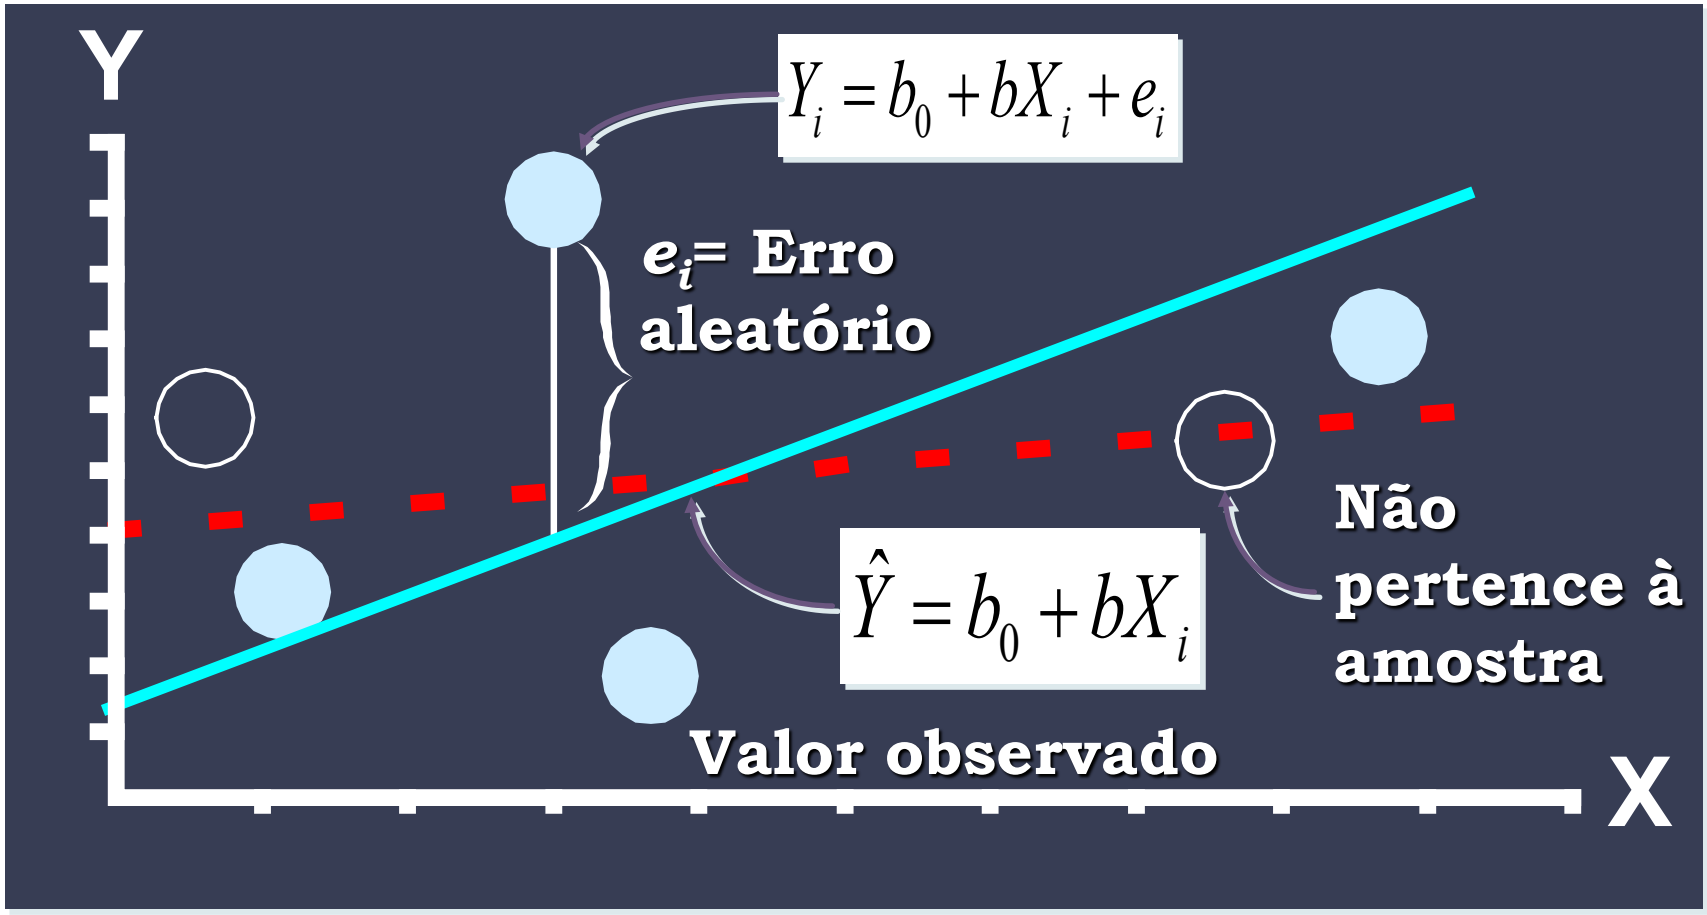
Adaptado de https://msu.edu/~fuw/teaching/Fu_Ch11_linear_regression.ppt

Regressão Linear Simples - População



Adaptado de https://msu.edu/~fuw/teaching/Fu_Ch11_linear_regression.ppt

Regressão Linear Simples - Amostra



Adaptado de https://msu.edu/~fuw/teaching/Fu_Ch11_linear_regression.ppt

1. Soma dos Erros Quadráticos

- Soma dos erros quadráticos (SSE - *sum of squares for errors*), é a diferença entre os pontos e a curva de regressão.
- Permite aferir quanto que a curva se adere aos dados.

$$SSE = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

1. Soma dos Erros Quadráticos

#	X	Y	XY	X^2	Y^2	$Y - \hat{Y}$	$(Y - \hat{Y})^2$
1	1,30	10,00	13,00	1,69	100,00	-3,24	10,47
2	2,00	6,00	12,00	4,00	36,00	2,94	8,65
3	1,70	5,00	8,50	2,89	25,00	-2,42	5,86
4	1,50	12,00	18,00	2,25	144,00	1,67	2,80
5	1,60	10,00	16,00	2,56	100,00	1,13	1,27
6	1,20	15,00	18,00	1,44	225,00	0,31	0,10
7	1,60	5,00	8,00	2,56	25,00	-3,87	15,01
8	1,40	12,00	16,80	1,96	144,00	0,22	0,05
9	1,00	17,00	17,00	1,00	289,00	-0,60	0,36
10	1,10	20,00	22,00	1,21	400,00	3,86	14,87
Soma	**14,40**	**112,00**	**149,30**	**21,56**	**1.488,00**		**59,425**

SSE

2. Erro Padrão da Estimativa

- O erro padrão da estimativa consiste no valor padrão pelo qual o valor real difere do valor estimado pela regressão.
- O erro médio é zero.
- Se o erro padrão σ_ε for baixo, os erros tenderão a ficar próximos de zero, indicando que o modelo de regressão se adere aos dados. Também indicará que o uso de um modelo linear é válido.
- Um estimador de σ_ε pode ser dado por s_ε.

2. Erro Padrão da Estimativa

$$s_{y.x} = s_{\varepsilon} = \sqrt{\frac{\sum\left(Y - \hat{Y}\right)^2}{n-2}} = \sqrt{\frac{SSE}{n-2}}$$

- $s_{\varepsilon} = \sqrt{\frac{59{,}425}{8}} = 2{,}725$

3. Teste de Hipótese Coeficiente Angular

- Quando não houver relação linear entre duas variáveis, a curva de regressão deve ser uma reta horizontal (coeficiente angular = 0).
- Inferência sobre β por meio de um teste de hipótese em b:

$$H_0: \beta = 0$$
$$H_1: \beta \neq 0$$

- A estatística de teste é:

$$t = \frac{b - \beta}{s_b}, \qquad s_b = \frac{s_\varepsilon}{\sqrt{\sum (X - \bar{X})^2}}$$

3. Teste de Hipótese Coeficiente Angular

- Sendo o erro normalmente distribuído, a estatística segue a distribuição *t* de Student, com *n*-2 graus de liberdade.
- $s_b = \frac{s_\varepsilon}{\sqrt{\sum(X-\bar{X})^2}} = \frac{2{,}725}{\sqrt{0{,}824}} = 3{,}002$
- $t = \frac{b-\beta}{s_b} = \frac{-14{,}539-0}{3{,}002} = -4{,}843$
- Estatística de referência, para nível de significância α=5% e α=1%, com 8 graus de liberdade: -2.306004 e -3.355387

```
import scipy.stats
scipy.stats.t.ppf(0.025, 8)
```

```
-2.306004135033371
```

- Rejeito H_0. O coeficiente angular é diferente de 0.

4. Análise de Variação dos Resíduos

- É importante conhecer qual é a variação na variável dependente Y que está associada à variação na variável dependente X.
- Vamos considerar a variação dos valores de Y em torno de sua média $\bar{Y}$ (chamaremos de SSTO - *total sum of squares*).

$$SSTO = \sum_{i=1}^{n} (y_i - \bar{y}_i)^2$$

4. Análise de Variação dos Resíduos

- Vamos separar o valor de SSTO em duas componentes: uma será a variação dos valores previstos pelo modelo de regressão $\hat{Y}$ em relação à média $\bar{Y}$ (SSR – *sum of squares due regression*); a outra medirá a variação dos valores em relação aos valores previstos (SSE – *sum of squares due to error*), que é uma variação não explicada pelo modelo.

4. Análise de Variação dos Resíduos

$$SSTO = \sum_{i=1}^{n} (y_i - \bar{y}_i)^2$$

$$SSTO = \sum_{i=1}^{n} (y_i - \bar{y}_i)^2 = (y_i - \hat{y}_i + \hat{y}_i - \bar{y}_i)^2$$

$$SSR = \sum_{i=1}^{n} (\hat{y}_i - \bar{y}_i)^2 \qquad SSE = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

$$= \sum_{i=1}^{n} (\hat{y}_i - \bar{y}_i)^2 + \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = SSR + SSE$$

- OBS: relação válida já que a soma dos demais termos é nula.

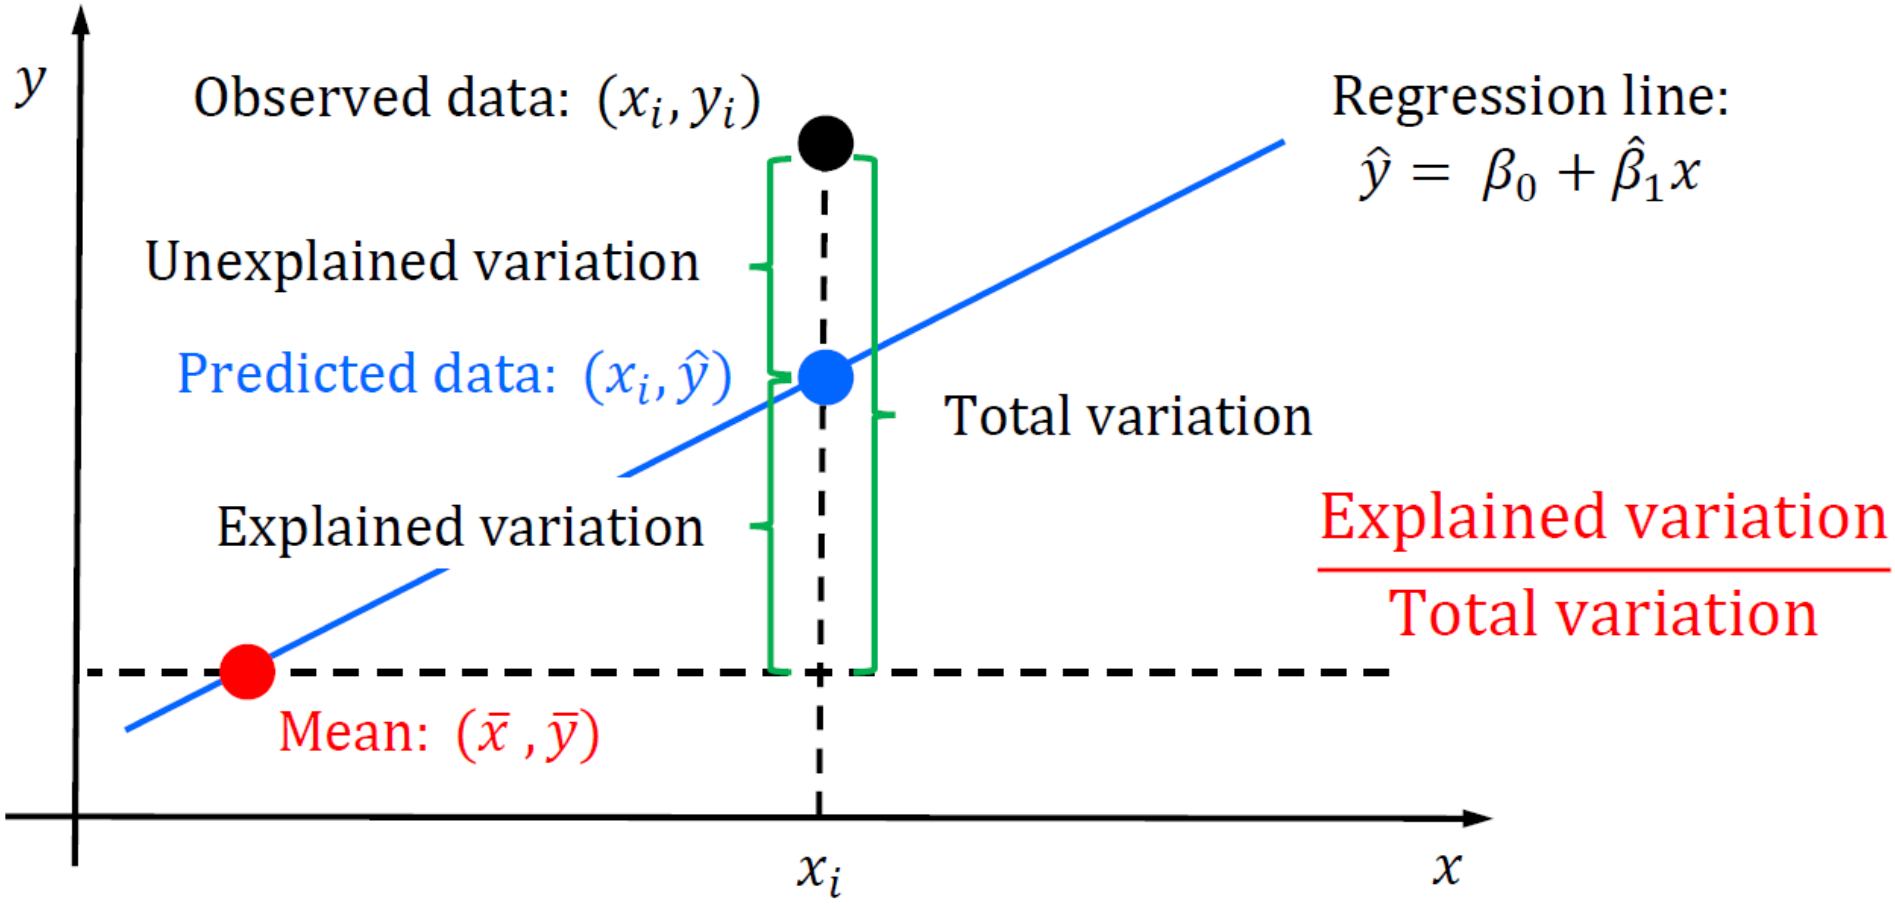
4. Análise de Variação dos Resíduos

- **Coeficiente de determinação**

$$r^2 = 1 - \frac{SSE}{SSTO} = \frac{SSR}{SSTO}$$

- r^2 indica a proporção da variação em Y que pode ser explicada pela variação em X.
- $r^2 = (-0{,}8635)^2 = 0{,}75$
- Aproximadamente 75% das vendas podem ser explicadas pela variação de preço, enquanto que 25% das vendas são atribuídas a outros fatores.

4. Análise de Variação dos Resíduos



5. Usando o Modelo para Previsão

- Para o preço X=1,63, prever a quantidade a ser vendida.
- $\hat{Y} = b_0 + bX$ = $32{,}136 - 14{,}539(1{,}63) = 8{,}440$

6. Erro da Previsão

$$s_f = s_\varepsilon \sqrt{1 + \frac{1}{n} + \frac{(X - \bar{X})^2}{\sum (X - \bar{X})^2}}$$

- Intervalo de previsão: $\hat{Y} \pm z s_f$
- Para usar a estatística z as seguintes hipóteses devem ser feitas:
  - Amostra $n \geq 30$.
  - Os valores de *Y* são normalmente distribuídos em relação à linha de regressão.
  - A dispersão (variância) dos valores de Y em relação à linha de regressão é constante.
  - Os erros são independentes uns dos outros.
  - A regressão é linear.

6. Erro da Previsão

$$s_f = s_{y.x}\sqrt{1 + \frac{1}{n} + \frac{(X - \bar{X})^2}{\sum(X - \bar{X})^2}}$$

- Para o exemplo dado, em que n=10, aproximaremos pela distribuição *t* de Student: $\hat{Y} \pm t s_f$
- A estatística *t* pode ser calculada como (Excel), para nível de significância $\alpha = 5\%$, teste bi-caudal, com $n = 10 - 2 = 8$ graus de liberdade: =INV.T(2,5%;8)

```
import scipy.stats
scipy.stats.t.ppf(0.025, 8)
```

```
-2.306004135033371
```

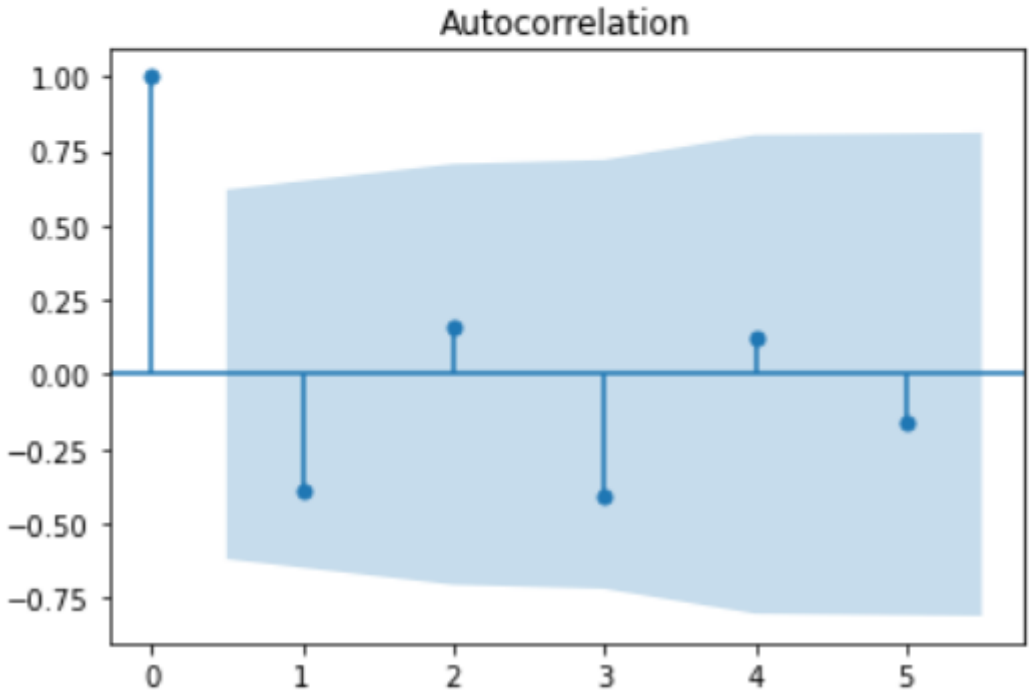
6. Erro da Previsão

- $\hat{Y} \pm ts_f = 8{,}44 \pm 2{,}306(2{,}92) = 8{,}44 \pm 6{,}71$
- Com 95% de certeza a previsão de vendas irá variar entre 1,73 a 15,15.

7. Análise de Resíduos

```
import pandas as pd
from statsmodels.graphics.tsaplots import plot_acf
from statsmodels.graphics.tsaplots import acf

residuos = [-3.24, 2.94, -2.42, 1.67, 1.13, 0.31, -3.87, 0.22, -0.60, 3.86]
df_res = pd.DataFrame (residuos, columns = ['Resíduos'])
plot_acf(df_res, lags=5, alpha = 0.05)
```



Regressão Linear Multivariada

Regressão Linear – Exemplo Introdutório

- No exemplo introdutório usado em regressão linear simples, buscou-se uma expressão linear, baseada na variável independente ‘preço de venda’ (X), a fim de explicar o nível de vendas (Y).

#	X	Y
1	1,3	10
2	2,0	6
3	1,7	5
4	1,5	12
5	1,6	10
6	1,2	15
7	1,6	5
8	1,4	12
9	1,0	17
10	1,1	20

Regressão Linear – Exemplo Introdutório

- Para este exemplo, o coeficiente de determinação (r^2), que indica o percentual da variação em Y que pode ser explicada pela variação em X, era de $(-0{,}8635)^2 = 0{,}75$.
- Assim, existe 25% de variação em Y que não é consequência da (não é explicada pela) variação em X.

Regressão Linear – Exemplo Introdutório

- Uma nova variável independente será introduzida na análise, e consiste na verba gasta em publicidade (milhares de reais).

#	Preço	Publicidade	Vendas
1	1,3	9,0	10
2	2,0	7,0	6
3	1,7	5,0	5
4	1,5	14,0	12
5	1,6	15,0	10
6	1,2	12,0	15
7	1,6	6,0	5
8	1,4	10,0	12
9	1,0	15,0	17
10	1,1	21,0	20

Regressão Linear Multivariada
Leitura de dados

Regressão Linear Multivariada

```
# Importa bibliotecas
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
```

```
Preço = [1.3, 2.0, 1.7, 1.5, 1.6, 1.2, 1.6, 1.4, 1.0, 1.1]
Publicidade = [9.0, 7.0, 5.0, 14.0, 15.0, 12.0, 6.0, 10.0, 15.0, 21.0]
Vendas = [10, 6, 5, 12, 10, 15, 5, 12, 17, 20]
df = pd.DataFrame(list(zip(Preço, Publicidade, Vendas)), columns =['Preço','Publicidade','Vendas'])
print(df)
```

```
   Preço  Publicidade  Vendas
0    1.3          9.0      10
1    2.0          7.0       6
2    1.7          5.0       5
3    1.5         14.0      12
4    1.6         15.0      10
5    1.2         12.0      15
6    1.6          6.0       5
7    1.4         10.0      12
8    1.0         15.0      17
9    1.1         21.0      20
```

Regressão Linear Multivariada
Coeficiente de Correlação

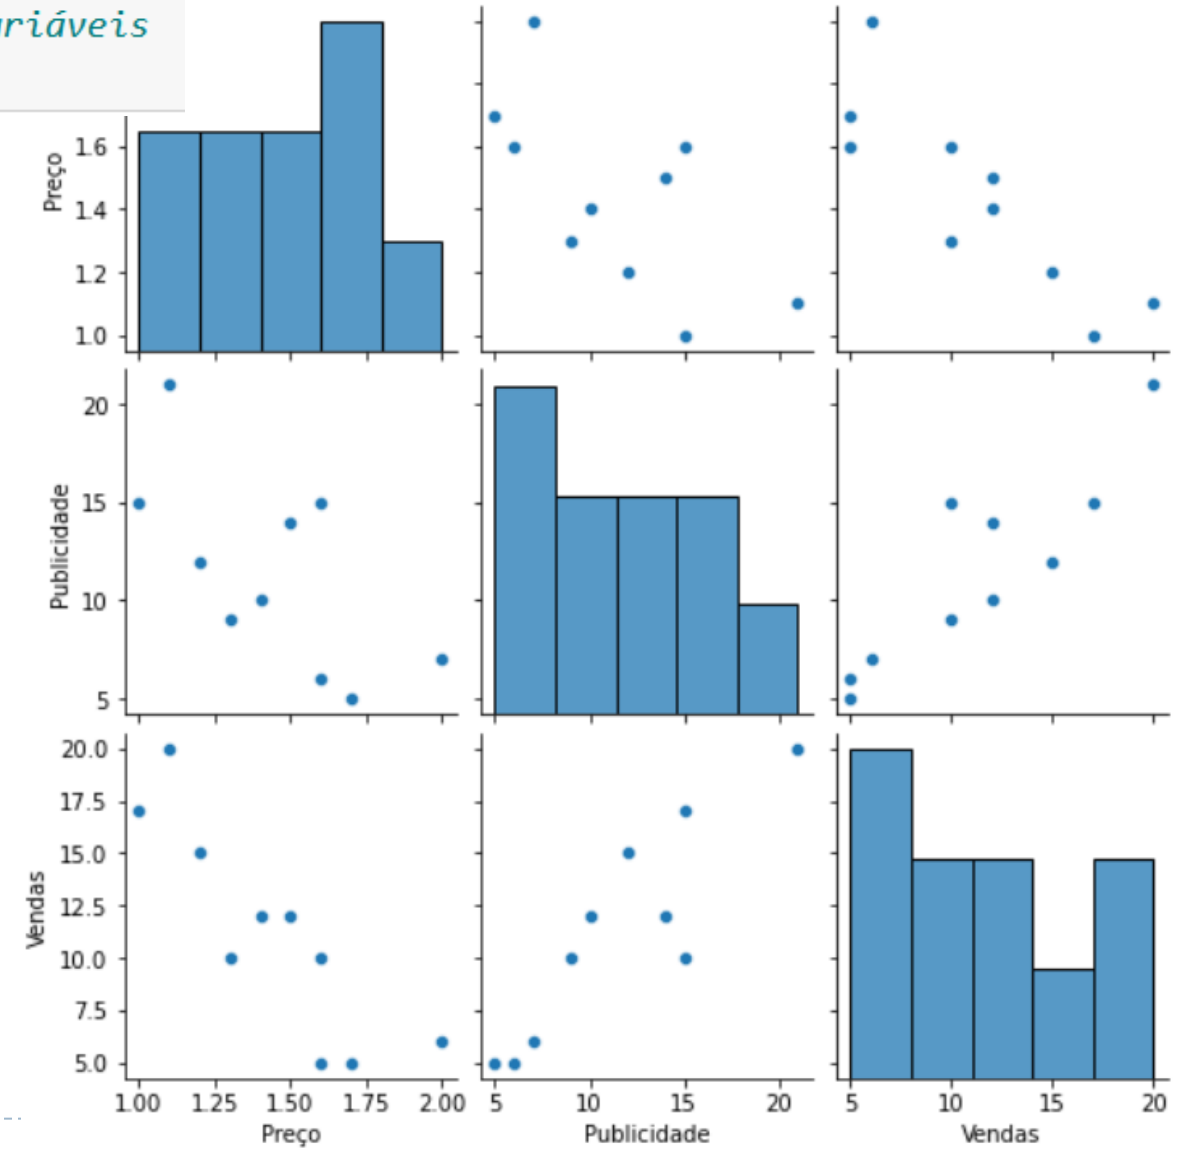
```
corr = df.corr()
print(corr)
```

```
                Preço  Publicidade    Vendas
Preço        1.000000    -0.654490 -0.863489
Publicidade -0.654490     1.000000  0.891497
Vendas      -0.863489     0.891497  1.000000
```

- OBS: o valor gasto com publicidade tem correlação linear positiva (~89%) com o nível de vendas; o preço tem correlação negativa (~-86%) com o nível de vendas. São correlações coerentes com o problema em questão.

Regressão Linear Multivariada
Diagrama de Dispersão

```
# Mostra a correção entre as variáveis
sns.pairplot(df)
```



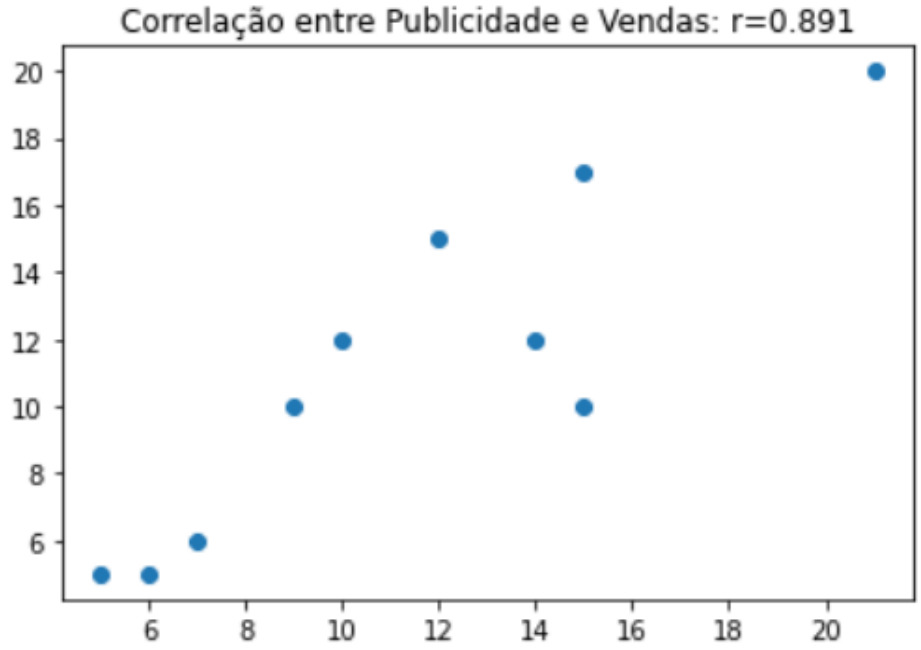
Regressão Linear Multivariada
Diagrama de Dispersão

```
corr_Publicidade_Vendas = np.corrcoef(df.Publicidade, df.Vendas)[0,1]
print("Correlação entre Publicidade e Vendas: {:.3f}".format(corr_Publicidade_Vendas))
```

```
Correlação entre Publicidade e Vendas: 0.891
```

```
# Visualizar a correlação entre Preço e Vendas
plt.scatter(df['Publicidade'], df['Vendas'])
plt.title("Correlação entre Publicidade e Vendas: r={:.3f}".format(corr_Publicidade_Vendas))
```

```
Text(0.5, 1.0, 'Correlação entre Publicidade e Vendas: r=0.891')
```



Regressão Linear Multivariada

- Reta (curva) de Regressão: $\hat{Y} = b_0 + b_2 X_2 + b_3 X_3$
- A melhor regressão é aquela que minimiza a soma das diferenças quadráticas (distância) entre os pontos e a reta – *método dos mínimos quadrados*, e deriva da resolução do sistema abaixo:

$$\sum_i Y_i = n b_0 + b_2 \sum_i X_{2_i} + b_3 \sum_i X_{3_i}$$

$$\sum_i X_{2_i} Y_i = b_0 \sum_i X_{2_i} + b_2 \sum_i X_{2_i}^2 + b_3 \sum_i X_{2_i} X_{3_i}$$

$$\sum_i X_{3_i} Y_i = b_0 \sum_i X_{3_i} + b_2 \sum_i X_{2_i} X_{3_i} + b_3 \sum_i X_{3_i}^2$$

Regressão Linear Multivariada
Coeficiente de Correlação

#	Y	X_2	X_3	X_2Y	X_3Y	X_2X_3	Y^2	X_2^2	X_3^2
1	10,0	1,3	9,0	13,0	90,0	11,7	100,0	1,7	81,0
2	6,0	2,0	7,0	12,0	42,0	14,0	36,0	4,0	49,0
3	5,0	1,7	5,0	8,5	25,0	8,5	25,0	2,9	25,0
4	12,0	1,5	14,0	18,0	168,0	21,0	144,0	2,3	196,0
5	10,0	1,6	15,0	16,0	150,0	24,0	100,0	2,6	225,0
6	15,0	1,2	12,0	18,0	180,0	14,4	225,0	1,4	144,0
7	5,0	1,6	6,0	8,0	30,0	9,6	25,0	2,6	36,0
8	12,0	1,4	10,0	16,8	120,0	14,0	144,0	2,0	100,0
9	17,0	1,0	15,0	17,0	255,0	15,0	289,0	1,0	225,0
10	20,0	1,1	21,0	22,0	420,0	23,1	400,0	1,2	441,0
Soma	**112,00**	**14,40**	**114,00**	**149,30**	**1.480,00**	**155,30**	**1.488,00**	**21,56**	**1.522,00**
Média	**11,2**	**1,44**	**11,4**						

Regressão Linear Multivariada

- Sistema:

$$112 = 10b_0 + 14.4b_2 + 114b_3$$
$$149.3 = 14.4b_0 + 21.56b_2 + 155.3b_3$$
$$1480 = 114b_0 + 155.3b_2 + 1522b_3$$

- O sistema tem solução, cujos valores são: $b_0 = 16.4064; b_2 = -8.2476; b_3 = 0.5851.$

$$\hat{Y} = 16.4064 - 8.2476X_2 + 0.5851X_3$$

Regressão Linear Multivariada

```
# Importa as Bibliotecas
import statsmodels.api as sm
from statsmodels.formula.api import ols

# Regressão - Variável Independente Preço
model_1 = ols('Vendas ~ Preço + Publicidade', df).fit()
print(model_1.summary())
```

Regressão Linear Multivariada

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.932
Model:	OLS	Adj. R-squared:	0.912
Method:	Least Squares	F-statistic:	47.92
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	8.23e-05
Time:	18:50:40	Log-Likelihood:	-16.509
No. Observations:	10	AIC:	39.02
Df Residuals:	7	BIC:	39.92
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	16.4064	4.343	3.778	0.007	6.138	26.675
Preço	-8.2476	2.196	-3.756	0.007	-13.440	-3.055
Publicidade	0.5851	0.134	4.377	0.003	0.269	0.901

Omnibus:	0.493	Durbin-Watson:	3.136
Prob(Omnibus):	0.782	Jarque-Bera (JB):	0.492
Skew:	-0.027	Prob(JB):	0.782
Kurtosis:	1.914	Cond. No.	126.

1. Soma dos Erros Quadráticos

- Soma dos erros quadráticos (SSE - *sum of squares for errors*), é a diferença entre os pontos e a curva de regressão.
- Permite aferir quanto que a curva se adere aos dados.

$$SSE = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

1. Soma dos Erros Quadráticos

Y	X_2	X_3	$\hat{Y}$	$Y - \hat{Y}$	$(Y - \hat{Y})^2$
10,0	1,3	9,0	10,95	-0,95	0,90
6,0	2,0	7,0	4,01	1,99	3,97
5,0	1,7	5,0	5,31	-0,31	0,10
12,0	1,5	14,0	12,23	-0,23	0,05
10,0	1,6	15,0	11,99	-1,99	3,95
15,0	1,2	12,0	13,53	1,47	2,16
5,0	1,6	6,0	6,72	-1,72	2,96
12,0	1,4	10,0	10,71	1,29	1,66
17,0	1,0	15,0	16,94	0,06	0,00
20,0	1,1	21,0	19,62	0,38	0,14
112,00					**15,90**
11,2					**SSE**

2. Erro Padrão da Estimativa

- O erro padrão da estimativa consiste no valor padrão pelo qual o valor real difere do valor estimado pela regressão.
- O erro médio é zero.
- Se o erro padrão σ_ε for baixo, os erros tenderão a ficar próximos de zero, indicando que o modelo de regressão se adere aos dados. Também indicará que o uso de um modelo linear é válido.
- Um estimador de σ_ε pode ser dado por s_ε.

2. Erro Padrão da Estimativa

$$s_{y.x} = s_{\varepsilon} = \sqrt{\frac{\sum\left(Y - \hat{Y}\right)^2}{n-k}} = \sqrt{\frac{SSE}{n-k}}$$

- k – número de parâmetros sendo estimados pelo modelo
- $s_{\varepsilon} = \sqrt{\frac{15{,}90}{7}} = 1{,}51$

3. Teste de Hipótese Coeficiente Angular

- Quando não houver relação linear entre duas variáveis, os coeficientes angulares das variáveis independentes será igual a 0.
- Inferência sobre β_2 e β_3 por meio de um teste de hipótese, para cada um dos coeficientes (b_2 e b_3):
- $H_0: \beta_2 = 0$
- $H_1: \beta_2 \neq 0$
- A estatística de teste é: $t = \frac{b_2 - \beta_2}{s_{b_2}}$

4. Análise de Variação dos Resíduos

- É importante conhecer qual é a variação na variável dependente Y que está associada à variação na variável dependente X.
- Vamos considerar a variação dos valores de Y em torno de sua média $\bar{Y}$ (chamaremos de SSTO - *total sum of squares*).

$$SSTO = \sum_{i=1}^{n} (y_i - \bar{y}_i)^2$$

4. Análise de Variação dos Resíduos

- Vamos separar o valor de SSTO em duas componentes: uma será a variação dos valores previstos pelo modelo de regressão $\hat{Y}$ em relação à média $\bar{Y}$ (SSR – *sum of squares due regression*); a outra medirá a variação dos valores em relação aos valores previstos (SSE – *sum of squares due to error*), que é uma variação não explicada pelo modelo.

4. Análise de Variação dos Resíduos

$$SSTO = \sum_{i=1}^{n} (y_i - \bar{y}_i)^2$$

$$SSR = \sum_{i=1}^{n} (\hat{y}_i - \bar{y}_i)^2 \qquad SSE = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

$$SSTO = \sum_{i=1}^{n} (y_i - \bar{y}_i)^2 = (y_i - \hat{y}_i + \hat{y}_i - \bar{y}_i)^2$$

$$= \sum_{i=1}^{n} (\hat{y}_i - \bar{y}_i)^2 + \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = SSR + SSE$$

- OBS: relação válida já que a soma dos demais termos é nula.

4. Análise de Variação dos Resíduos

Y	X_2	X_3	$Y - \bar{Y}$	$(Y - \bar{Y})^2$	$\hat{Y}$	$(\hat{Y} - \bar{Y})$	$(\hat{Y} - \bar{Y})^2$	$Y - \hat{Y}$	$(Y - \hat{Y})^2$
10,0	1,3	9,0	-1,20	1,44	10,95	-0,25	0,06	-0,95	0,90
6,0	2,0	7,0	-5,20	27,04	4,01	-7,19	51,74	1,99	3,97
5,0	1,7	5,0	-6,20	38,44	5,31	-5,89	34,68	-0,31	0,10
12,0	1,5	14,0	0,80	0,64	12,23	1,03	1,05	-0,23	0,05
10,0	1,6	15,0	-1,20	1,44	11,99	0,79	0,62	-1,99	3,95
15,0	1,2	12,0	3,80	14,44	13,53	2,33	5,43	1,47	2,16
5,0	1,6	6,0	-6,20	38,44	6,72	-4,48	20,06	-1,72	2,96
12,0	1,4	10,0	0,80	0,64	10,71	-0,49	0,24	1,29	1,66
17,0	1,0	15,0	5,80	33,64	16,94	5,74	32,89	0,06	0,00
20,0	1,1	21,0	8,80	77,44	19,62	8,42	70,92	0,38	0,14
112,00				**233,60**			**217,70**		**15,90**
11,2				**SSTO**			**SSR**		**SSE**

4. Análise de Variação dos Resíduos

- **Coeficiente de determinação**

$$r^2 = 1 - \frac{SSE}{SSTO} = \frac{SSR}{SSTO} = \frac{217{,}7}{233{,}6} = 0{,}932$$

- r^2 indica a proporção da variação em Y que pode ser explicada pela variação em X_2 e X_3.
- Aproximadamente 93,2% das vendas podem ser explicadas pela variação de preço e do valor gasto em publicidade, enquanto que 6,8% das vendas são atribuídas a outros fatores.

5. Usando o Modelo para Previsão

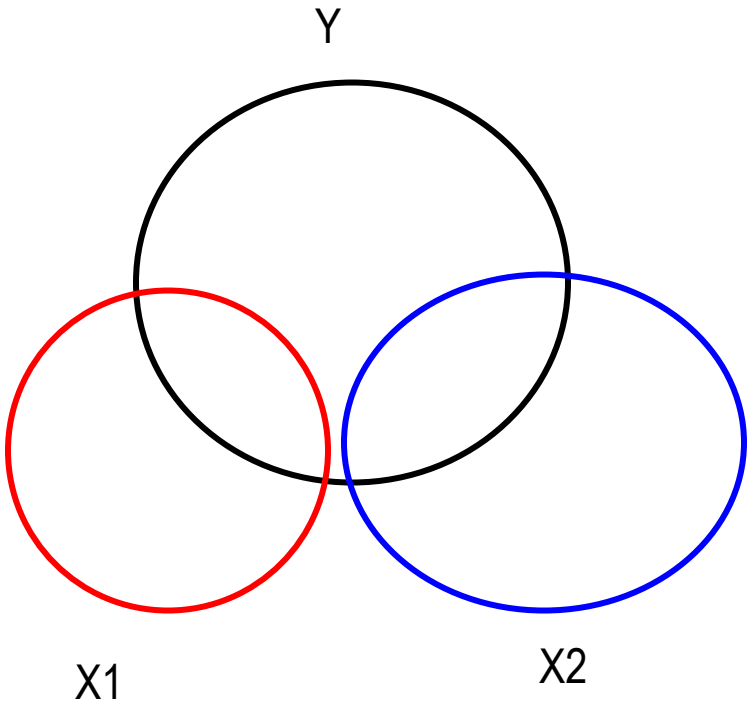
- Para o preço $X_2 = 1{,}50$ e para o orçamento de publicidade (em milhares de R$) $X_3 = 10{,}0$ prever a quantidade a ser vendida.
- $\hat{Y} = 16.4064 - 8.2476X_2 + 0.5851X_3 = 16.4064 - 8.2476(1{,}50) + 0.5851(10{,}0) = 14{,}06.$

Exemplo de Colinearidade

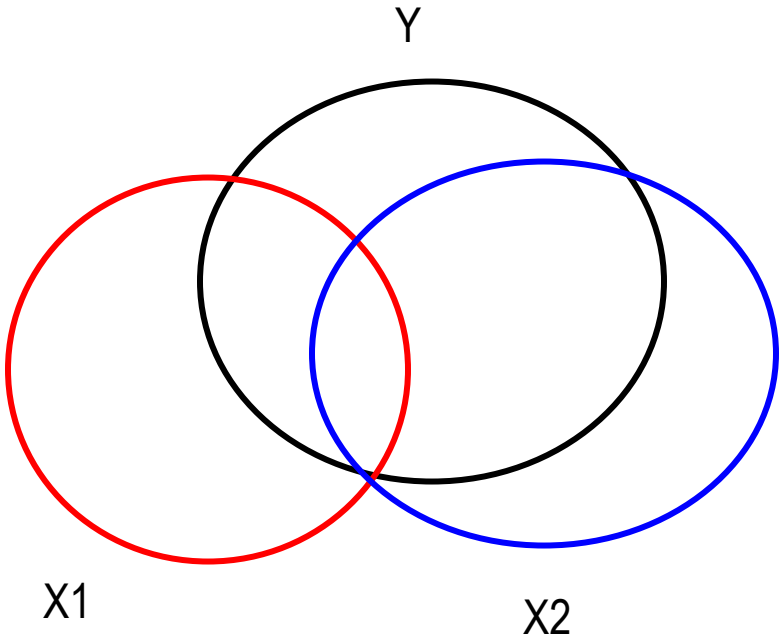
Colinearidade

- A colinearidade ocorre quando uma ou mais variáveis independentes são altamente relacionadas.

Colinearidade & Diagramas de Venn



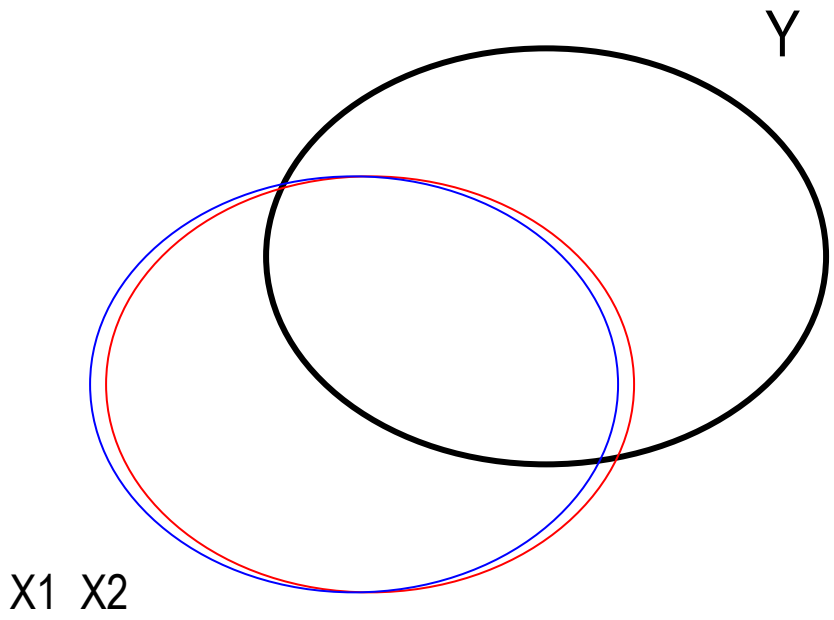
Não existe correlação entre X1 e X2. Cada variável explica parte da variação de Y.



Existe correlação entre X1 e X2. Há sobreposição do que cada variável contribui para explicar a variação de Y.

Fonte: utminers.utep.edu/crboehmer/Multivariate%20Regression.ppt

Colinearidade Perfeita & Diagrama de Venn



X2 é função de X1. Portanto, incluir X2 no modelo de previsão não irá explicar nenhuma variação de Y que é atribuída a X1.

Fonte: utminers.utep.edu/crboehmer/Multivariate%20Regression.ppt

Colinearidade

- Colinearidade:
  1. À medida que novas variáveis são acrescentadas ao modelo, o coeficiente de uma variável pode mudar de sinal, adquirindo sinal contrário ao de sua correlação.
  2. As estimativas dos coeficientes dos modelos de regressão variam grandemente de amostra para amostra.
  3. Torna-se difícil o entendimento e a interpretação da contribuição de cada variável junto à variável dependente.

Colinearidade - Exemplo

- Considere o seguinte exemplo que procura explicar o gasto anual de uma família com alimentação (Y), em centenas de reais, por meio das variáveis independentes de renda anual em milhares de reais (X_2) e tamanho da família (X_3).

Colinearidade - Exemplo

Família	Gasto Anual (Y)	Renda Anual (X_2)	Tamanho da Família (X_3)
A	24	11	6
B	8	3	2
C	16	4	1
D	18	7	3
E	24	9	5
F	23	8	4
G	11	5	2
H	15	7	2
I	21	8	3
J	20	7	2

Colinearidade - Exemplo

```
Renda = [11, 3, 4, 7, 9, 8, 5, 7, 8, 7]
Tamanho = [6, 2, 1, 3, 5, 4, 2, 2, 3, 2]
Gasto = [24, 8, 16, 18, 24, 23, 11, 15, 21, 20]
df = pd.DataFrame(list(zip(Renda, Tamanho, Gasto)), columns =['Renda','Tamanho','Gasto'])
print(df)
```

```
   Renda  Tamanho  Gasto
0     11        6     24
1      3        2      8
2      4        1     16
3      7        3     18
4      9        5     24
5      8        4     23
6      5        2     11
7      7        2     15
8      8        3     21
9      7        2     20
```

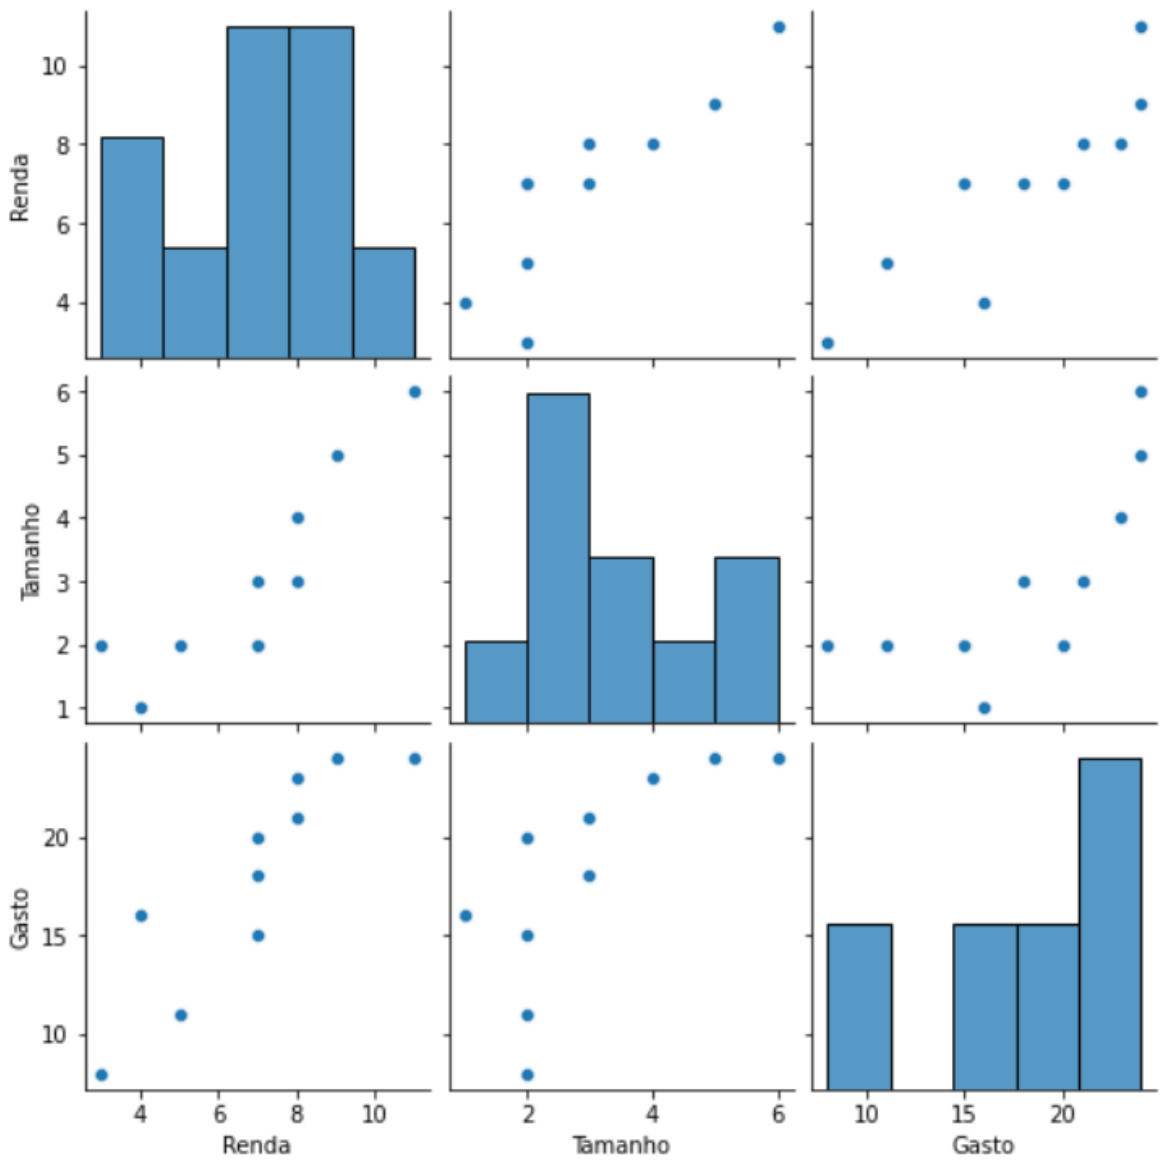
Colinearidade - Exemplo

```
corr = df.corr()
print(corr)
```

```
             Renda   Tamanho     Gasto
Renda     1.000000  0.866618  0.883873
Tamanho   0.866618  1.000000  0.736850
Gasto     0.883873  0.736850  1.000000
```

Colinearidade - Exemplo

```
# Mostra a correção entre as vari
sns.pairplot(df)
```



Regressão Linear Multivariada

```
# Importa as Bibliotecas
import statsmodels.api as sm
from statsmodels.formula.api import ols

# Regressão - Variável Independente Preço
model_1 = ols('Gasto ~ Renda + Tamanho', df).fit()
print(model_1.summary())
```

Regressão Linear Multivariada

OLS Regression Results

Dep. Variable:	Gasto	R-squared:	0.785
Model:	OLS	Adj. R-squared:	0.723
Method:	Least Squares	F-statistic:	12.75
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	0.00464
Time:	19:19:45	Log-Likelihood:	-23.028
No. Observations:	10	AIC:	52.06
Df Residuals:	7	BIC:	52.96
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	3.5187	3.161	1.113	0.302	-3.955	10.992
Renda	2.2776	0.813	2.803	0.026	0.356	4.199
Tamanho	-0.4114	1.236	-0.333	0.749	-3.334	2.511

Omnibus:	1.279	Durbin-Watson:	1.785
Prob(Omnibus):	0.527	Jarque-Bera (JB):	0.691
Skew:	-0.005	Prob(JB):	0.708
Kurtosis:	1.713	Cond. No.	28.6

Colinearidade - Exemplo

- Apesar de ambas variáveis serem correlacionadas de forma positiva com Y, o coeficiente de X_3 é negativo, sugerindo que com o aumento de uma pessoa na família, o gasto com alimentação cai independente da renda familiar, o que é inconsistente.

Procedimento para Seleção de Variáveis Independentes

Seleção de Variáveis – Exemplo

- Um dos canais de distribuição de uma empresa é a venda direta, por meio de uma equipe de vendedores que visitam os clientes. A empresa está interessada em prever se um funcionário será um bom vendedor, e para isso pretende confrontar o nível de vendas do primeiro mês de trabalho (Y) com as seguintes variáveis: nota no teste de aptidão para vendas (X_2), idade do vendedor (X_3), nota em uma prova de ansiedade (X_4), anos de experiência anterior (X_5), e média ponderada do ensino médio em escala de 0 a 5 (X_6).

Seleção de Variáveis – Exemplo

- Identifique quais as variáveis mais relevantes para explicar o desempenho da equipe de vendas.

Seleção de Variáveis (Dados 1/2)

Unidades Vendidas em Mês de Experiência (Y)	Teste de Aptidão (X_2)	Idade (X_3)	Teste de Ansiedade (X4)	Experiência (anos) (X_5)	Média Ponderada Ensino Médio (X_6)
44	10	21,1	4,9	0	2,4
47	19	22,5	3,0	1	2,6
60	27	23,1	1,5	0	2,8
71	31	24,0	0,6	3	2,7
61	64	22,6	1,8	2	2,0
60	81	21,7	3,3	1	2,5
58	42	23,8	3,2	0	2,5
56	67	22,0	2,1	0	2,3
66	48	22,4	6,0	1	2,8
61	64	22,6	1,8	1	3,4
51	57	21,1	3,8	0	3,0
47	10	22,5	4,5	1	2,7
53	48	22,2	4,5	0	2,8
74	96	24,8	0,1	3	3,8
65	75	22,6	0,9	0	3,7

Seleção de Variáveis (Dados 2/2)

Unidades Vendidas em Mês de Experiência (Y)	Teste de Aptidão (X_2)	Idade (X_3)	Teste de Ansiedade (X4)	Experiência (anos) (X_5)	Média Ponderada Ensino Médio (X_6)
33	12	20,5	4,8	0	2,1
54	47	21,9	2,3	1	1,8
39	20	20,5	3,0	2	1,5
52	73	20,8	0,3	2	1,9
30	4	20,0	2,7	0	2,2
58	9	23,3	4,4	1	2,8
59	98	21,3	3,9	1	2,9
52	27	22,9	1,4	2	3,2
56	59	22,3	2,7	1	2,7
49	23	22,6	2,7	1	2,4
63	90	22,4	2,2	2	2,6
61	34	23,8	0,7	1	3,4
39	16	20,6	3,1	1	2,3
62	32	24,4	0,6	3	4,0
78	94	25,0	4,6	5	3,6

Seleção de Variáveis

```
corr = df1.corr()
print(corr)
```

	Teste	Idade	Ansiedade	Experiencia	Media	Vendas
Teste	1.000000	0.256649	-0.221988	0.349639	0.317772	0.676120
Idade	0.256649	1.000000	-0.319224	0.557595	0.696922	0.811956
Ansiedade	-0.221988	-0.319224	1.000000	-0.278689	-0.244382	-0.295860
Experiencia	0.349639	0.557595	-0.278689	1.000000	0.312129	0.549834
Media	0.317772	0.696922	-0.244382	0.312129	1.000000	0.621784
Vendas	0.676120	0.811956	-0.295860	0.549834	0.621784	1.000000

Seleção de Variáveis – Método Exaustivo

- O método exaustivo consiste em gerar todas as possíveis combinações de variáveis, e avaliar o coeficiente de determinação resultante.
- Para *n* variáveis independentes, haverá 2^n possibilidades.
- Será solução a combinação que resultar no maior coeficiente de determinação.
- Característica desejável: menor número possível de variáveis, visando garantir a maior independência entre as variáveis.

Seleção de Variáveis (1/3)

Variáveis Independentes					# Parâmetros	Graus de Liberdade	r^2
X_2					2	28	0,457
X_3					2	28	0,637
X_4					2	28	0,088
X_5					2	28	0,302
X_6					2	28	0,387
X_2	X_3				3	27	0,8948
X_2	X_4				3	27	0,479
X_2	X_5				3	27	0,569
X_2	X_6				3	27	0,641
X_3	X_4				3	27	0,642

Seleção de Variáveis (2/3)

Variáveis Independentes					# Parâmetros	Graus de Liberdade	r^2
X_3	X_5				3	27	0,657
X_3	X_6				3	27	0,646
X_4	X_5				3	27	0,324
X_4	X_6				3	27	0,409
X_5	X_6				3	27	0,527
X_2	X_3	X_4			4	26	0,8951
X_2	X_3	X_5			4	26	0,8948
X_2	X_3	X_6			4	26	0,8953
X_2	X_4	X_5			4	26	0,575
X_2	X_4	X_6			4	26	0,646

Seleção de Variáveis (3/3)

Variáveis Independentes					# Parâmetros	Graus de Liberdade	r^2
X_2	X_5	X_6			4	26	0,701
X_3	X_4	X_5			4	26	0,659
X_3	X_4	X_6			4	26	0,65
X_3	X_5	X_6			4	26	0,669
X_4	X_5	X_6			4	26	0,531
X_2	X_3	X_4	X_5		5	25	0,8951
X_2	X_3	X_4	X_6		5	25	0,8955
X_2	X_3	X_5	X_6		5	25	0,8953
X_2	X_4	X_5	X_6		5	25	0,701
X_3	X_4	X_5	X_6		5	25	0,671
X_2	X_3	X_4	X_5	X_6	6	24	0,8955

Seleção de Variáveis – Método Exaustivo

- Tabela resumo, contendo a melhor seleção de variáveis (de 1 a 5).

Variáveis Independentes					# Parâmetros	Graus de Liberdade	r^2
X_3					2	28	0,637
X_2	X_3				3	27	0,8948
X_2	X_3	X_6			4	26	0,8953
X_2	X_3	X_4	X_6		5	25	0,8955
X_2	X_3	X_4	X_5	X_6	6	24	0,8955

Seleção de Variáveis – Método Aditivo

- O método aditivo consiste em selecionar, em cada iteração, uma variável independente, que resulte no maior valor da estatística *t* (em módulo) para o coeficiente angular.
- Na primeira iteração, a escolha coincide com a variável com o maior coeficiente de correlação. A variável escolhida será designada de X_2, e o modelo de regressão será $\hat{Y} = b_{0(1)} + b_{2(1)}X_2$.

Seleção de Variáveis – Método Aditivo

- Na iteração subsequente, a variável X_2é mantida, e será escolhida a variável X_3 que resulte no maior valor da estatística *t* (em módulo) para o coeficiente angular b_3. Se o teste indicar que o coeficiente é diferente de zero, para o nível de significância considerado, então a expressão para a ser expressa por $\hat{Y} = b_{0(2)} + b_{2(2)}X_2 + b_{3(2)}X_3$.
- OBS: Os coeficientes dos termos mantidos de uma iteração para a outra provavelmente irão variar. Assim $b_{0(1)} \neq b_{0(2)}$, e assim por diante...

Seleção de Variáveis – Método Aditivo

- Continuar o procedimento até que não haja uma variável a ser adicionada, que possua coeficiente angular significativamente diferente de zero.

Seleção de Variáveis – Método Aditivo
Adição da 1ª variável independente

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.457
Model:	OLS	Adj. R-squared:	0.438
Method:	Least Squares	F-statistic:	23.58
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	4.11e-05
Time:	20:31:15	Log-Likelihood:	-105.28
No. Observations:	30	AIC:	214.6
Df Residuals:	28	BIC:	217.4
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	43.4120	2.886	15.041	0.000	37.500	49.324
Teste	0.2590	0.053	4.856	0.000	0.150	0.368

Omnibus:	0.592	Durbin-Watson:	1.995
Prob(Omnibus):	0.744	Jarque-Bera (JB):	0.639
Skew:	0.293	Prob(JB):	0.727
Kurtosis:	2.590	Cond. No.	102.

Seleção de Variáveis – Método Aditivo
Adição da 1ª variável independente

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.659
Model:	OLS	Adj. R-squared:	0.647
Method:	Least Squares	F-statistic:	54.18
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	5.15e-08
Time:	20:31:25	Log-Likelihood:	-98.298
No. Observations:	30	AIC:	200.6
Df Residuals:	28	BIC:	203.4
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-100.7317	21.233	-4.744	0.000	-144.226	-57.238
Idade	6.9730	0.947	7.361	0.000	5.032	8.914

Omnibus:	6.324	Durbin-Watson:	2.481
Prob(Omnibus):	0.042	Jarque-Bera (JB):	1.951
Skew:	0.060	Prob(JB):	0.377
Kurtosis:	1.757	Cond. No.	394.

Seleção de Variáveis – Método Aditivo
Adição da 1ª variável independente

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.088
Model:	OLS	Adj. R-squared:	0.055
Method:	Least Squares	F-statistic:	2.686
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	0.112
Time:	20:31:37	Log-Likelihood:	-113.07
No. Observations:	30	AIC:	230.1
Df Residuals:	28	BIC:	233.0
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	61.0367	4.022	15.174	0.000	52.797	69.276
Ansiedade	-2.1143	1.290	-1.639	0.112	-4.757	0.528

Omnibus:	1.453	Durbin-Watson:	1.523
Prob(Omnibus):	0.484	Jarque-Bera (JB):	0.456
Skew:	-0.055	Prob(JB):	0.796
Kurtosis:	3.594	Cond. No.	6.83

Seleção de Variáveis – Método Aditivo
Adição da 1ª variável independente

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.302
Model:	OLS	Adj. R-squared:	0.277
Method:	Least Squares	F-statistic:	12.13
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	0.00165
Time:	20:31:58	Log-Likelihood:	-109.05
No. Observations:	30	AIC:	222.1
Df Residuals:	28	BIC:	224.9
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	49.0882	2.487	19.740	0.000	43.994	54.182
Experiencia	5.1765	1.486	3.483	0.002	2.132	8.221

Omnibus:	2.585	Durbin-Watson:	1.711
Prob(Omnibus):	0.275	Jarque-Bera (JB):	2.230
Skew:	-0.645	Prob(JB):	0.328
Kurtosis:	2.656	Cond. No.	2.92

Seleção de Variáveis – Método Aditivo
Adição da 1ª variável independente

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.387
Model:	OLS	Adj. R-squared:	0.365
Method:	Least Squares	F-statistic:	17.65
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	0.000245
Time:	20:32:01	Log-Likelihood:	-107.12
No. Observations:	30	AIC:	218.2
Df Residuals:	28	BIC:	221.0
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	24.2765	7.561	3.211	0.003	8.787	39.765
Media	11.4337	2.722	4.201	0.000	5.859	17.009

Omnibus:	0.462	Durbin-Watson:	1.698
Prob(Omnibus):	0.794	Jarque-Bera (JB):	0.600
Skew:	-0.174	Prob(JB):	0.741
Kurtosis:	2.401	Cond. No.	14.5

Seleção de Variáveis – Método Aditivo
Adição da 2ª variável independente

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.893
Model:	OLS	Adj. R-squared:	0.886
Method:	Least Squares	F-statistic:	113.2
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	7.43e-14
Time:	20:43:07	Log-Likelihood:	-80.858
No. Observations:	30	AIC:	167.7
Df Residuals:	27	BIC:	171.9
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-84.8405	12.265	-6.917	0.000	-110.006	-59.675
Idade	5.8694	0.558	10.516	0.000	4.724	7.015
Teste	0.1918	0.025	7.704	0.000	0.141	0.243

Omnibus:	8.787	Durbin-Watson:	2.023
Prob(Omnibus):	0.012	Jarque-Bera (JB):	7.132
Skew:	1.048	Prob(JB):	0.0283
Kurtosis:	4.146	Cond. No.	1.02e+03

Seleção de Variáveis – Método Aditivo
Adição da 2ª variável independente

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.661
Model:	OLS	Adj. R-squared:	0.636
Method:	Least Squares	F-statistic:	26.30
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	4.59e-07
Time:	20:44:28	Log-Likelihood:	-98.232
No. Observations:	30	AIC:	202.5
Df Residuals:	27	BIC:	206.7
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-97.4358	23.594	-4.130	0.000	-145.846	-49.025
Idade	6.8610	1.016	6.755	0.000	4.777	8.945
Ansiedade	-0.2917	0.845	-0.345	0.733	-2.026	1.443

Omnibus:	4.868	Durbin-Watson:	2.478
Prob(Omnibus):	0.088	Jarque-Bera (JB):	1.764
Skew:	0.103	Prob(JB):	0.414
Kurtosis:	1.830	Cond. No.	434.

Seleção de Variáveis – Método Aditivo
Adição da 2ª variável independente

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.673
Model:	OLS	Adj. R-squared:	0.649
Method:	Least Squares	F-statistic:	27.78
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	2.80e-07
Time:	20:56:57	Log-Likelihood:	-97.684
No. Observations:	30	AIC:	201.4
Df Residuals:	27	BIC:	205.6
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-87.2260	24.704	-3.531	0.002	-137.914	-36.538
Idade	6.2983	1.139	5.532	0.000	3.962	8.634
Experiencia	1.3265	1.248	1.063	0.297	-1.235	3.888

Omnibus:	4.452	Durbin-Watson:	2.442
Prob(Omnibus):	0.108	Jarque-Bera (JB):	1.671
Skew:	0.067	Prob(JB):	0.434
Kurtosis:	1.852	Cond. No.	460.

Seleção de Variáveis – Método Aditivo
Adição da 2ª variável independente

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.665
Model:	OLS	Adj. R-squared:	0.641
Method:	Least Squares	F-statistic:	26.84
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	3.82e-07
Time:	20:57:56	Log-Likelihood:	-98.028
No. Observations:	30	AIC:	202.1
Df Residuals:	27	BIC:	206.3
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-91.5958	25.087	-3.651	0.001	-143.071	-40.121
Idade	6.3223	1.333	4.742	0.000	3.587	9.058
Media	1.9992	2.855	0.700	0.490	-3.858	7.856

Omnibus:	7.270	Durbin-Watson:	2.412
Prob(Omnibus):	0.026	Jarque-Bera (JB):	2.056
Skew:	-0.002	Prob(JB):	0.358
Kurtosis:	1.717	Cond. No.	465.

Seleção de Variáveis – Método Aditivo
Adição da 3ª variável independente

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.895
Model:	OLS	Adj. R-squared:	0.883
Method:	Least Squares	F-statistic:	73.68
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	7.73e-13
Time:	20:59:50	Log-Likelihood:	-80.677
No. Observations:	30	AIC:	169.4
Df Residuals:	26	BIC:	175.0
Df Model:	3		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-87.7393	13.453	-6.522	0.000	-115.392	-60.086
Idade	5.9613	0.589	10.128	0.000	4.751	7.171
Teste	0.1940	0.026	7.603	0.000	0.142	0.246
Ansiedade	0.2727	0.485	0.562	0.579	-0.725	1.271

Omnibus:	7.213	Durbin-Watson:	1.971
Prob(Omnibus):	0.027	Jarque-Bera (JB):	5.474
Skew:	0.950	Prob(JB):	0.0648
Kurtosis:	3.878	Cond. No.	1.11e+03

Seleção de Variáveis – Método Aditivo
Adição da 3ª variável independente

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.894
Model:	OLS	Adj. R-squared:	0.881
Method:	Least Squares	F-statistic:	72.74
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	8.97e-13
Time:	21:01:34	Log-Likelihood:	-80.849
No. Observations:	30	AIC:	169.7
Df Residuals:	26	BIC:	175.3
Df Model:	3		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-85.7134	14.365	-5.967	0.000	-115.241	-56.186
Idade	5.9116	0.664	8.902	0.000	4.547	7.277
Teste	0.1926	0.026	7.340	0.000	0.139	0.247
Experiencia	-0.0925	0.751	-0.123	0.903	-1.636	1.451

Omnibus:	8.948	Durbin-Watson:	2.021
Prob(Omnibus):	0.011	Jarque-Bera (JB):	7.317
Skew:	1.051	Prob(JB):	0.0258
Kurtosis:	4.200	Cond. No.	1.18e+03

Seleção de Variáveis – Método Aditivo
Adição da 3ª variável independente

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.894
Model:	OLS	Adj. R-squared:	0.882
Method:	Least Squares	F-statistic:	72.98
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	8.63e-13
Time:	21:02:45	Log-Likelihood:	-80.805
No. Observations:	30	AIC:	169.6
Df Residuals:	26	BIC:	175.2
Df Model:	3		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-87.0317	14.411	-6.039	0.000	-116.655	-57.409
Idade	6.0257	0.766	7.864	0.000	4.451	7.601
Teste	0.1934	0.026	7.481	0.000	0.140	0.247
Media	-0.5080	1.672	-0.304	0.764	-3.946	2.929

Omnibus:	8.416	Durbin-Watson:	2.051
Prob(Omnibus):	0.015	Jarque-Bera (JB):	6.720
Skew:	1.022	Prob(JB):	0.0347
Kurtosis:	4.093	Cond. No.	1.19e+03

Seleção de Variáveis – Método Aditivo
Modelo Final: 2 Variáveis Independentes

OLS Regression Results

Dep. Variable:	Vendas	R-squared:	0.893
Model:	OLS	Adj. R-squared:	0.886
Method:	Least Squares	F-statistic:	113.2
Date:	Mon, 24 Oct 2022	Prob (F-statistic):	7.43e-14
Time:	20:43:07	Log-Likelihood:	-80.858
No. Observations:	30	AIC:	167.7
Df Residuals:	27	BIC:	171.9
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-84.8405	12.265	-6.917	0.000	-110.006	-59.675
Idade	5.8694	0.558	10.516	0.000	4.724	7.015
Teste	0.1918	0.025	7.704	0.000	0.141	0.243

Omnibus:	8.787	Durbin-Watson:	2.023
Prob(Omnibus):	0.012	Jarque-Bera (JB):	7.132
Skew:	1.048	Prob(JB):	0.0283
Kurtosis:	4.146	Cond. No.	1.02e+03

Variáveis “Dummy”

Variáveis “Dummy” para Categorias

- Quando os dados representarem uma determinada categoria ao invés de uma variável quantitativa, estes poderão ser substituídos por valores numéricos.
- Exemplo: para diferenciar o desempenho entre dois terminais A e B. Fazer com que uma determinada variável X seja 1 quando os dados se referirem ao terminal A, e 0 em caso contrário (terminal B).

Exercícios

Regressão Linear Simples
Exercício 1

- Uma empresa de e-commerce registrou o nível de vendas, em função do número de propagandas veiculadas em horário nobre, nas semanas que antecediam uma certa data comemorativa.

Cidade	Vendas (x1000)	# Aparições
A	26	6
B	16	2
C	23	5
D	15	1
E	32	10
F	25	7
G	18	15
H	18	3
I	35	11
J	34	13
K	15	2
L	32	12

Regressão Linear Simples
Exercício 1

a) Verifique se há correlação linear entre as 2 variáveis.

b) Determine a curva de regressão.

c) Calcule o erro padrão da estimativa.

d) Qual o percentual de vendas que é explicado pela variação na quantidade de aparições em comerciais na televisão?

e) Verifique se o coeficiente angular é significativamente diferente de zero, para um nível de significância de 1%.

f) Faça uma previsão das vendas para 10 aparições na televisão.

Regressão Linear Simples
Exercício 2

- Gere 2 amostras diferentes de tamanho=20, 40, 60, 80 e 100 e compare o intervalo de previsão, ao prever Y para X=305.
- Os dados encontram-se anexados no eDisciplinas.

Exercício 3

- Uma empresa de energia necessita prever o consumo de energia para o 3º e o 4º trimestre com base no consumo registrado nos últimos 16 anos.
- O modelo de regressão é baseado em categorias indicativas do trimestre em questão, estruturadas da seguinte maneira: S_2, S_3, S_4- serão 1, se o trimestre *t* for, respectivamente, o 1º, 2º e 3º trimestre de um ano, e 0 em caso contrário.
- Curva de regressão: $\hat{Y} = b_0 + b_2 S_2 + b_3 S_3 + b_4 S_4$.

Exercício 3

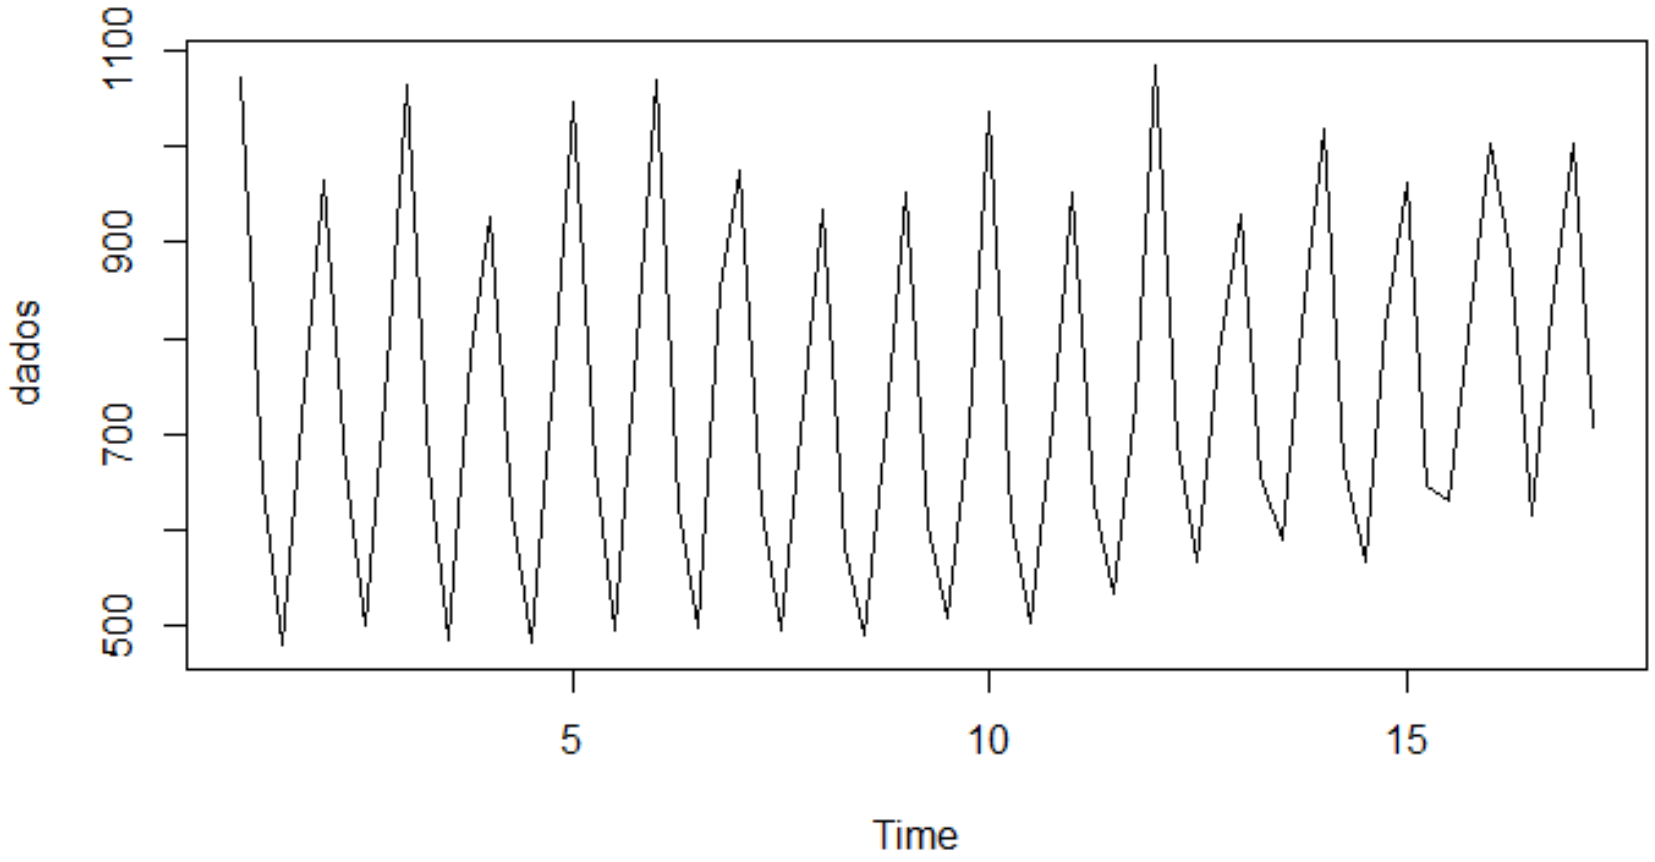
Ano	Trim.	kWh
2001	1	1071
	2	648
	3	480
	4	746
2002	1	965
	2	661
	3	501
	4	768
2003	1	1065
	2	667
	3	486
	4	780
2004	1	926
	2	618
	3	483
	4	757

Ano	Trim.	kWh
2005	1	1047
	2	667
	3	495
	4	794
2006	1	1068
	2	625
	3	499
	4	850
2007	1	975
	2	623
	3	496
	4	728
2008	1	933
	2	582
	3	490
	4	708

Ano	Trim.	kWh
2009	1	953
	2	604
	3	508
	4	708
2010	1	1036
	2	612
	3	503
	4	710
2011	1	952
	2	628
	3	534
	4	733
2012	1	1085
	2	692
	3	568
	4	783

Ano	Trim.	kWh
2013	1	928
	2	655
	3	590
	4	814
2014	1	1018
	2	670
	3	566
	4	811
2015	1	962
	2	647
	3	630
	4	803
2016	1	1002
	2	887
	3	615
	4	828
2017	1	1003
	2	706

Exercício 3



Exercício 3

- Estruturação dos dados, fazendo uso das variáveis $S_2, S_3, S_4 \ldots$

Ano	Trim.	kWh (Y)	S_2	S_3	S_4
2001	1	1071	1	0	0
	2	648	0	1	0
	3	480	0	0	1
	4	746	0	0	0
2002	1	965	1	0	0
	2	661	0	1	0
	3	501	0	0	1
	4	768	0	0	0
2003	1	1065	1	0	0
	2	667	0	1	0
	3	486	0	0	1
	4	780	0	0	0
2004	1	926	1	0	0
	2	618	0	1	0
	3	483	0	0	1
	4	757	0	0	0

Exercício 4

- Para os dados do exercício 4 (anexado no edisciplinas), relativo ao preço de venda de imóveis, realize o processo aditivo de seleção de variáveis independentes.