Teste de Durbin-Watson
Modelos Autoregressivos

PNV-3421 – Processos Estocásticos

Prof. Dr. André Bergsten Mendes

Bibliografia Principal

- Hanke, J.E & Reitsch A.G. (1998) Business Forecasting. 6th Edition, Prentice Hall, Upper Sadle River, NJ.

Regressão de Séries Temporais

- Iremos aplicar modelos de regressão linear para um conjunto de observações que foram coletadas ao longo do tempo.
- Tipicamente, o problema que surge é a ausência de independência dos resíduos, deixando de caracterizar uma série aleatória, com distribuição aproximadamente normal. Ou seja, os resíduos apresentam *autocorrelação* (correlação serial).

Exemplo Introdutório

- Considere o histórico de vendas de um determinado produto (10^3 \$), ao qual foi associada a renda líquida (10^6 \$) da região.

Ano	Vendas	Renda Líquida
1976	295	273,4
1977	400	291,3
1978	390	306,9
1979	425	317,1
1980	547	336,1
1981	555	349,4
1982	620	362,9
1983	720	383,9
1984	880	402,8
1985	1050	437,0
1986	1290	472,2

Ano	Vendas	Renda Líquida
1987	1528	510,4
1988	1586	544,5
1989	1960	588,1
1990	2118	630,4
1991	2116	685,9
1992	2477	742,8
1993	3199	801,3
1994	3702	903,1
1995	3316	983,6
1996	2702	1076,7

Exemplo Introdutório

```
# Importa bibliotecas
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
```

```
Renda = [273.4, 291.3, 306.9, 317.1, 336.1, 349.4, 362.9, 383.9, 402.8, 437.0, 472.2
Venda = [295, 400, 390, 425, 547, 555, 620, 720, 880, 1050, 1290, 1528, 1586, 1960,
df = pd.DataFrame(list(zip(Renda, Venda)), columns =['Renda','Venda'])
print(df)
```

```
     Renda  Venda
0    273.4    295
1    291.3    400
2    306.9    390
3    317.1    425
4    336.1    547
5    349.4    555
6    362.9    620
7    383.9    720
8    402.8    880
```

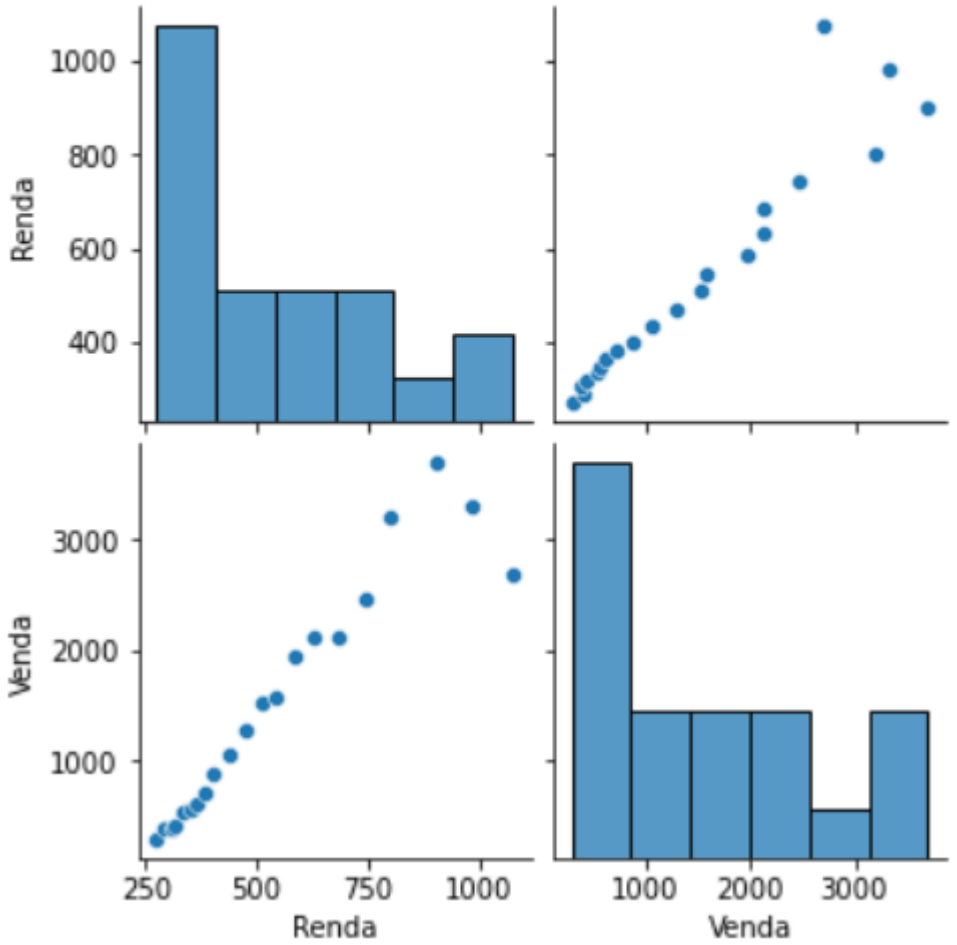
Exemplo Introdutório

```
corr = df.corr()
print(corr)
```

```
          Renda     Venda
Renda  1.000000  0.951319
Venda  0.951319  1.000000
```

```
# Mostra a correção entre as variáveis
sns.pairplot(df)
```

```
<seaborn.axisgrid.PairGrid at 0x144e084ac40>
```



Exemplo Introdutório

```
# Importa as Bibliotecas
import statsmodels.api as sm
from statsmodels.formula.api import ols

# Regressão - Variável Independente Renda
model_1 = ols('Venda ~ Renda', df).fit()
print(model_1.summary())
```

Exemplo Introdutório

OLS Regression Results

Dep. Variable:	Venda	R-squared:	0.905
Model:	OLS	Adj. R-squared:	0.900
Method:	Least Squares	F-statistic:	181.0
Date:	Mon, 21 Nov 2022	Prob (F-statistic):	3.67e-11
Time:	15:37:19	Log-Likelihood:	-151.22
No. Observations:	21	AIC:	306.4
Df Residuals:	19	BIC:	308.5
Df Model:	1		
Covariance Type:	nonrobust		

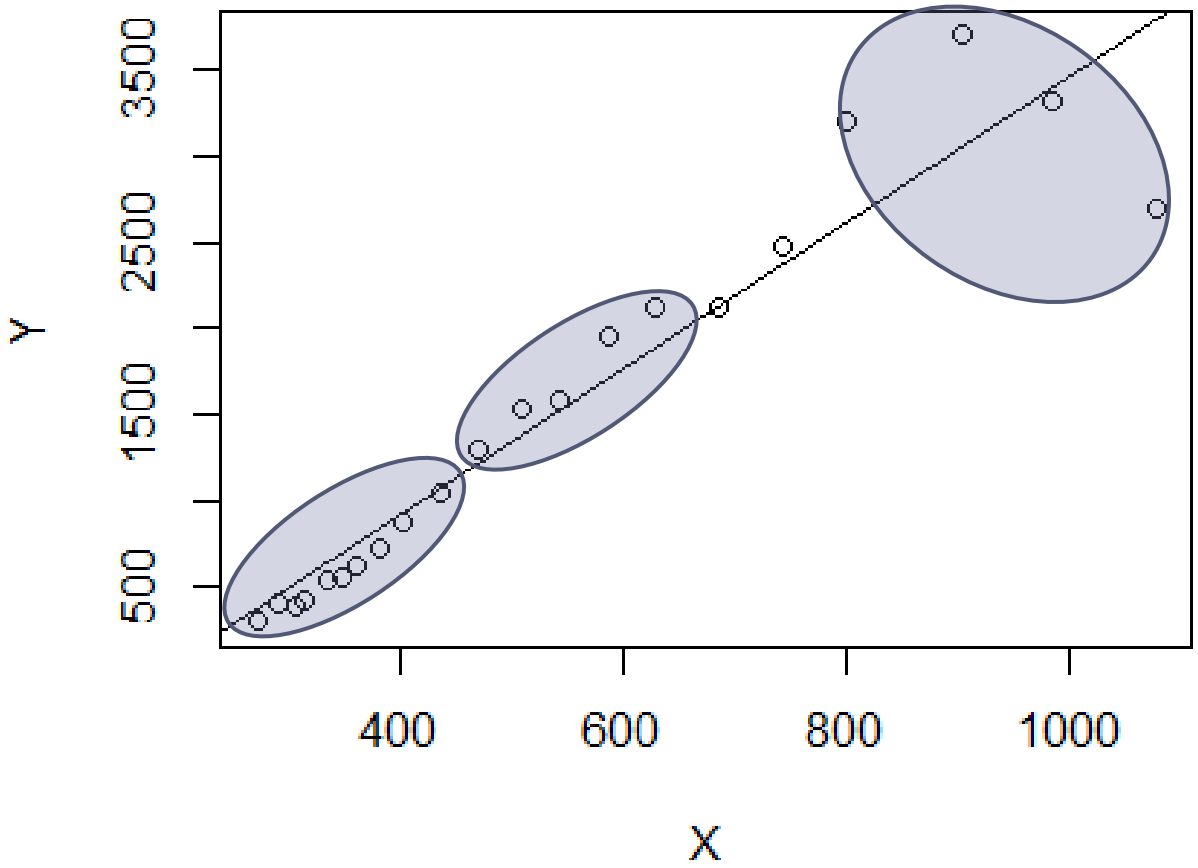
	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-792.0024	187.128	-4.232	0.000	-1183.665	-400.340
Renda	4.2552	0.316	13.454	0.000	3.593	4.917

Omnibus:	14.717	Durbin-Watson:	0.871
Prob(Omnibus):	0.001	Jarque-Bera (JB):	20.563
Skew:	-1.107	Prob(JB):	3.43e-05
Kurtosis:	7.312	Cond. No.	1.49e+03

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 1.49e+03. This might indicate that there are strong multicollinearity or other numerical problems.

Exemplo Introdutório

- Regressão linear



Resíduos negativos + Resíduos positivos + Resíduos com grande dispersão

Exemplo Introdutório

- O que se verifica é que o valor das vendas em um determinado período está correlacionado com o valor no período anterior (faria sentido ser totalmente aleatório!?). Assim, os resíduos não são independentes de uma observação para a próxima.
- Iremos usar o termo ***correlação serial*** para esta característica.

Correlação Serial de Primeira Ordem

- A correlação mais usual é a de primeira ordem, na qual o erro é função do erro do período anterior.

$$Y_t = \beta_0 + \beta X_t + \epsilon_t$$

$$\epsilon_t = \rho \epsilon_{t-1} + v_t$$

- Onde:

ϵ_t – componente de erro

ρ – coeficiente de correlação serial de 1ª ordem

v_t – termo independente, normalmente distribuído

Correlação Serial de Primeira Ordem

- A principal causa da correlação serial é a ausência de variável explanatória no modelo.
- Consequências: i) o erro padrão da estimativa subestima de forma significativa a variabilidade das componentes de erro; ii) o uso da distribuição *t* (e *F*) para construção do intervalo de confiança da previsão não é válido; iii) o erro padrão dos coeficientes da curva de regressão subestimam a variabilidade destes coeficientes.

Teste de Durbin-Watson

- Para detectar a correlação serial pode ser aplicado o teste de Durbin-Watson (DW), que consiste em fazer um teste de hipótese para determinar se o coeficiente ρ na expressão $\epsilon_t = \rho\epsilon_{t-1} + v_t$ é zero.
- Teste de hipótese:

$$H_0: \rho = 0$$
$$H_1: \rho > 0$$

- O teste será feito apenas para $\rho > 0$, que é o caso mais usual (OBS: se $\rho < 0$, então os resíduos mudam de sinal a cada período; é, portanto, um caso menos frequente).

Teste de Durbin-Watson

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2}$$

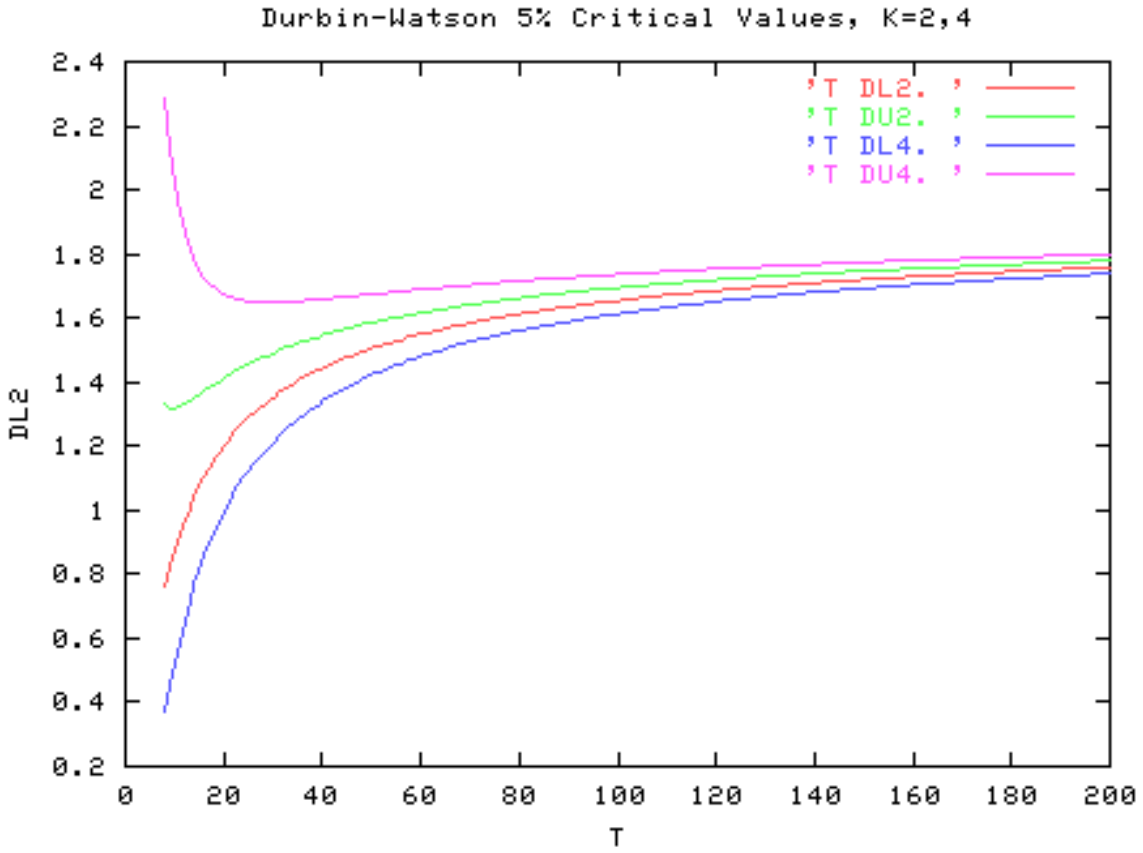
- Onde:

  e_t - erro entre o valor observado e a curva de regressão

- O teste é aproximado, e o valor calculado de *DW* é comparado a um limitante inferior (*L*) e um limitante superior (*U*):
- Se *DW* > *U*, então aceita-se H_0
- Se *DW* < *L*, então aceita-se H_1
- Se $L \leq DW \leq U$, o teste é inconclusivo

Teste de Durbin-Watson

- Valores de referência: https://www.real-statistics.com/statistics-tables/durbin-watson-table/



Teste de Durbin-Watson p/Exemplo Introdutório

Ano	Vendas (Y)	Renda (X)	e_t	e_t-e_{t-1}	$(e_t - e_{t-1})^2$	e_t^2
1976	295	273,4	-76,4			5.832,3
1977	400	291,3	-47,5	28,8	831,3	2.259,8
1978	390	306,9	-123,9	-76,4	5.834,1	15.355,8
1979	425	317,1	-132,3	-8,4	70,6	17.509,0
1980	547	336,1	-91,2	41,2	1.693,4	8.312,0
1981	555	349,4	-139,8	-48,6	2.361,4	19.534,1
1982	620	362,9	-132,2	7,6	57,1	17.479,4
1983	720	383,9	-121,6	10,6	113,2	14.779,0
1984	880	402,8	-42,0	79,6	6.332,5	1.763,3
1985	1050	437,0	-17,5	24,5	598,9	307,0
1986	1290	472,2	72,7	90,2	8.139,1	5.284,8
1987	1528	510,4	148,1	75,5	5.692,9	21.947,9
1988	1586	544,5	61,0	-87,1	7.586,8	3.726,6
1989	1960	588,1	249,5	188,5	35.522,2	62.259,9
1990	2118	630,4	227,5	-22,0	483,8	51.767,3
1991	2116	685,9	-10,6	-238,2	56.721,9	113,2
1992	2477	742,8	108,2	118,9	14.132,2	11.715,9
1993	3199	801,3	581,3	473,1	223.796,0	337.922,1
1994	3702	903,1	651,1	69,8	4.874,9	423.971,9
1995	3316	983,6	-77,4	-728,5	530.775,8	5.992,7
1996	2702	1076,7	-1.087,6	-1.010,2	1.020.421,4	1.182.811,6
					1.926.039,5	**2.210.645,6**

Teste de Durbin-Watson p/Exemplo Introdutório

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2} = \frac{1.926.035,14}{2.210.641,78} = 0,87$$

- Valores de referência para $\alpha = 1\%$ de nível de significância, amostra de 21 dados e 1 variável independente:

Critical Values for the Durbin-Watson Test: 1% Significance Level

T=6 to 100, K=2 to 21 (K <= T-4)

K includes intercept

T	K	dL	dU
21.	**2.**	**0.97545**	**1.16059**
21.	3.	0.88950	1.27688
21.	4.	0.80319	1.40823
21.	5.	0.71752	1.55360

DW < 0,97 → aceitamos H_1 (os resíduos são correlacionados)

Teste de Durbin-Watson p/Exemplo Introdutório

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2} = \frac{1.926.035,14}{2.210.641,78} = 0,87$$

```
from statsmodels.stats.stattools import durbin_watson

#realiza o teste Durbin-Watson
durbin_watson(model_1.resid)
```

```
0.8712532014949105
```

Exemplo 2

- Neste exemplo, vamos corrigir o efeito da correlação serial dos resíduos, pela adição de uma nova variável explanatória.
- O exemplo é similar ao primeiro, em que o nível de vendas é, inicialmente, explicado pela renda líquida total dos clientes de uma determinada região.

Ano	Vendas	Renda Líquida
1980	8,0	336,1
1981	8,2	349,4
1982	8,5	362,9
1983	9,2	383,9
1984	10,2	402,8
1985	11,4	437,0
1986	12,8	472,2
1987	13,6	510,4
1988	14,6	544,5
1989	16,4	588,1
1990	17,8	630,4
1991	18,6	685,9
1992	20,0	742,8
1993	21,9	801,3
1994	24,9	903,1
1995	27,3	983,6
1996	29,1	1076,7

Exemplo 2

```
# Importa bibliotecas
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
```

```
Renda = [336.1, 349.4, 362.9, 383.9, 402.8, 437.0, 472.2, 510.4, 544.5, 588.1, 630.4,
Venda = [8.0, 8.2, 8.5, 9.2, 10.2, 11.4, 12.8, 13.6, 14.6, 16.4, 17.8, 18.6, 20.0, 21.
df = pd.DataFrame(list(zip(Renda, Venda)), columns =['Renda','Venda'])
print(df)
```

```
     Renda  Venda
0    336.1    8.0
1    349.4    8.2
2    362.9    8.5
3    383.9    9.2
4    402.8   10.2
5    437.0   11.4
6    472.2   12.8
7    510.4   13.6
8    544.5   14.6
```

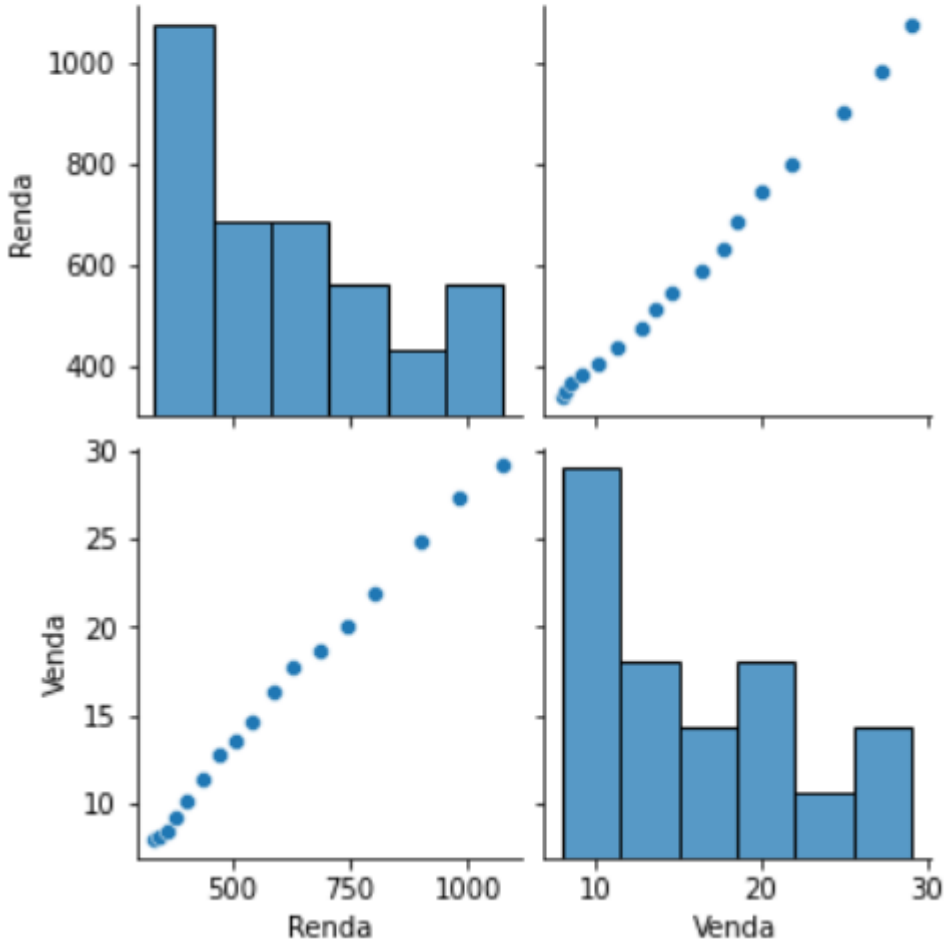
Exemplo 2

```
corr = df.corr()
print(corr)
```

```
          Renda     Venda
Renda  1.000000  0.997693
Venda  0.997693  1.000000
```

```
# Mostra a correção entre as variáveis
sns.pairplot(df)
```

```
<seaborn.axisgrid.PairGrid at 0x144e084abe0>
```



Exemplo 2

```
# Importa as Bibliotecas
import statsmodels.api as sm
from statsmodels.formula.api import ols

# Regressão - Variável Independente Renda
model_2 = ols('Venda ~ Renda', df).fit()
print(model_2.summary())
```

Exemplo 2

OLS Regression Results

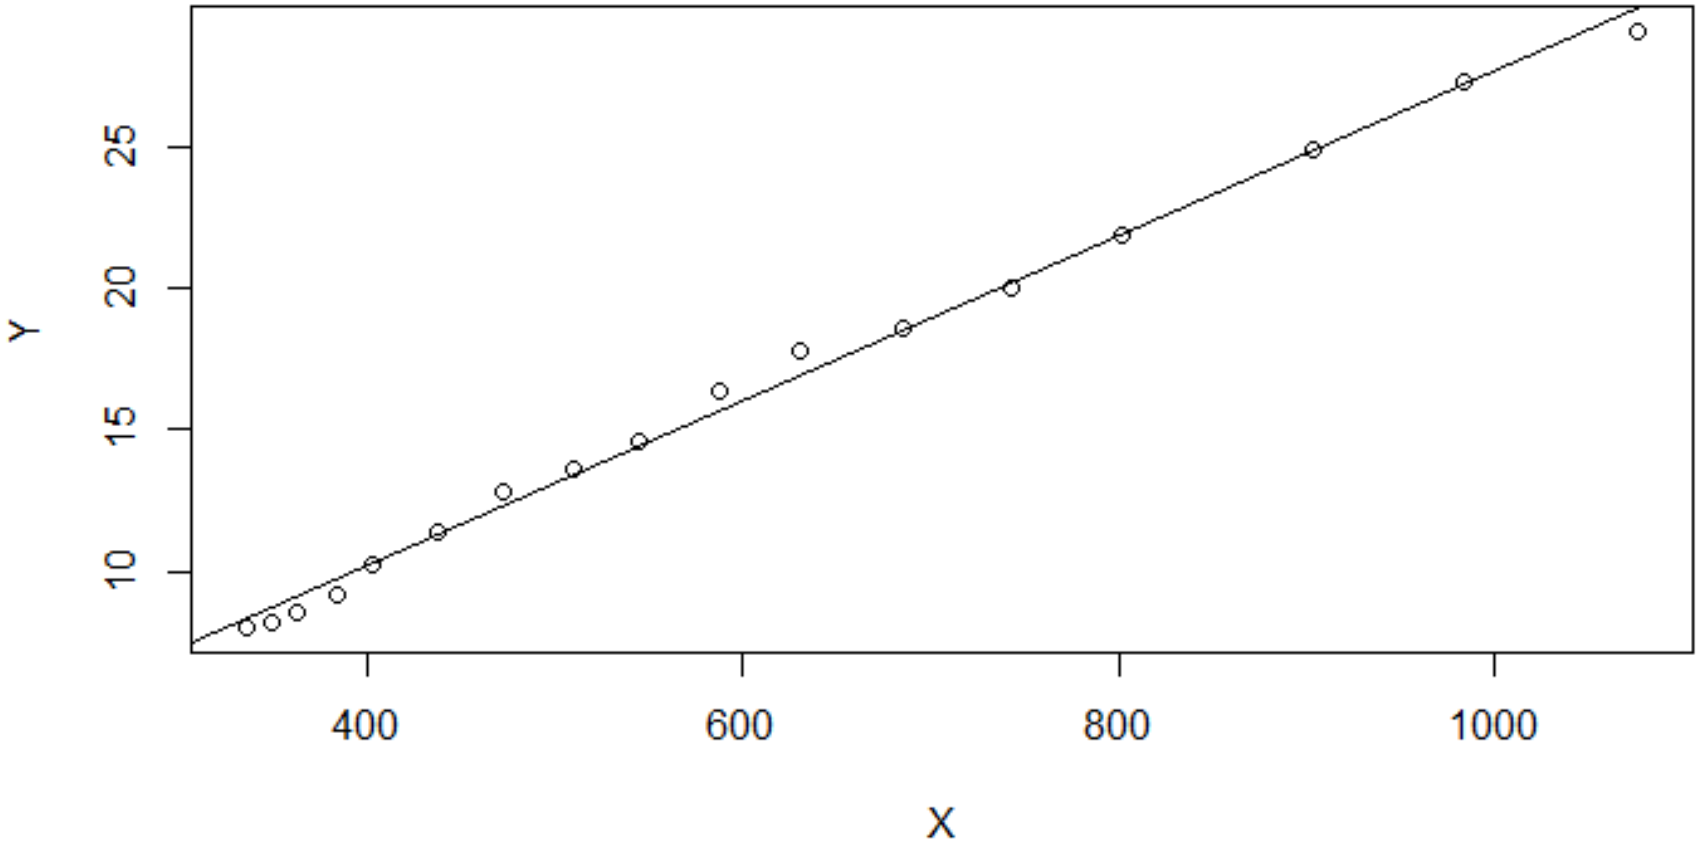
Dep. Variable:	Venda	R-squared:	0.995
Model:	OLS	Adj. R-squared:	0.995
Method:	Least Squares	F-statistic:	3240.
Date:	Mon, 21 Nov 2022	Prob (F-statistic):	6.08e-19
Time:	18:50:22	Log-Likelihood:	-10.462
No. Observations:	17	AIC:	24.92
Df Residuals:	15	BIC:	26.59
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-1.5046	0.329	-4.573	0.000	-2.206	-0.803
Renda	0.0292	0.001	56.920	0.000	0.028	0.030

Omnibus:	0.126	Durbin-Watson:	0.722
Prob(Omnibus):	0.939	Jarque-Bera (JB):	0.207
Skew:	0.162	Prob(JB):	0.902
Kurtosis:	2.568	Cond. No.	1.83e+03

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 1.83e+03. This might indicate that there are
strong multicollinearity or other numerical problems.

Exemplo 2



Teste de Durbin-Watson p/Exemplo 2

Ano	Vendas (Y)	Renda (X)	e_t	e_t-e_{t-1}	$(e_t-e_{t-1})^2$	e_t^2
1980	8,0	336,1	-0,3			0,1
1981	8,2	349,4	-0,5	-0,2	0,0	0,2
1982	8,5	362,9	-0,6	-0,1	0,0	0,3
1983	9,2	383,9	-0,5	0,1	0,0	0,3
1984	10,2	402,8	-0,1	0,4	0,2	0,0
1985	11,4	437,0	0,1	0,2	0,0	0,0
1986	12,8	472,2	0,5	0,4	0,1	0,3
1987	13,6	510,4	0,2	-0,3	0,1	0,0
1988	14,6	544,5	0,2	0,0	0,0	0,0
1989	16,4	588,1	0,7	0,5	0,3	0,5
1990	17,8	630,4	0,9	0,2	0,0	0,8
1991	18,6	685,9	0,1	-0,8	0,7	0,0
1992	20,0	742,8	-0,2	-0,3	0,1	0,0
1993	21,9	801,3	0,0	0,2	0,0	0,0
1994	24,9	903,1	0,0	0,0	0,0	0,0
1995	27,3	983,6	0,1	0,1	0,0	0,0
1996	29,1	1076,7	-0,8	-0,9	0,8	0,7
					2,5	**3,4**

Teste de Durbin-Watson p/Exemplo 2

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2} = \frac{2{,}5}{3{,}3} = 0{,}7218$$

- Valores de referência para $\alpha = 1\%$ de nível de significância, amostra de 17 dados e 1 variável independente:

Critical Values for the Durbin-Watson Test: 1% Significance Level

T=6 to 100, K=2 to 21 (K <= T-4)

K includes intercept

T	K	dL	dU
17.	**2.**	**0.87363**	**1.10210**
17.	3.	0.77209	1.25512
17.	4.	0.67158	1.43193
17.	5.	0.57380	1.63022

DW < 0,87 → aceitamos H_1 (os resíduos são correlacionados)

Teste de Durbin-Watson p/Exemplo 2

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2} = \frac{2{,}5}{3{,}3} = 0{,}7218$$

```
from statsmodels.stats.stattools import durbin_watson

#realiza o teste Durbin-Watson
durbin_watson(model_2.resid)
```

```
0.7218064442510285
```

Exemplo 2b

- Tendo em vista a correlação entre os resíduos, uma nova variável explanatória será introduzida, que consiste na taxa de desemprego da região.

Ano	Vendas	Renda Líquida	Taxa
1980	8,0	336,1	5,5
1981	8,2	349,4	5,5
1982	8,5	362,9	6,7
1983	9,2	383,9	5,5
1984	10,2	402,8	5,7
1985	11,4	437,0	5,2
1986	12,8	472,2	4,5
1987	13,6	510,4	3,8
1988	14,6	544,5	3,8
1989	16,4	588,1	3,6
1990	17,8	630,4	3,5
1991	18,6	685,9	4,9
1992	20,0	742,8	5,9
1993	21,9	801,3	5,6
1994	24,9	903,1	4,9
1995	27,3	983,6	5,6
1996	29,1	1076,7	8,5

Exemplo 2b

```
# Importa bibliotecas
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
```

```
Renda = [336.1, 349.4, 362.9, 383.9, 402.8, 437.0, 472.2, 510.4, 544.5, 588.1, 630.4,
Taxa = [5.5, 5.5, 6.7, 5.5, 5.7, 5.2, 4.5, 3.8, 3.8, 3.6, 3.5, 4.9, 5.9, 5.6, 4.9, 5.6
Venda = [8.0, 8.2, 8.5, 9.2, 10.2, 11.4, 12.8, 13.6, 14.6, 16.4, 17.8, 18.6, 20.0, 21.
df = pd.DataFrame(list(zip(Renda, Taxa, Venda)), columns =['Renda','Taxa','Venda'])
print(df)
```

```
     Renda  Taxa  Venda
0    336.1   5.5    8.0
1    349.4   5.5    8.2
2    362.9   6.7    8.5
3    383.9   5.5    9.2
4    402.8   5.7   10.2
5    437.0   5.2   11.4
6    472.2   4.5   12.8
7    510.4   3.8   13.6
```

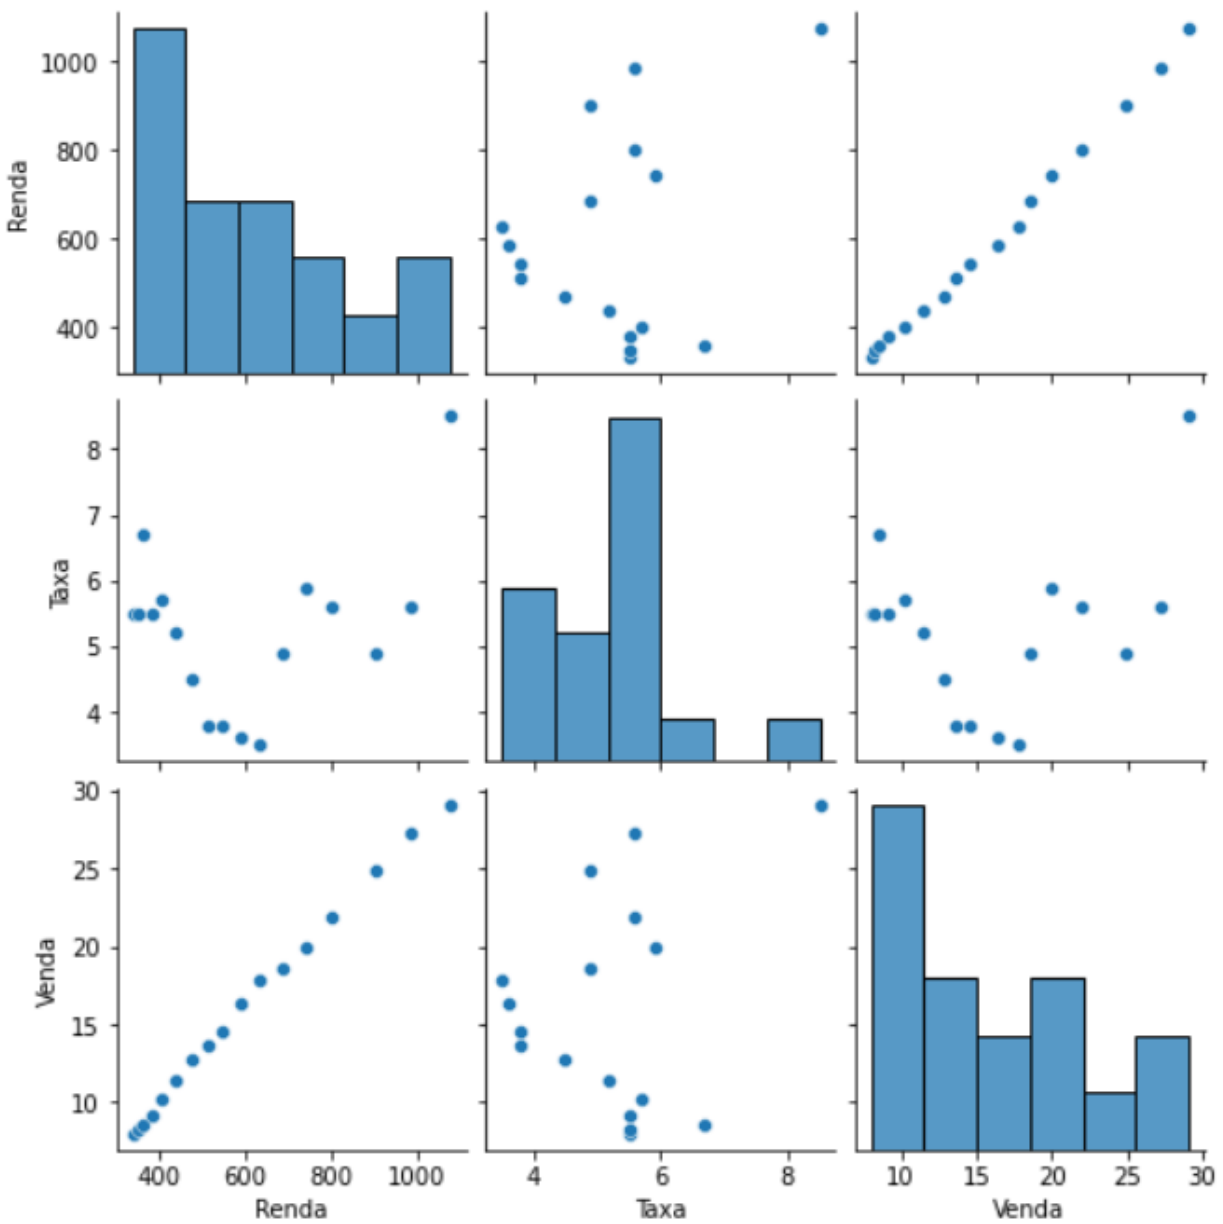
Exemplo 2b

```
corr = df.corr()
print(corr)
```

	Renda	Taxa	Venda
Renda	1.000000	0.299212	0.997693
Taxa	0.299212	1.000000	0.240537
Venda	0.997693	0.240537	1.000000

```
# Mostra a correção entre as variáveis
sns.pairplot(df)
```

```
<seaborn.axisgrid.PairGrid at 0x144e20debe0>
```



Exemplo 2b

```
# Importa as Bibliotecas
import statsmodels.api as sm
from statsmodels.formula.api import ols

# Regressão - Variável Independente Renda
model_2b = ols('Venda ~ Renda + Taxa', df).fit()
print(model_2b.summary())
```

Exemplo 2b

OLS Regression Results

Dep. Variable:	Venda	R-squared:	0.999
Model:	OLS	Adj. R-squared:	0.999
Method:	Least Squares	F-statistic:	7638.
Date:	Mon, 21 Nov 2022	Prob (F-statistic):	5.40e-22
Time:	19:08:56	Log-Likelihood:	3.2740
No. Observations:	17	AIC:	-0.5479
Df Residuals:	14	BIC:	1.952
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-0.0140	0.250	-0.056	0.956	-0.550	0.522
Renda	0.0297	0.000	119.963	0.000	0.029	0.030
Taxa	-0.3499	0.047	-7.514	0.000	-0.450	-0.250

Omnibus:	2.354	Durbin-Watson:	1.980
Prob(Omnibus):	0.308	Jarque-Bera (JB):	1.061
Skew:	0.066	Prob(JB):	0.588
Kurtosis:	1.784	Cond. No.	3.04e+03

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 3.04e+03. This might indicate that there are
strong multicollinearity or other numerical problems.

Teste de Durbin-Watson p/Exemplo 2b

Ano	Vendas (Y)	Renda (X2)	Taxa (X3)	e_t	e_t-e_{t-1}	$(e_t-e_{t-1})^2$	e_t^2
1980	8,0	336,1	5,5	-0,1			0,0
1981	8,2	349,4	5,5	-0,3	-0,2	0,0	0,1
1982	8,5	362,9	6,7	0,1	0,3	0,1	0,0
1983	9,2	383,9	5,5	-0,3	-0,3	0,1	0,1
1984	10,2	402,8	5,7	0,2	0,5	0,3	0,1
1985	11,4	437,0	5,2	0,2	0,0	0,0	0,1
1986	12,8	472,2	4,5	0,3	0,1	0,0	0,1
1987	13,6	510,4	3,8	-0,2	-0,6	0,3	0,1
1988	14,6	544,5	3,8	-0,3	0,0	0,0	0,1
1989	16,4	588,1	3,6	0,2	0,4	0,2	0,0
1990	17,8	630,4	3,5	0,3	0,1	0,0	0,1
1991	18,6	685,9	4,9	-0,1	-0,4	0,1	0,0
1992	20,0	742,8	5,9	0,0	0,1	0,0	0,0
1993	21,9	801,3	5,6	0,0	0,1	0,0	0,0
1994	24,9	903,1	4,9	-0,2	-0,3	0,1	0,1
1995	27,3	983,6	5,6	0,0	0,3	0,1	0,0
1996	29,1	1076,7	8,5	0,1	0,0	0,0	0,0
						1,3	**0,7**

Teste de Durbin-Watson p/Exemplo 2b

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2} = \frac{1{,}3}{0{,}7} = 1{,}98$$

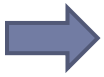
- Valores de referência para $\alpha = 1\%$ de nível de significância, amostra de 17 dados e 2 variáveis independentes:

Critical Values for the Durbin-Watson Test: 1% Significance Level

T=6 to 100, K=2 to 21 (K <= T-4)

K includes intercept

T	K	dL	dU
17.	2.	0.87363	1.10210
17.	**3.**	**0.77209**	**1.25512**
17.	4.	0.67158	1.43193
17.	5.	0.57380	1.63022



DW > 1,25 → aceitamos H_0 (os resíduos **não** são correlacionados)

Teste de Durbin-Watson p/Exemplo 2b

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} e_t{}^2} = \frac{1{,}3}{0{,}7} = 1{,}98$$

```
from statsmodels.stats.stattools import durbin_watson

#realiza o teste Durbin-Watson
durbin_watson(model_2b.resid)
```

```
1.9800332212843381
```

Modelos Autoregressivos

Modelos Autorregressivos

- Uma maneira de resolver problemas com autocorrelação é desenvolvendo um modelo que reconhece a relação entre os resíduos.

$$Y_t = \beta_0 + \beta X_t + \epsilon_t$$

$$\epsilon_t = \rho\epsilon_{t-1} + v_t \quad \text{ou} \quad v_t = \epsilon_t - \rho\epsilon_{t-1}$$

- O novo modelo pode ser escrito como:

$$Y_t = \beta_0 + \beta X_t + \rho\epsilon_{t-1} + v_t$$

- Se ρ for conhecido, então o método dos mínimos quadrados pode ser usado para gerar os parâmetros do modelo de regressão, de forma que os erros sejam independentes.

Modelos Autorregressivos

- Notar que

$$Y_t = \beta_0 + \beta X_t + \epsilon_t$$
$$Y_{t-1} = \beta_0 + \beta X_{t-1} + \epsilon_{t-1}$$

- Vamos multiplicar a segunda expressão por ρ e subtrair da primeira expressão.

$$Y_t - \rho Y_{t-1} = (\beta_0 - \rho\beta_0) + (\beta X_t - \rho\beta X_{t-1}) + (\epsilon_t - \rho\epsilon_{t-1})$$

- Fazendo $Y_t' = Y_t - \rho Y_{t-1}$, $X_t' = X_t - \rho X_{t-1}$, $\beta_0' = \beta_0(1-\rho)$: $Y_t' = \beta_0' + \beta X_t' + v_t$
- Para a expressão de Y_t', os erros não apresentam correlação serial, e o valor de β é mantido.

Modelos Autorregressivos

- Para poder fazer a devida transformação, faz-se necessário estimar o valor de ρ.
- Uma das formas empregadas de estimativa de ρ é por meio do coeficiente de correlação entre os resíduos defasados por 1 período.
- Outro método, proposto por Cochrane e Orcutt utiliza $\hat{\rho}$ como estimativa de ρ, onde:

$$\hat{\rho} = \frac{\sum_{t=2}^{n} e_t e_{t-1}}{\sum_{t=2}^{n} {e_{t-1}}^2}$$

Exemplo 3

- Considere o histórico de vendas de um determinado produto (10^3 \$), ao qual foi associada a renda líquida (10^6 \$) da região.

Ano	Vendas	Renda Líquida
1976	3307	273,4
1977	3556	291,3
1978	3601	306,9
1979	3721	317,1
1980	4036	336,1
1981	4134	349,4
1982	4268	362,9
1983	4758	383,9
1984	5093	402,8
1985	5716	437,0
1986	6357	472,2

Ano	Vendas	Renda Líquida
1987	6769	510,4
1988	7296	544,5
1989	8178	588,1
1990	8844	630,4
1991	9251	685,9
1992	10006	742,8
1993	11200	801,3
1994	12500	903,1
1995	13101	983,6
1996	13640	1076,7

Exemplo 3

```
# Importa as Bibliotecas
import statsmodels.api as sm
from statsmodels.formula.api import ols

# Regressão - Variável Independente Renda
model_3 = ols('Venda ~ Renda', df).fit()
print(model_3.summary())
```

Exemplo 3

OLS Regression Results

Dep. Variable:	Venda	R-squared:	0.991
Model:	OLS	Adj. R-squared:	0.990
Method:	Least Squares	F-statistic:	2006.
Date:	Mon, 21 Nov 2022	Prob (F-statistic):	9.91e-21
Time:	19:48:58	Log-Likelihood:	-151.01
No. Observations:	21	AIC:	306.0
Df Residuals:	19	BIC:	308.1
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-502.4086	185.280	-2.712	0.014	-890.204	-114.613
Renda	14.0250	0.313	44.787	0.000	13.370	14.680

Omnibus:	7.142	Durbin-Watson:	0.640
Prob(Omnibus):	0.028	Jarque-Bera (JB):	4.795
Skew:	-0.854	Prob(JB):	0.0909
Kurtosis:	4.601	Cond. No.	1.49e+03

Teste de Durbin-Watson p/Exemplo 3

Ano	Vendas (Y)	Renda (X)	e_t	e_t-e_{t-1}	$(e_t-e_{t-1})^2$	e_t^2
1976	3307	273,4	-25,0			626,3
1977	3556	291,3	-27,1	-2,0	4,2	733,0
1978	3601	306,9	-200,9	-173,8	30.203,0	40.346,3
1979	3721	317,1	-223,9	-23,1	531,5	50.139,7
1980	4036	336,1	-175,4	48,5	2.354,7	30.763,0
1981	4134	349,4	-263,9	-88,5	7.838,0	69.657,1
1982	4268	362,9	-319,3	-55,3	3.062,2	101.929,4
1983	4758	383,9	-123,8	195,5	38.210,5	15.323,7
1984	5093	402,8	-53,9	69,9	4.889,9	2.901,1
1985	5716	437,0	89,5	143,3	20.547,8	8.007,3
1986	6357	472,2	236,8	147,3	21.703,2	56.075,9
1987	6769	510,4	113,0	-123,8	15.315,3	12.780,0
1988	7296	544,5	161,8	48,7	2.376,3	26.178,0
1989	8178	588,1	432,3	270,5	73.175,7	186.888,6
1990	8844	630,4	505,0	72,7	5.291,5	255.074,1
1991	9251	685,9	133,7	-371,4	137.928,7	17.865,3
1992	10006	742,8	90,6	-43,0	1.850,9	8.215,4
1993	11200	801,3	464,2	373,5	139.530,3	215.459,5
1994	12500	903,1	336,4	-127,7	16.318,8	113.185,9
1995	13101	983,6	-191,6	-528,0	278.797,2	36.703,4
1996	13640	1076,7	-958,3	-766,7	587.871,1	918.355,9
					1.387.800,6	**2.167.208,9**

Teste de Durbin-Watson p/Exemplo 3

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2} = \frac{1.387.800,6}{2.166.582,6} = 0,64$$

- Valores de referência para $\alpha = 1\%$ de nível de significância, amostra de 21 dados e 1 variável independente:

Critical Values for the Durbin-Watson Test: 1% Significance Level

T=6 to 100, K=2 to 21 (K <= T-4)

K includes intercept

T	K	dL	dU
21.	**2.**	**0.97545**	**1.16059**
21.	3.	0.88950	1.27688
21.	4.	0.80319	1.40823
21.	5.	0.71752	1.55360

DW < 0,97 → aceitamos H_1 (os resíduos são correlacionados)

Teste de Durbin-Watson p/Exemplo 3

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2} = \frac{1.387.800,6}{2.166.582,6} = 0,64$$

```
from statsmodels.stats.stattools import durbin_watson

#realiza o teste Durbin-Watson
durbin_watson(model_3.resid)
```

```
0.6403663650726367
```

Exemplo 3

- Correlação dos resíduos, defasados em 1 período:
- ρ ~ 0,627

T	U	V	W	X	Y	Z

Ano	Vendas (Y)	Renda (X)	e_t	e_t-e_{t-1}	$(e_t-e_{t-1})^2$	e_t^2
1976	3307	273,4	-25,0			626,3
1977	3556	291,3	-27,1	-2,0	4,2	733,0
1978	3601	306,9	-200,9	-173,8	30.203,0	40.346,3
1979	3721	317,1	-223,9	-23,1	531,5	50.139,7
1980	4036	336,1	-175,4	48,5	2.354,7	30.763,0
1981	4134	349,4	-263,9	-88,5	7.838,0	69.657,1
1982	4268	362,9	-319,3	-55,3	3.062,2	101.929,4
1983	4758	383,9	-123,8	195,5	38.210,5	15.323,7
1984	5093	402,8	-53,9	69,9	4.889,9	2.901,1
1985	5716	437,0	89,5	143,3	20.547,8	8.007,3
1986	6357	472,2	236,8	147,3	21.703,2	56.075,9
1987	6769	510,4	113,0	-123,8	15.315,3	12.780,0
1988	7296	544,5	161,8	48,7	2.376,3	26.178,0
1989	8178	588,1	432,3	270,5	73.175,7	186.888,6
1990	8844	630,4	505,0	72,7	5.291,5	255.074,1
1991	9251	685,9	133,7	-371,4	137.928,7	17.865,3
1992	10006	742,8	90,6	-43,0	1.850,9	8.215,4
1993	11200	801,3	464,2	373,5	139.530,3	215.459,5
1994	12500	903,1	336,4	-127,7	16.318,8	113.185,9
1995	13101	983,6	-191,6	-528,0	278.797,2	36.703,4
1996	13640	1076,7	-958,3	-766,7	587.871,1	918.355,9
					1.387.800,6	**2.167.208,9**

=CORREL(W5:W24;W6:W25)

Exemplo 3

- $Y_t' = Y_t - \rho Y_{t-1}$
- $Y_2' = Y_2 - 0{,}627 Y_1 = 3556 - 0{,}627 * 3307 = 1481{,}7$
- $X_t' = X_t - \rho X_{t-1}$
- $X_2' = X_2 - 0{,}627 X_1 = 291{,}3 - 0{,}627 * 273{,}4 = 119{,}8$

Ano	Vendas (Y)	Renda (X)	Vendas (Y')	Renda (X')
1976	3307	273,4		
1977	3556	291,3	1481,7	119,8
1978	3601	306,9	1370,5	124,2
1979	3721	317,1	1462,3	124,6
1980	4036	336,1	1702,0	137,2
1981	4134	349,4	1602,4	138,6
1982	4268	362,9	1675,0	143,7
1983	4758	383,9	2080,9	156,3
1984	5093	402,8	2108,6	162,0
1985	5716	437,0	2521,4	184,3
1986	6357	472,2	2771,7	198,1
1987	6769	510,4	2781,6	214,2
1988	7296	544,5	3050,2	224,4
1989	8178	588,1	3601,6	246,6
1990	8844	630,4	3714,4	261,5
1991	9251	685,9	3703,6	290,5
1992	10006	742,8	4203,3	312,6
1993	11200	801,3	4923,8	335,4
1994	12500	903,1	5474,8	400,5
1995	13101	983,6	5260,4	417,1
1996	13640	1076,7	5422,4	459,7

Exemplo 3

```
# Importa bibliotecas
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
```

```
Renda1 = [119.8, 124.2, 124.6, 137.2, 138.6, 143.7, 156.3, 162.0, 184.3, 198.1, 214.2, 224.4,
Venda1 = [1481.7, 1370.5, 1462.3, 1702.0, 1602.4, 1675.0, 2080.9, 2108.6, 2521.4, 2771.7, 278
df1 = pd.DataFrame(list(zip(Renda1, Venda1)), columns =['Renda1','Venda1'])
print(df1)
```

```
    Renda1  Venda1
0    119.8  1481.7
1    124.2  1370.5
2    124.6  1462.3
3    137.2  1702.0
4    138.6  1602.4
5    143.7  1675.0
6    156.3  2080.9
7    162.0  2108.6
8    184.3  2521.4
9    198.1  2771.7
```

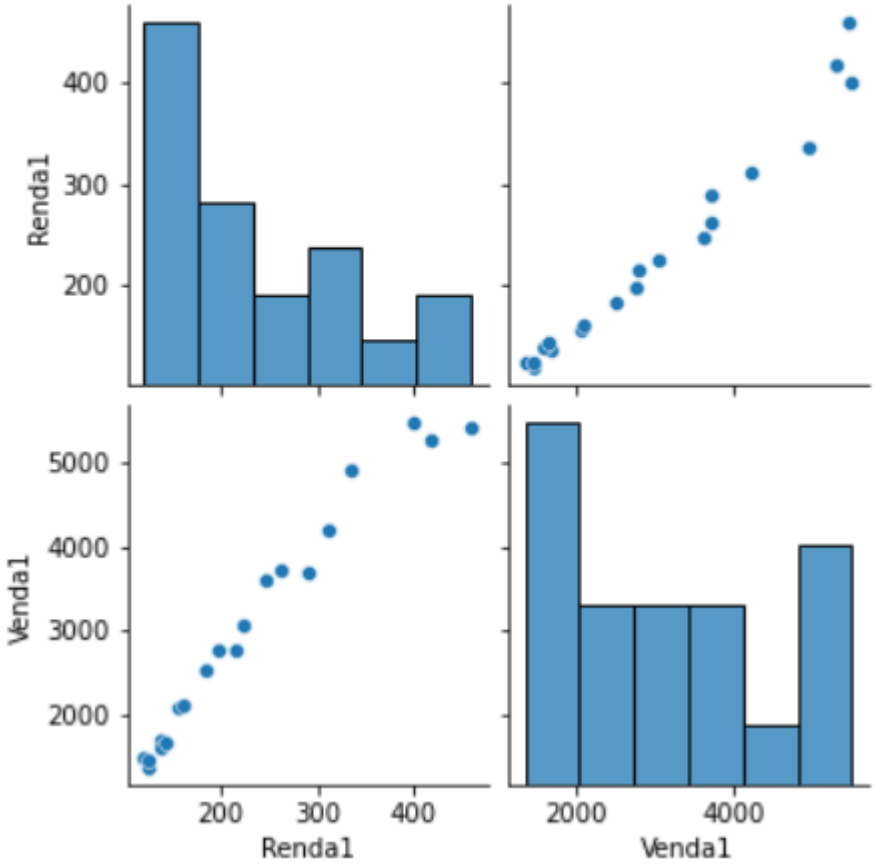
Exemplo 3

```
corr = df1.corr()
print(corr)
```

```
          Renda1    Venda1
Renda1  1.000000  0.983784
Venda1  0.983784  1.000000
```

```
# Mostra a correção entre as variáveis
sns.pairplot(df1)
```

```
<seaborn.axisgrid.PairGrid at 0x144e2873f40>
```



Exemplo 3

```
# Importa as Bibliotecas
import statsmodels.api as sm
from statsmodels.formula.api import ols

# Regressão - Variável Independente Renda
model_3b = ols('Venda1 ~ Renda1', df1).fit()
print(model_3b.summary())
```

Exemplo 3

OLS Regression Results

Dep. Variable:	Venda1	R-squared:	0.968
Model:	OLS	Adj. R-squared:	0.966
Method:	Least Squares	F-statistic:	541.6
Date:	Mon, 21 Nov 2022	Prob (F-statistic):	6.94e-15
Time:	19:59:44	Log-Likelihood:	-138.65
No. Observations:	20	AIC:	281.3
Df Residuals:	18	BIC:	283.3
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-29.1691	144.490	-0.202	0.842	-332.731	274.393
Renda1	13.2212	0.568	23.271	0.000	12.028	14.415

Omnibus:	1.473	Durbin-Watson:	0.882
Prob(Omnibus):	0.479	Jarque-Bera (JB):	0.335
Skew:	-0.197	Prob(JB):	0.846
Kurtosis:	3.497	Cond. No.	628.

Teste de Durbin-Watson p/Exemplo 3 (ajustado)

Ano	Vendas (Y)	Renda (X)	Vendas (Y')	Renda (X')	e_t	e_t-e_{t-1}	$(e_t-e_{t-1})^2$	e_t^2
1976	3307	273,4						
1977	3556	291,3	1481,7	119,8	-73,2			5.354,9
1978	3601	306,9	1370,5	124,2	-242,2	-169,0	28.558,1	58.645,7
1979	3721	317,1	1462,3	124,6	-155,9	86,3	7.445,6	24.298,9
1980	4036	336,1	1702,0	137,2	-82,8	73,1	5.345,9	6.850,1
1981	4134	349,4	1602,4	138,6	-200,6	-117,9	13.890,6	40.249,9
1982	4268	362,9	1675,0	143,7	-196,3	4,3	18,8	38.527,3
1983	4758	383,9	2080,9	156,3	44,0	240,3	57.724,2	1.933,8
1984	5093	402,8	2108,6	162,0	-4,1	-48,1	2.311,7	16,8
1985	5716	437,0	2521,4	184,3	113,3	117,4	13.793,1	12.845,8
1986	6357	472,2	2771,7	198,1	181,8	68,5	4.686,5	33.050,3
1987	6769	510,4	2781,6	214,2	-21,4	-203,2	41.291,5	458,2
1988	7296	544,5	3050,2	224,4	113,1	134,5	18.096,3	12.795,3
1989	8178	588,1	3601,6	246,6	370,9	257,8	66.453,8	137.569,0
1990	8844	630,4	3714,4	261,5	286,0	-84,9	7.210,7	81.788,6
1991	9251	685,9	3703,6	290,5	-107,7	-393,7	155.024,1	11.608,7
1992	10006	742,8	4203,3	312,6	99,9	207,7	43.132,4	9.987,9
1993	11200	801,3	4923,8	335,4	518,8	418,9	175.441,7	269.150,6
1994	12500	903,1	5474,8	400,5	209,1	-309,7	95.922,2	43.716,1
1995	13101	983,6	5260,4	417,1	-225,4	-434,5	188.794,2	50.814,4
1996	13640	1076,7	5422,4	459,7	-626,7	-401,3	161.030,4	392.760,9
							1.086.171,8	**1.232.423,3**

Teste de Durbin-Watson p/Exemplo 3 (ajustado)

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2} = \frac{1.086.171,8}{1.232.423,3} = 0,88$$

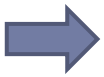
- Valores de referência para $\alpha = 1\%$ de nível de significância, amostra de 20 dados e 1 variável independente:

Critical Values for the Durbin-Watson Test: 1% Significance Level

T=6 to 100, K=2 to 21 (K <= T-4)

K includes intercept

T	K	dL	dU
20.	**2.**	**0.952**	**1.147**
20.	3.	0.862	1.270
20.	4.	0.774	1.410
20.	5.	0.684	1.567



DW < 0,952 → aceitamos H_1 (os resíduos são correlacionados); adicionar uma outra variável independente (explanatória).

Teste de Durbin-Watson p/Exemplo 3 (ajustado)

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2} = \frac{1.086.171,8}{1.232.423,3} = 0,88$$

```
from statsmodels.stats.stattools import durbin_watson

#realiza o teste Durbin-Watson
durbin_watson(model_3b.resid)
```

```
0.8817811116243258
```

Exemplo 4

- Para os dados fornecidos: faça a regressão linear simples e aplique os teste de Durbin-Watson para verificar se os resíduos são correlacionados. Neste caso, estime o coeficiente de correlação, realize a transformação linear, gerando as expressões de Y_t' e X_t', e reaplique o teste para checar se ainda há correlação.

X	Y
85,54	0,6714894
85,54	0,6784707
85,63	0,7781225
85,08	-0,273323
84,50	0,1297735
84,57	0,0858459
89,08	0,5436565
89,27	0,5651866
89,34	0,6508005
89,82	0,7829627
90,38	0,7983509
90,86	0,8479512
80,25	-0,894701
80,02	-0,718794
80,13	-0,699353
80,69	-0,69569
80,67	-0,465024
80,69	-0,393902
80,74	-0,634646
80,71	-0,367182

X	Y
80,64	-0,316156
86,97	0,2889577
87,77	0,3409281
87,91	0,3281562
88,05	0,2104538
88,44	0,430642
88,97	0,5209901
83,28	-0,295232
83,07	-0,242121
82,84	-0,160644
82,65	-0,253704
82,77	-0,357107
82,77	-0,292386
82,65	-0,421149
82,35	-0,334685
82,65	-0,24966
82,38	-0,28272
82,45	-0,166732
82,75	-0,170216

Exemplo 4

```
# Importa bibliotecas
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
```

```
X = [85.54, 85.54, 85.63, 85.08, 84.5, 84.57, 89.08, 89.27, 89.34, 89.82, 90.38, 90.86, 80.25,
Y = [0.671489391, 0.678470672, 0.778122455, -0.2733233, 0.129773502, 0.085845933, 0.543656478,
df4 = pd.DataFrame(list(zip(X, Y)), columns =['X','Y'])
print(df4)
```

```
       X         Y
0   85.54  0.671489
1   85.54  0.678471
2   85.63  0.778122
3   85.08 -0.273323
4   84.50  0.129774
5   84.57  0.085846
6   89.08  0.543656
7   89.27  0.565187
8   89.34  0.650801
9   89.82  0.782963
10  90.38  0.798351
11  90.86  0.847951
```

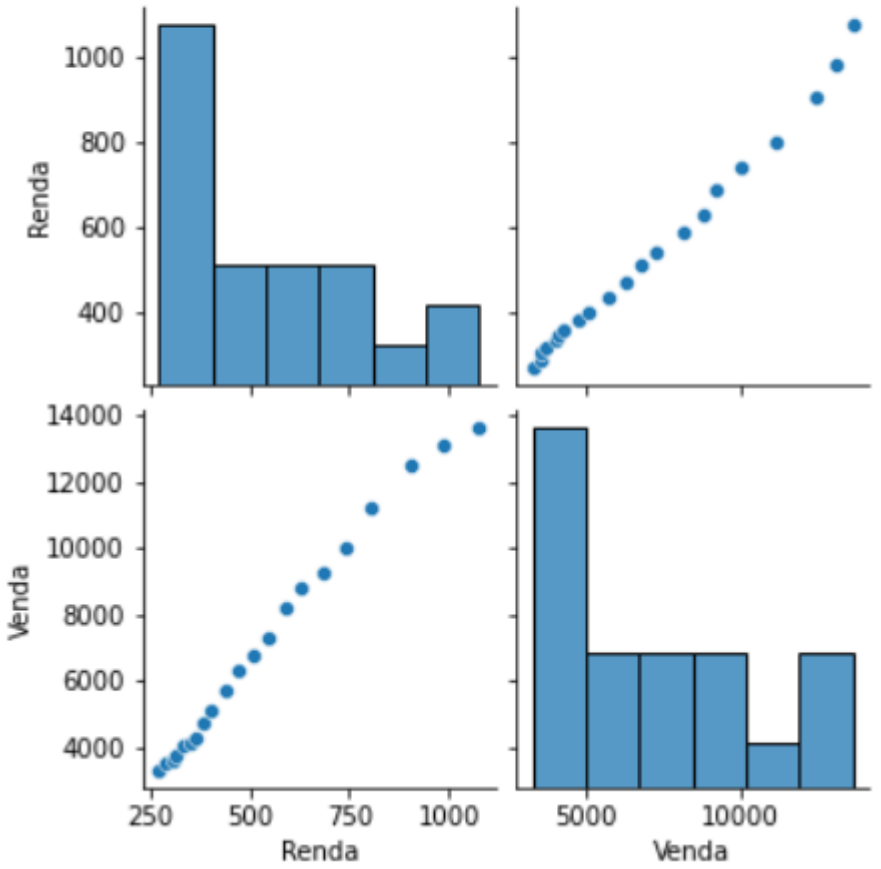
Exemplo 4

```
corr = df4.corr()
print(corr)
```

```
          X         Y
X  1.000000  0.914064
Y  0.914064  1.000000
```

```
# Mostra a correção entre as variáveis
sns.pairplot(df)
```

```
<seaborn.axisgrid.PairGrid at 0x144e26a1e80>
```



Exemplo 4

```
# Importa as Bibliotecas
import statsmodels.api as sm
from statsmodels.formula.api import ols

# Regressão - Variável Independente Renda
model_4 = ols('Y ~ X', df4).fit()
print(model_4.summary())
```

Exemplo 4

OLS Regression Results

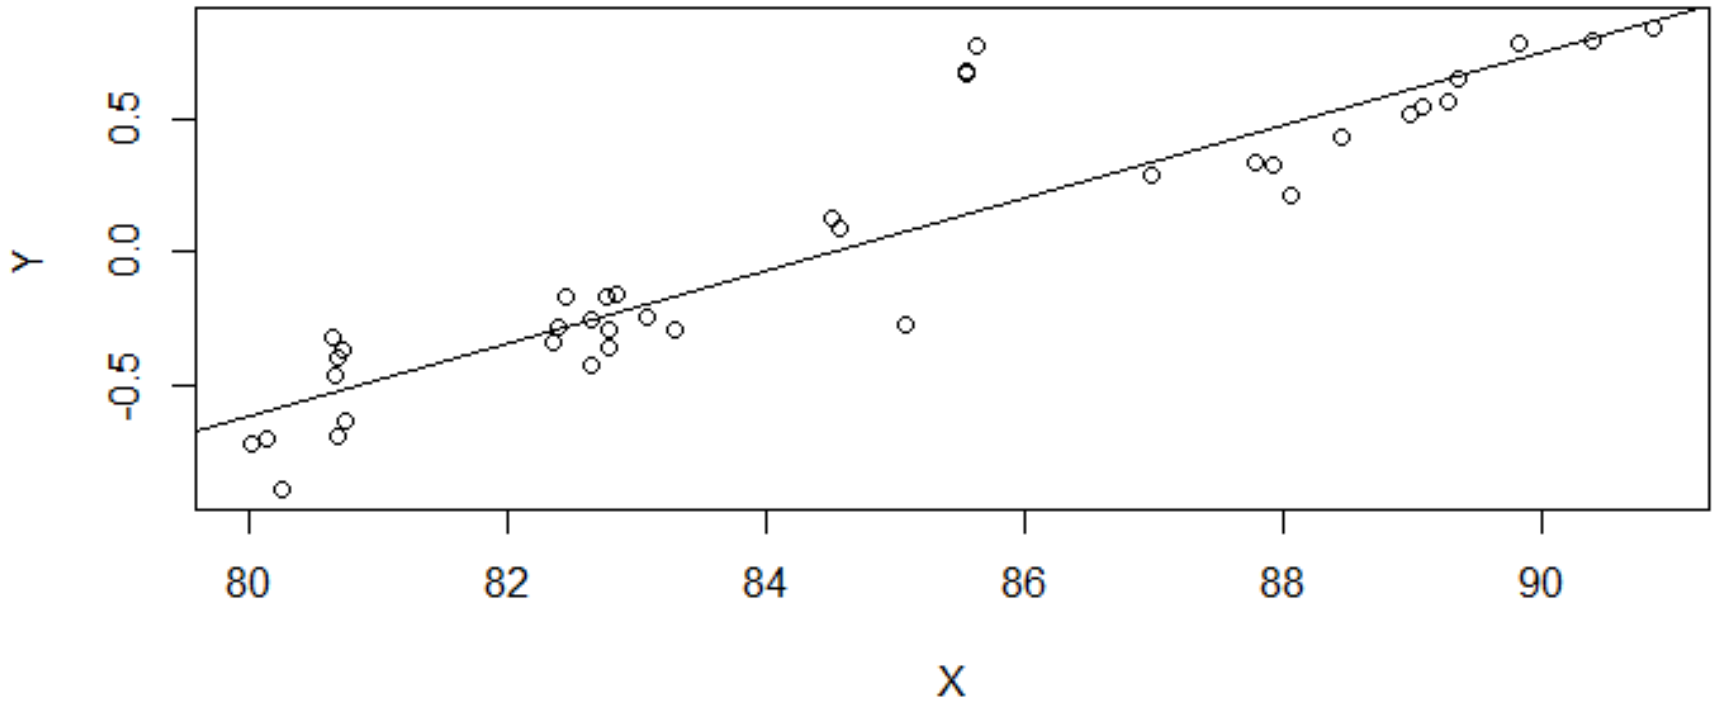
Dep. Variable:	Y	R-squared:	0.836
Model:	OLS	Adj. R-squared:	0.831
Method:	Least Squares	F-statistic:	187.9
Date:	Mon, 21 Nov 2022	Prob (F-statistic):	4.47e-16
Time:	21:25:43	Log-Likelihood:	7.0533
No. Observations:	39	AIC:	-10.11
Df Residuals:	37	BIC:	-6.780
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-11.5266	0.841	-13.699	0.000	-13.231	-9.822
X	0.1364	0.010	13.709	0.000	0.116	0.157

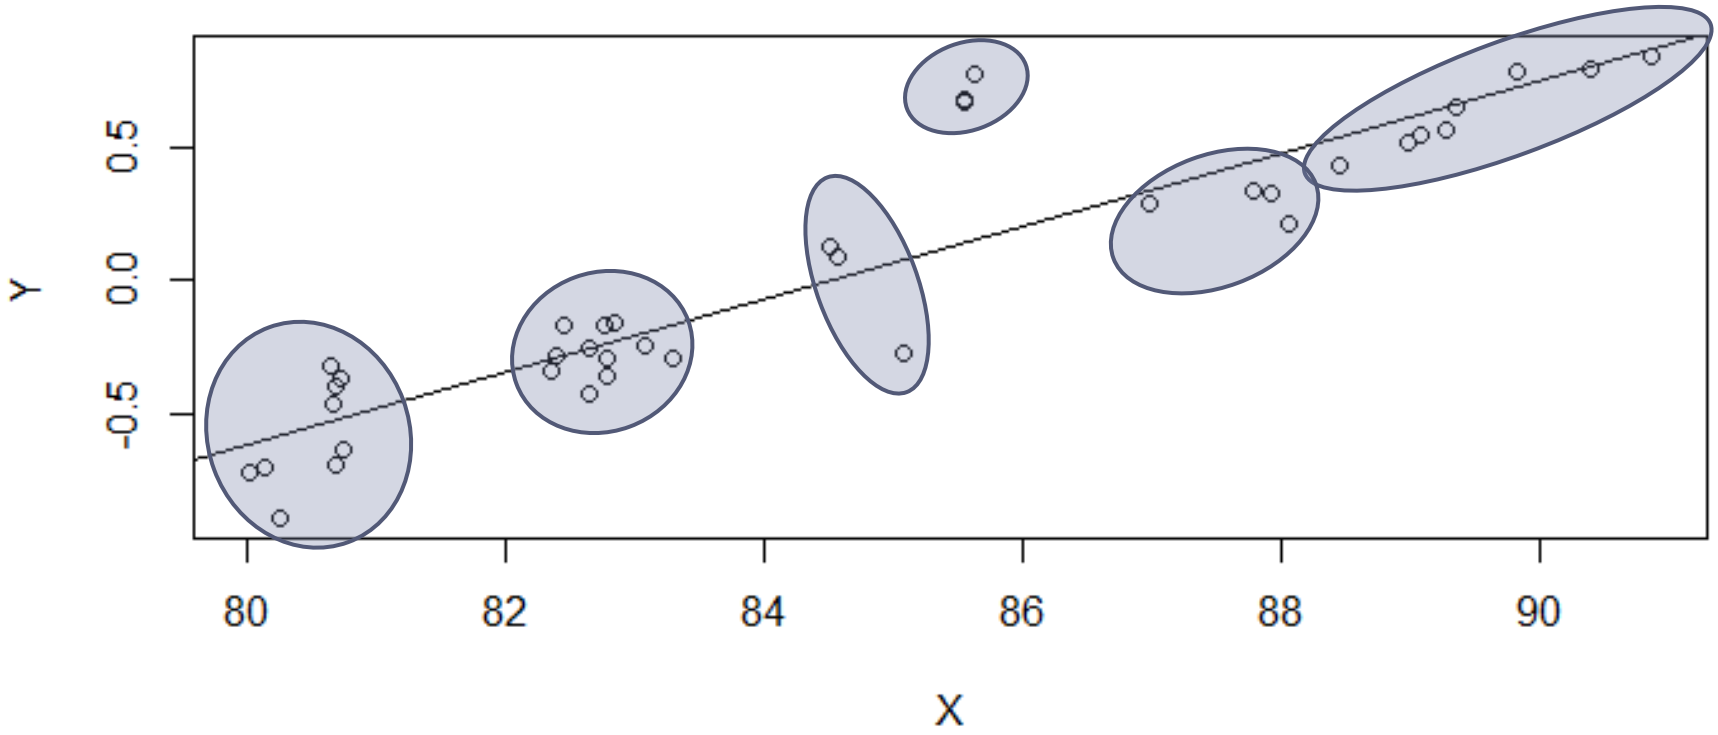
Omnibus:	17.071	Durbin-Watson:	1.116
Prob(Omnibus):	0.000	Jarque-Bera (JB):	21.232
Skew:	1.364	Prob(JB):	2.45e-05
Kurtosis:	5.372	Cond. No.	2.14e+03

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 2.14e+03. This might indicate that there are
strong multicollinearity or other numerical problems.

Exemplo 4

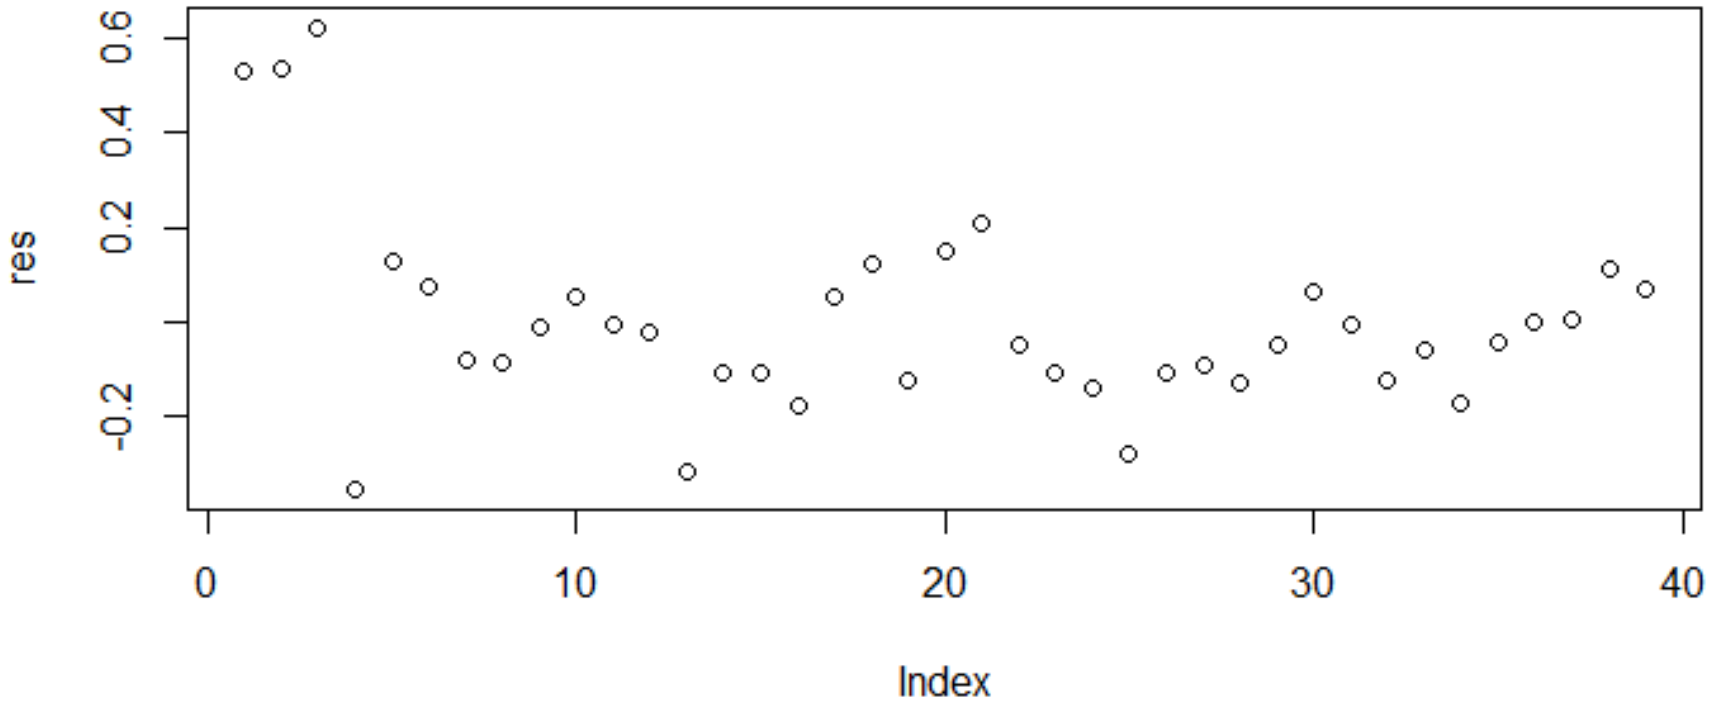


Resíduos



Padrões de resíduos diferentes...

Gráfico dos Resíduos



Teste de Durbin-Watson p/ Exemplo 4

X	Y	e_t	e_t-e_{t-1}	$(e_t-e_{t-1})^2$	e_t^2
85,54	0,6714894	0,5282			0,2790
85,54	0,6784707	0,5352	0,0070	0,0000	0,2864
85,63	0,7781225	0,6226	0,0874	0,0076	0,3876
85,08	-0,273323	-0,3538	-0,9764	0,9534	0,1252
84,50	0,1297735	0,1284	0,4822	0,2325	0,0165
84,57	0,0858459	0,0749	-0,0535	0,0029	0,0056
89,08	0,5436565	-0,0826	-0,1575	0,0248	0,0068
89,27	0,5651866	-0,0869	-0,0044	0,0000	0,0076
89,34	0,6508005	-0,0109	0,0761	0,0058	0,0001
89,82	0,7829627	0,0558	0,0667	0,0044	0,0031
90,38	0,7983509	-0,0052	-0,0610	0,0037	0,0000
90,86	0,8479512	-0,0211	-0,0159	0,0003	0,0004
80,25	-0,894701	-0,3163	-0,2952	0,0871	0,1000
80,02	-0,718794	-0,1090	0,2073	0,0430	0,0119
80,13	-0,699353	-0,1046	0,0044	0,0000	0,0109
80,69	-0,69569	-0,1773	-0,0727	0,0053	0,0314
80,67	-0,465024	0,0561	0,2334	0,0545	0,0031
80,69	-0,393902	0,1245	0,0684	0,0047	0,0155
80,74	-0,634646	-0,1231	-0,2476	0,0613	0,0151
80,71	-0,367182	0,1485	0,2716	0,0737	0,0220

Teste de Durbin-Watson p/ Exemplo 4

X	Y	e_t	$e_t - e_{t-1}$	$(e_t - e_{t-1})^2$	e_t^2
80,64	-0,316156	0,2091	0,0606	0,0037	0,0437
86,97	0,2889577	-0,0494	-0,2585	0,0668	0,0024
87,77	0,3409281	-0,1066	-0,0572	0,0033	0,0114
87,91	0,3281562	-0,1384	-0,0319	0,0010	0,0192
88,05	0,2104538	-0,2752	-0,1368	0,0187	0,0758
88,44	0,430642	-0,1083	0,1670	0,0279	0,0117
88,97	0,5209901	-0,0902	0,0180	0,0003	0,0081
83,28	-0,295232	-0,1302	-0,0400	0,0016	0,0169
83,07	-0,242121	-0,0484	0,0818	0,0067	0,0023
82,84	-0,160644	0,0644	0,1129	0,0127	0,0042
82,65	-0,253704	-0,0027	-0,0671	0,0045	0,0000
82,77	-0,357107	-0,1225	-0,1198	0,0143	0,0150
82,77	-0,292386	-0,0577	0,0647	0,0042	0,0033
82,65	-0,421149	-0,1701	-0,1124	0,0126	0,0289
82,35	-0,334685	-0,0427	0,1274	0,0162	0,0018
82,65	-0,24966	0,0013	0,0441	0,0019	0,0000
82,38	-0,28272	0,0051	0,0038	0,0000	0,0000
82,45	-0,166732	0,1116	0,1064	0,0113	0,0124
82,75	-0,170216	0,0671	-0,0444	0,0020	0,0045
			Soma:	**1,7749**	**1,5904**

Teste de Durbin-Watson

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2} = \frac{1{,}7749}{1{,}5904} = 1{,}116$$

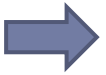
- Valores de referência para $\alpha = 1\%$ de nível de significância, amostra de 39 dados e 1 variável independente:

Critical Values for the Durbin-Watson Test: 1% Significance Level

T=6 to 100, K=2 to 21 (K <= T-4)

K includes intercept

T	K	dL	dU
39.	**2.**	**1.23655**	**1.33711**
39.	3.	1.18698	1.39312
39.	4.	1.13655	1.45306
39.	5.	1.08545	1.51682



DW < 1,23 → aceitamos H_1 (os resíduos são correlacionados)

Teste de Durbin-Watson

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2} = \frac{1{,}7749}{1{,}5904} = 1{,}116$$

```
from statsmodels.stats.stattools import durbin_watson

#realiza o teste Durbin-Watson
durbin_watson(model_4.resid)
```

```
1.1160394251564412
```

Estimativa do Coeficiente de Autocorrelação dos Resíduos

- Estimativa do coeficiente de autocorrelação dos resíduos
- Pela correlação entre os resíduos com defasagem de 1 período: ρ ~ 0,3896
- Pelo método de Cochrane e Orcutt:

$$\rho \sim \frac{\sum_{t=2}^{n} e_t e_{t-1}}{\sum_{t=2}^{n} {e_{t-1}}^2} = \frac{0{,}5612}{1{,}5904} = 0{,}3528$$

- Vamos adotar a estimativa de ρ pelo cálculo de autocorrelação.
- As duas estimativas são próximas e levam a resultados equivalentes: com ρ = 0,3528, obtém-se β = 0,1363 e DW = 2,27, também acima de dU.

Modelo reescrito

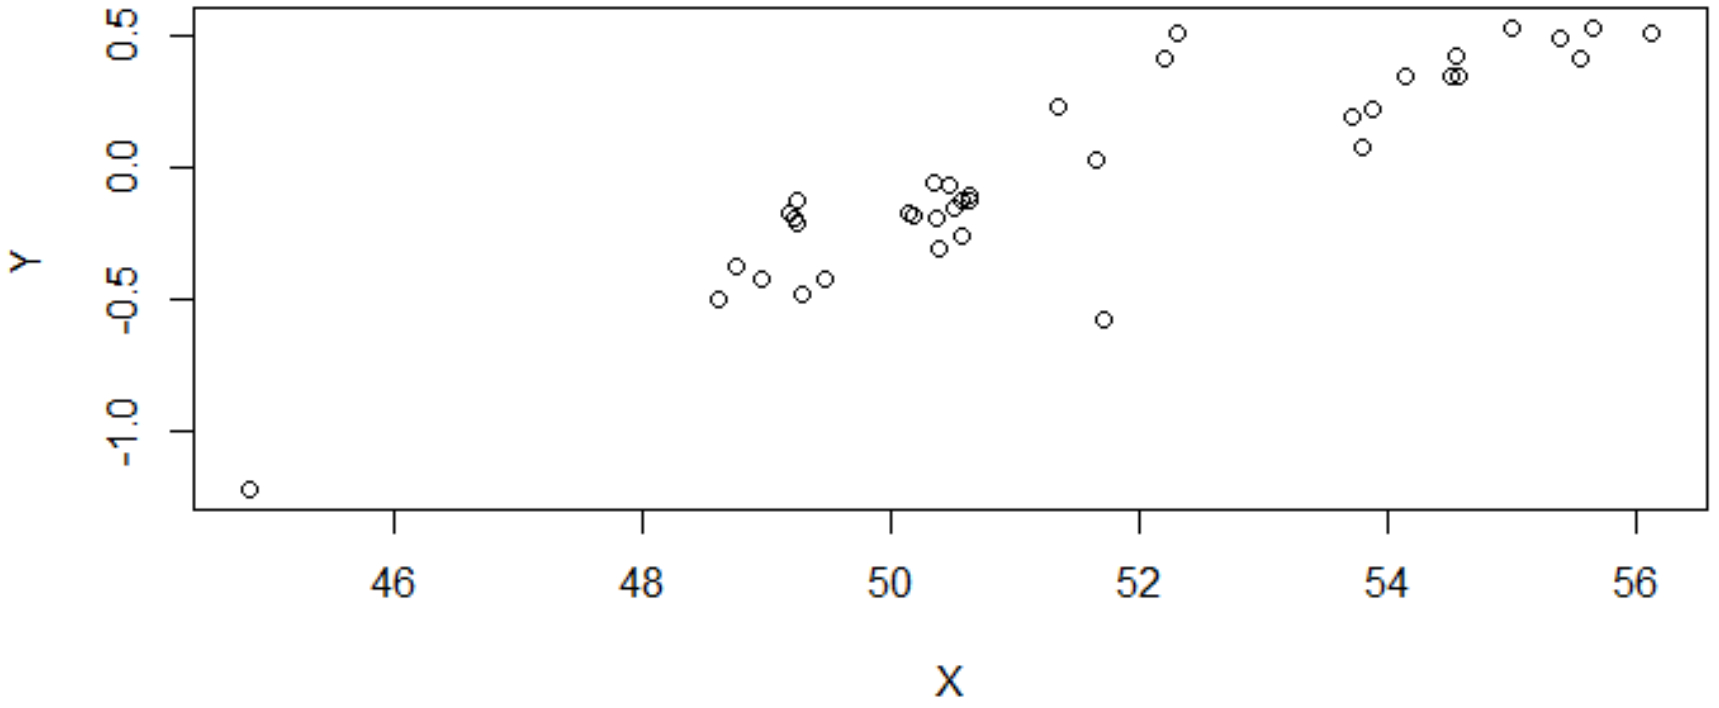
- $Y_t' = Y_t - \rho Y_{t-1}$
- $Y_2' = Y_2 - 0{,}3896 Y_1 = 0{,}6785 - 0{,}3896 * 0{,}6715 = 0{,}4169$
- $X_t' = X_t - \rho X_{t-1}$
- $X_2' = X_2 - 0{,}3896 X_1 = 85{,}54 - 0{,}3896 * 85{,}54 = 52{,}21$
- etc...

Modelo reescrito

```
X1 = [52.22, 52.31, 51.72, 51.35, 51.65, 56.13, 54.57, 54.56, 55.01, 55.39, 55.65, 44.85, 48.76,
Y1 = [0.416872252, 0.513804272, -0.576463762, 0.236254623, 0.035288853, 0.510212673, 0.353389228,
df4b = pd.DataFrame(list(zip(X1, Y1)), columns =['X1','Y1'])
print(df4b)
```

```
      X1        Y1
0   52.22  0.416872
1   52.31  0.513804
2   51.72 -0.576464
3   51.35  0.236255
4   51.65  0.035289
5   56.13  0.510213
6   54.57  0.353389
7   54.56  0.430615
8   55.01  0.529424
9   55.39  0.493325
10  55.65  0.536930
11  44.85 -1.225045
12  48.76 -0.370237
13  48.96 -0.419326
14  49.47 -0.423236
15  49.23 -0.193998
16  49.26 -0.212738
17  49.30 -0.481190
18  49.26 -0.119937
```

Gráfico de Dispersão



Regressão Linear

```
# Importa as Bibliotecas
import statsmodels.api as sm
from statsmodels.formula.api import ols

# Regressão - Variável Independente Renda
model_4b = ols('Y1 ~ X1', df4b).fit()
print(model_4b.summary())
```

Regressão Linear

OLS Regression Results

Dep. Variable:	Y1	R-squared:	0.804
Model:	OLS	Adj. R-squared:	0.798
Method:	Least Squares	F-statistic:	147.5
Date:	Mon, 21 Nov 2022	Prob (F-statistic):	2.70e-14
Time:	21:43:50	Log-Likelihood:	13.272
No. Observations:	38	AIC:	-22.54
Df Residuals:	36	BIC:	-19.27
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-7.0580	0.580	-12.167	0.000	-8.234	-5.881
X1	0.1366	0.011	12.147	0.000	0.114	0.159

Omnibus:	8.604	Durbin-Watson:	2.359
Prob(Omnibus):	0.014	Jarque-Bera (JB):	12.699
Skew:	-0.452	Prob(JB):	0.00175
Kurtosis:	5.684	Cond. No.	1.05e+03

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 1.05e+03. This might indicate that there are
strong multicollinearity or other numerical problems.

Curva de Regressão

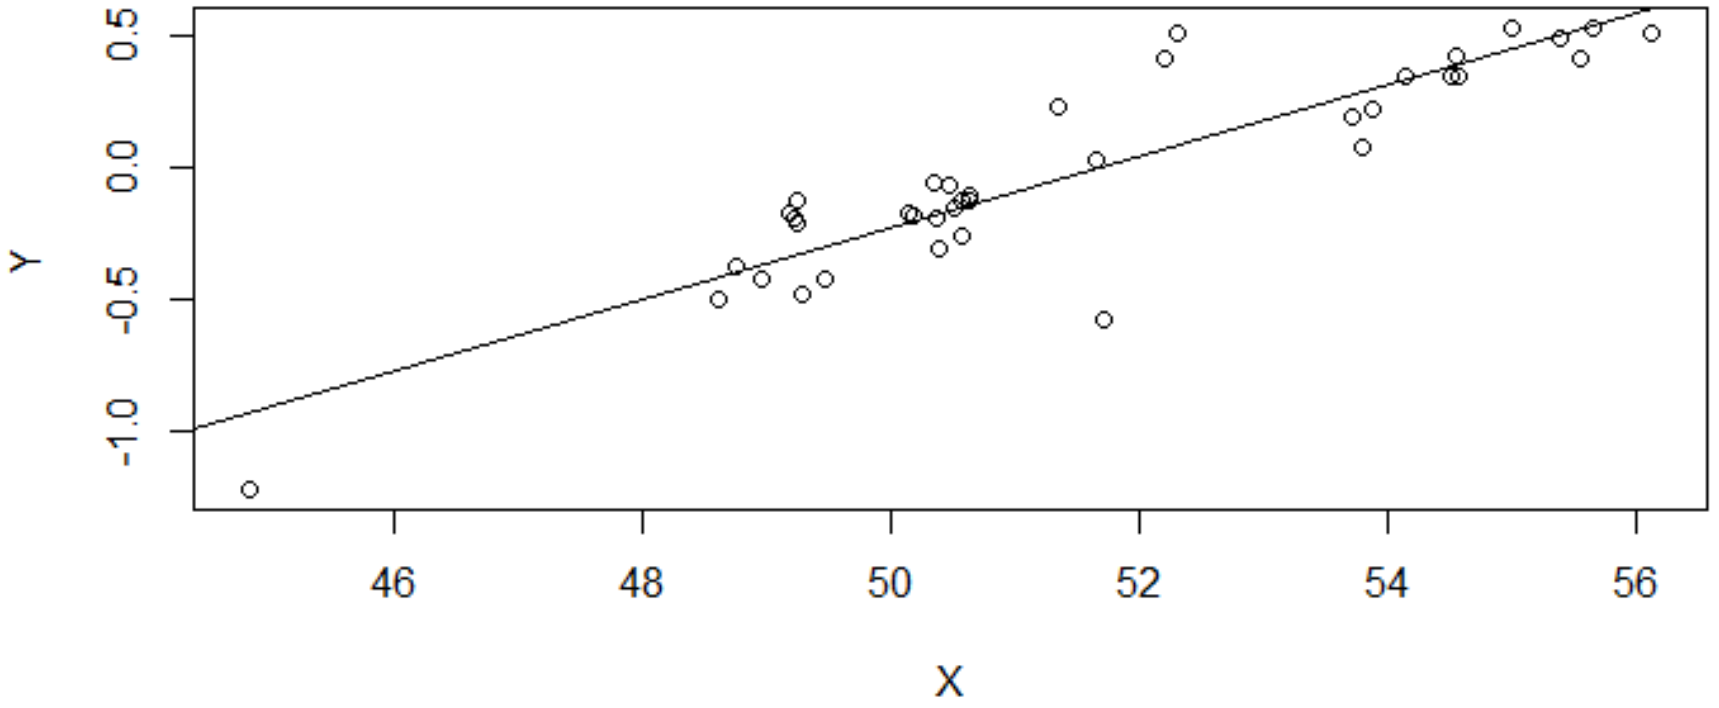
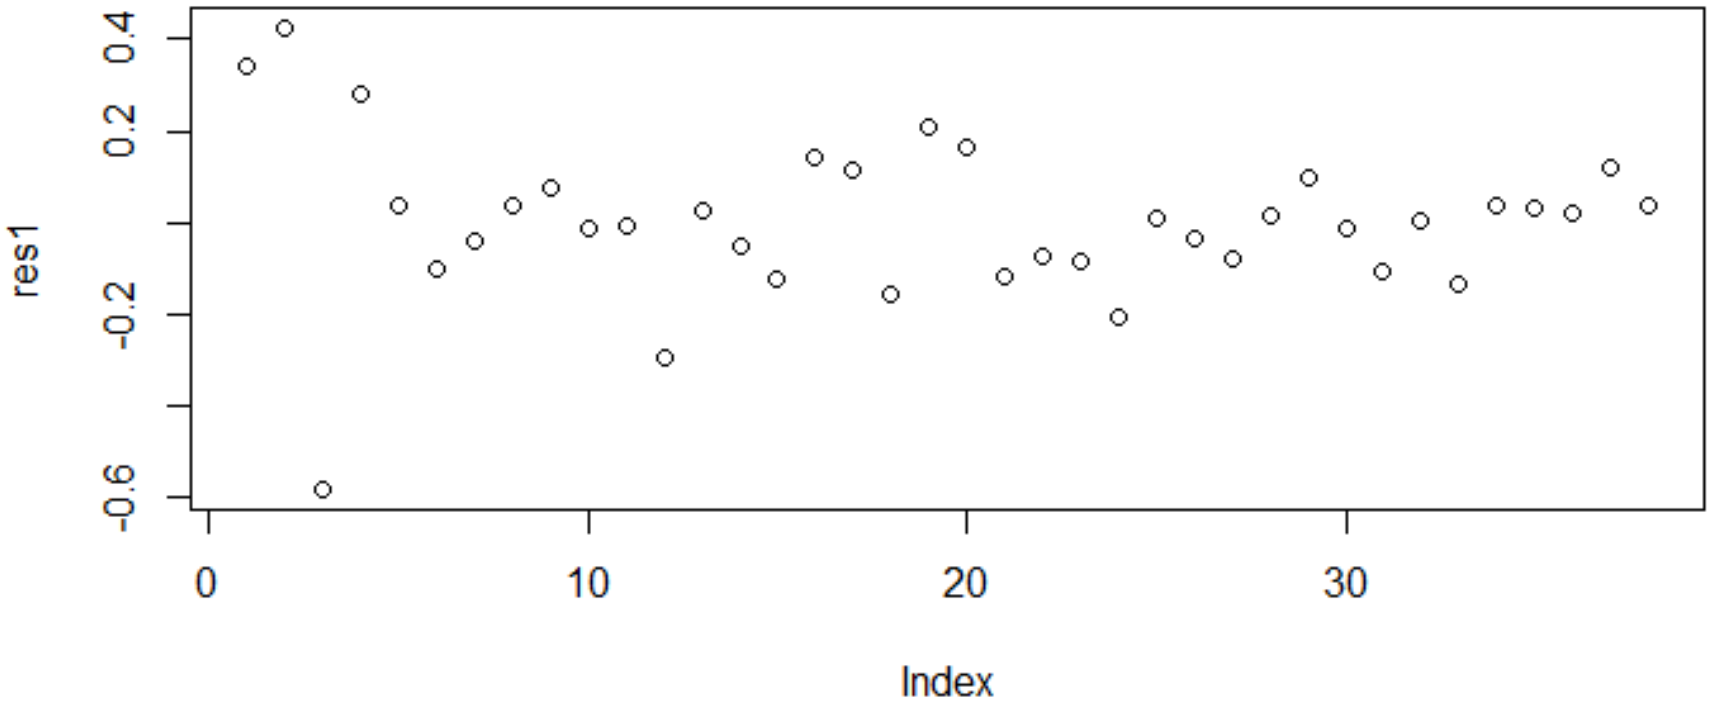


Gráfico de Resíduos



Teste de Durbin-Watson

X'	Y'	e_t	e_t-e_{t-1}	$(e_t-e_{t-1})^2$	e_t^2
52,22	0,4168723	0,3427			0,1175
52,31	0,5138043	0,4274	0,0846	0,0072	0,1827
51,72	-0,576464	-0,5830	-1,0104	1,0208	0,3399
51,35	0,2362546	0,2797	0,8627	0,7442	0,0782
51,65	0,0352889	0,0383	-0,2414	0,0583	0,0015
56,13	0,5102127	-0,0991	-0,1374	0,0189	0,0098
54,57	0,3533892	-0,0418	0,0572	0,0033	0,0018
54,56	0,4306155	0,0359	0,0778	0,0060	0,0013
55,01	0,5294243	0,0729	0,0370	0,0014	0,0053
55,39	0,4933248	-0,0141	-0,0870	0,0076	0,0002
55,65	0,5369302	-0,0063	0,0078	0,0001	0,0000
44,85	-1,225045	-0,2935	-0,2872	0,0825	0,0862
48,76	-0,370237	0,0281	0,3216	0,1035	0,0008
48,96	-0,419326	-0,0482	-0,0764	0,0058	0,0023
49,47	-0,423236	-0,1228	-0,0745	0,0056	0,0151
49,23	-0,193998	0,1390	0,2618	0,0685	0,0193
49,26	-0,212738	0,1164	-0,0225	0,0005	0,0136
49,30	-0,48119	-0,1578	-0,2742	0,0752	0,0249
49,26	-0,119937	0,2102	0,3680	0,1354	0,0442

Teste de Durbin-Watson

X'	Y'	e_t	e_t-e_{t-1}	$(e_t-e_{t-1})^2$	e_t^2
49,20	-0,173109	0,1650	-0,0452	0,0020	0,0272
55,55	0,4121254	-0,1181	-0,2831	0,0801	0,0139
53,89	0,2283562	-0,0743	0,0438	0,0019	0,0055
53,72	0,1953376	-0,0838	-0,0096	0,0001	0,0070
53,80	0,0826109	-0,2082	-0,1244	0,0155	0,0434
54,14	0,3486535	0,0120	0,2202	0,0485	0,0001
54,52	0,3532208	-0,0351	-0,0471	0,0022	0,0012
48,62	-0,498198	-0,0811	-0,0460	0,0021	0,0066
50,63	-0,127105	0,0159	0,0970	0,0094	0,0003
50,48	-0,066319	0,0969	0,0810	0,0066	0,0094
50,38	-0,19112	-0,0142	-0,1111	0,0123	0,0002
50,57	-0,258269	-0,1078	-0,0936	0,0088	0,0116
50,52	-0,153264	0,0036	0,1114	0,0124	0,0000
50,40	-0,307242	-0,1340	-0,1376	0,0189	0,0180
50,15	-0,170614	0,0372	0,1712	0,0293	0,0014
50,57	-0,119273	0,0316	-0,0056	0,0000	0,0010
50,18	-0,185458	0,0183	-0,0133	0,0002	0,0003
50,36	-0,05659	0,1232	0,1049	0,0110	0,0152
50,63	-0,10526	0,0373	-0,0859	0,0074	0,0014
			-0,3055	**2,6135**	**1,1082**

Teste de Durbin-Watson

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2} = \frac{2{,}6135}{1{,}1082} = 2{,}358$$

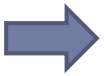
- Valores de referência para $\alpha = 1\%$ de nível de significância, amostra de 38 dados e 1 variável independente:

Critical Values for the Durbin-Watson Test: 1% Significance Level

T=6 to 100, K=2 to 21 (K <= T-4)

K includes intercept

T	K	dL	dU
38.	**2.**	**1.22681**	**1.32997**
38.	3.	1.17601	1.38763
38.	4.	1.12435	1.44946
38.	5.	1.07202	1.51530



DW > 1,32 → aceitamos H_0 (os resíduos **não** são correlacionados)

Teste de Durbin-Watson

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2} = \frac{2{,}6135}{1{,}1082} = 2{,}358$$

```
from statsmodels.stats.stattools import durbin_watson

#realiza o teste Durbin-Watson
durbin_watson(model_4b.resid)
```

```
2.358879849101729
```

Previsão com o Modelo Ajustado

- Com os resíduos não correlacionados (DW = 2,358 > dU), o modelo transformado pode ser usado para previsão:

$$\widehat{Y_t}' = \beta_0' + \beta X_t' = -7{,}058 + 0{,}1366 X_t'$$

- Mas a variável de interesse é Y_t, e não Y'_t. Basta desfazer a transformação, lembrando que $Y_t' = Y_t - \rho Y_{t-1}$:

$$\hat{Y}_t = \rho Y_{t-1} + \beta_0' + \beta(X_t - \rho X_{t-1})$$

- Coeficientes do modelo original: $\beta_0 = \beta_0'/(1-\rho) = -7{,}058/0{,}6104 \approx -11{,}56$ e $\beta = 0{,}1366$ (a inclinação é preservada).
- A previsão usa o valor **observado** de Y no período anterior: daí o nome **autorregressivo**.

Previsão – Exemplo 4

- Última observação (t = 39): $X_{39} = 82{,}75$ e $Y_{39} = -0{,}1702$
- Supondo que, para o próximo período, $X_{40} = 83{,}00$:
  - 1) $X'_{40} = X_{40} - \rho X_{39} = 83{,}00 - 0{,}3896 \cdot 82{,}75 = 50{,}76$
  - 2) $\hat{Y}'_{40} = -7{,}058 + 0{,}1366 \cdot 50{,}76 = -0{,}1242$
  - 3) $\hat{Y}_{40} = \hat{Y}'_{40} + \rho Y_{39} = -0{,}1242 + 0{,}3896 \cdot (-0{,}1702) = -0{,}1905$
- Intervalo de previsão (95%): o intervalo calculado para Y'_{40} é deslocado de ρY_{39} (valor conhecido):

$$Y_{40} \in [-0{,}55\ ;\ 0{,}17]$$

- Pela regressão original (Y ~ X): $\hat{Y}_{40} = -0{,}203$, IP 95% [−0,63 ; 0,22], intervalo mais largo e, além disso, **não confiável**, pois os resíduos são correlacionados.

Previsão – Exemplo 4 (Python)

```
# Coeficiente de autocorrelação e última observação
rho = 0.3896
x_ant, y_ant = df4['X'].iloc[-1], df4['Y'].iloc[-1]   # X39 e Y39

# Valor de X previsto para o próximo período
x_novo = 83.00

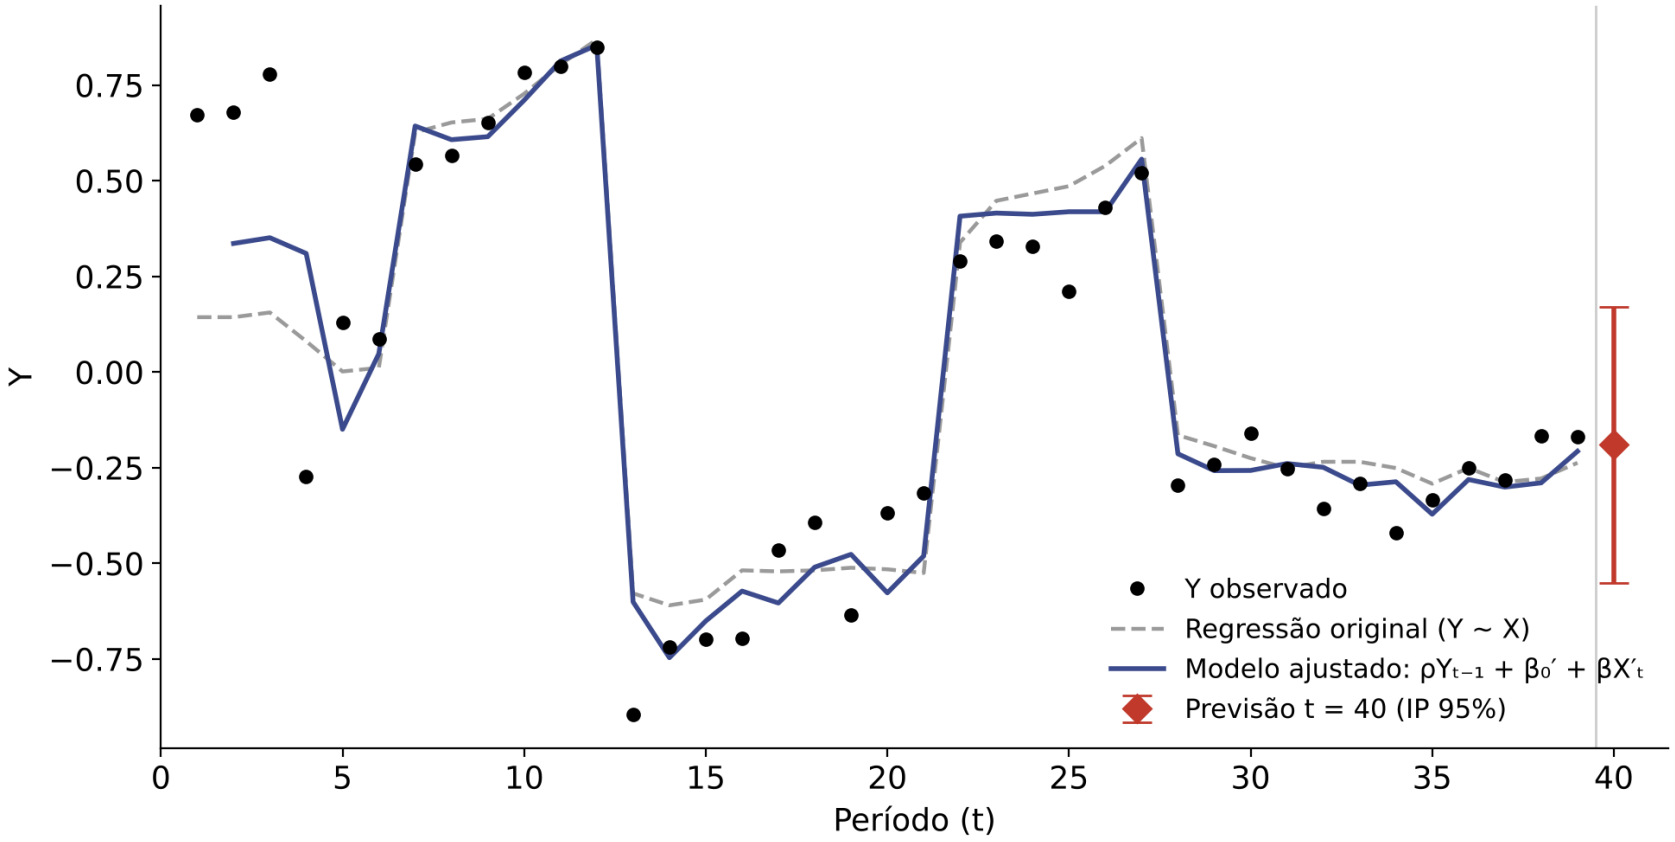
# 1) Transforma X  ->  X'
x_novo_t = x_novo - rho * x_ant

# 2) Prevê Y' com o modelo ajustado (model_4b: Y1 ~ X1)
prev = model_4b.get_prediction(pd.DataFrame({'X1': [x_novo_t]}))
res  = prev.summary_frame(alpha=0.05)

# 3) Desfaz a transformação:  Y = Y' + rho * Y_ant
y_prev = res['mean'][0]         + rho * y_ant
ic_inf = res['obs_ci_lower'][0] + rho * y_ant
ic_sup = res['obs_ci_upper'][0] + rho * y_ant
print(f"Previsão: {y_prev:.4f}   IP 95%: [{ic_inf:.3f} ; {ic_sup:.3f}]")
```

```
Previsão: -0.1904   IP 95%: [-0.551 ; 0.171]
```

Previsão – Exemplo 4



- O modelo ajustado acompanha melhor a série porque incorpora a informação do período anterior (raiz do erro quadrático médio, um passo à frente: 0,171 contra 0,186 da regressão original).